南京大學
NANJING UNIVERSITY

自然语言处理

神经网络和语言模型

吴震

wuz@nju.edu.cn

2023年3月

目录

01 神经网络基础

BASICS OF NEURAL NETWORK

人工神经网络

- 人工神经网络（Artificial Neural Network，ANN）从信息处理角度对人脑神经元网络进行抽象， 建立某种算法数学模型，从而达到处理信息的目的。
  - 神经元之间进行连接，组成网络
  - 网络通常是某种算法或者函数的逼近，也可能是一种逻辑策略的表达

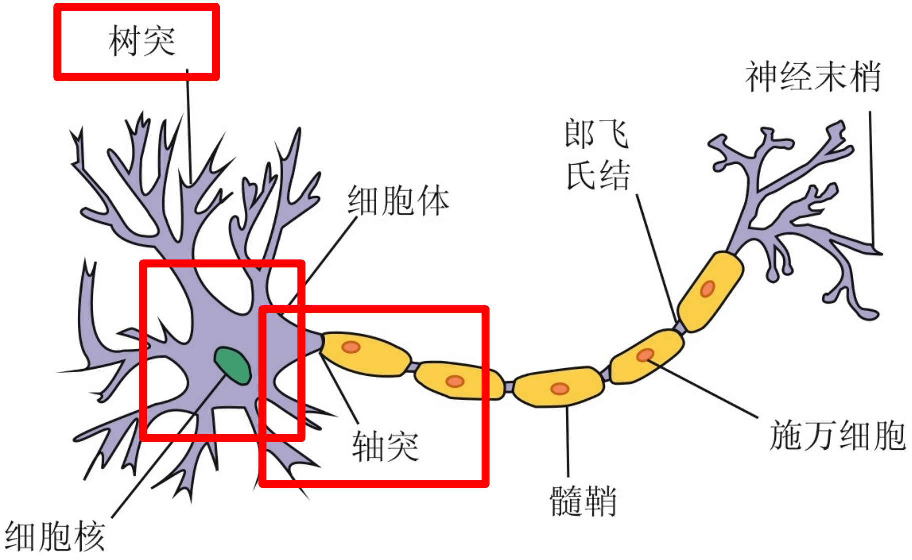

大脑神经元

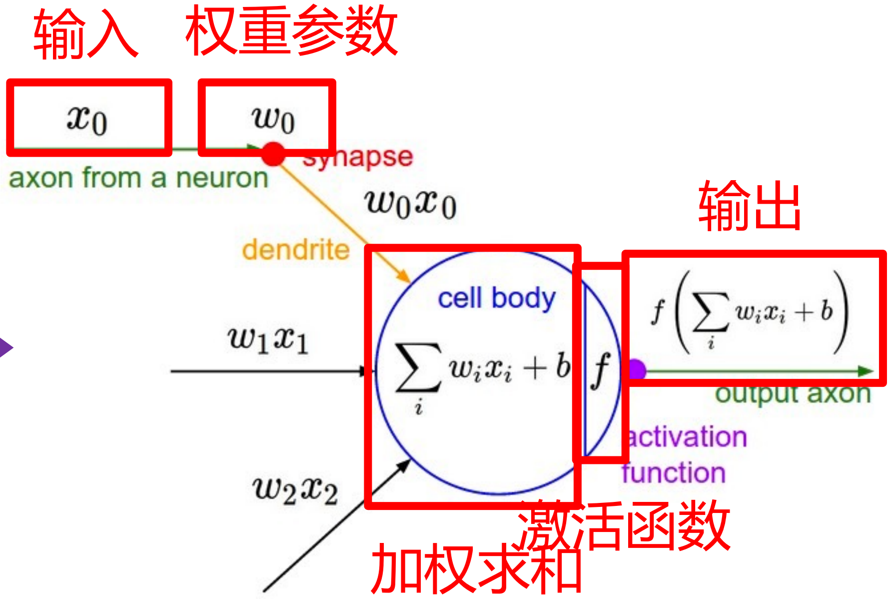

人工神经元

人工神经元

- 为什么需要非线性激活函数？
  - Sigmoid、Tanh、ReLu…

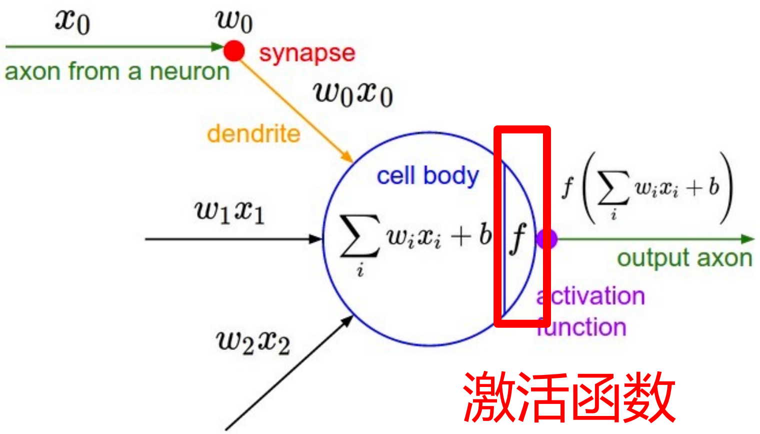

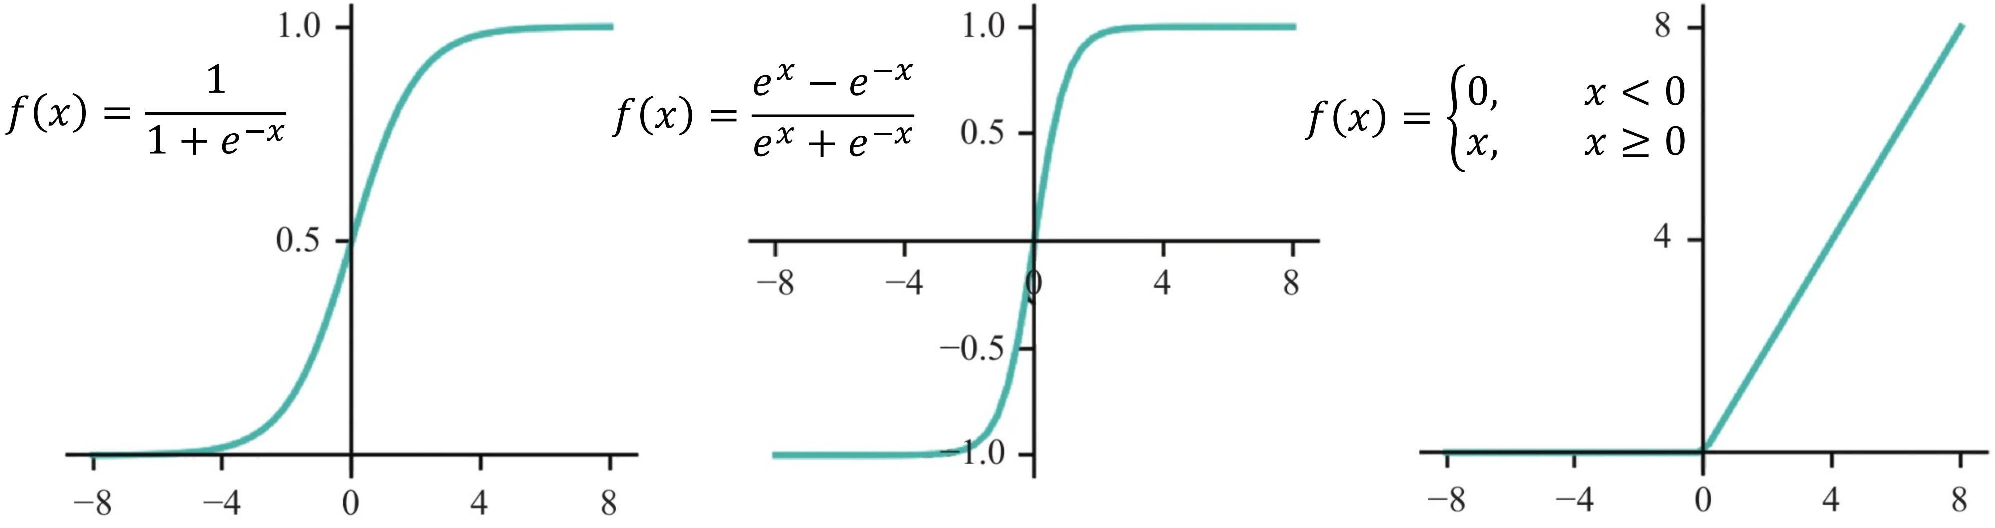

$$f(x) = \frac{1}{1 + e^{-x}}$$

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$f(x) = \begin{cases} 0, & x < 0 \\ x, & x \ge 0 \end{cases}$$

(a) Sigmoid (b) tanh (c) ReLU

人工神经元

- 为什么需要非线性激活函数？
  - 使神经网络具有非线性拟合能力

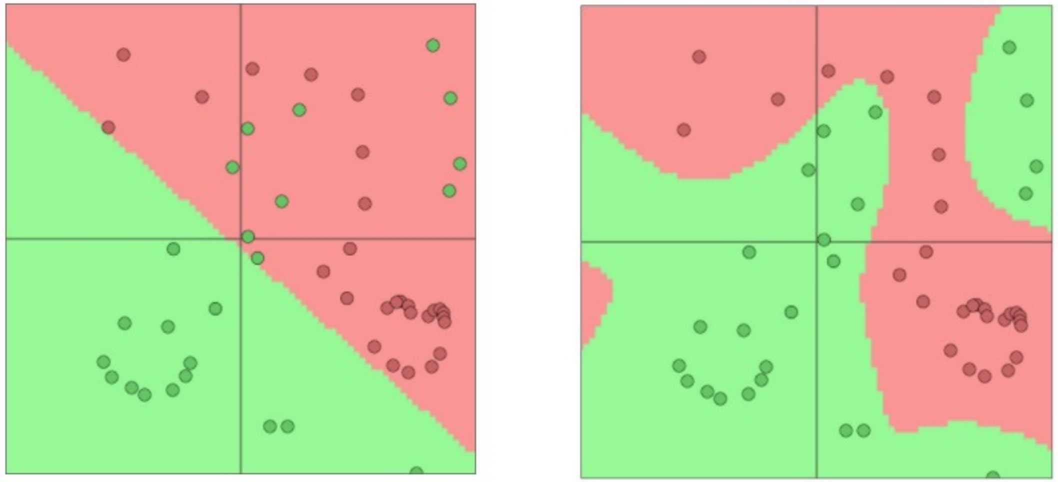

分类

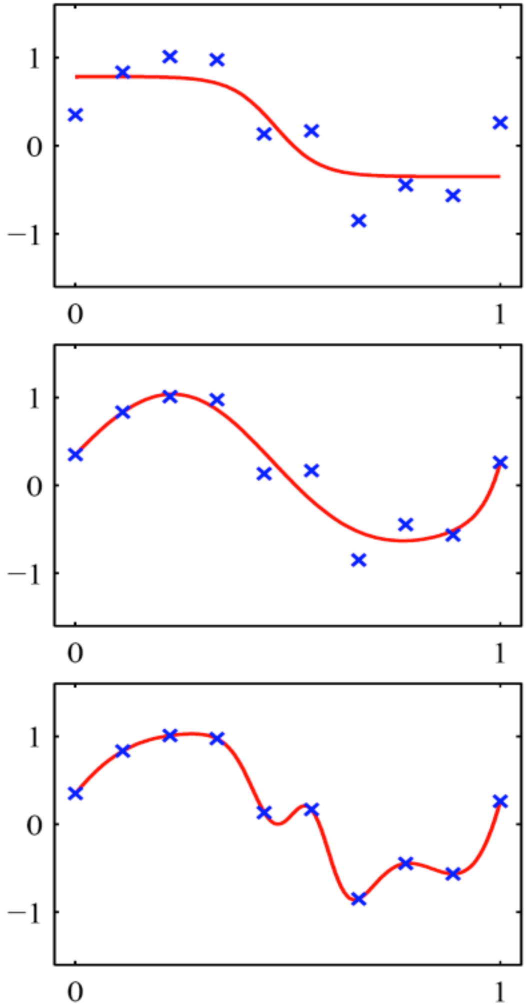

回归

人工神经元

- 为什么需要偏置项？
  - 权重参数W：进行缩放拟合
  - 偏置项b：进行平移拟合

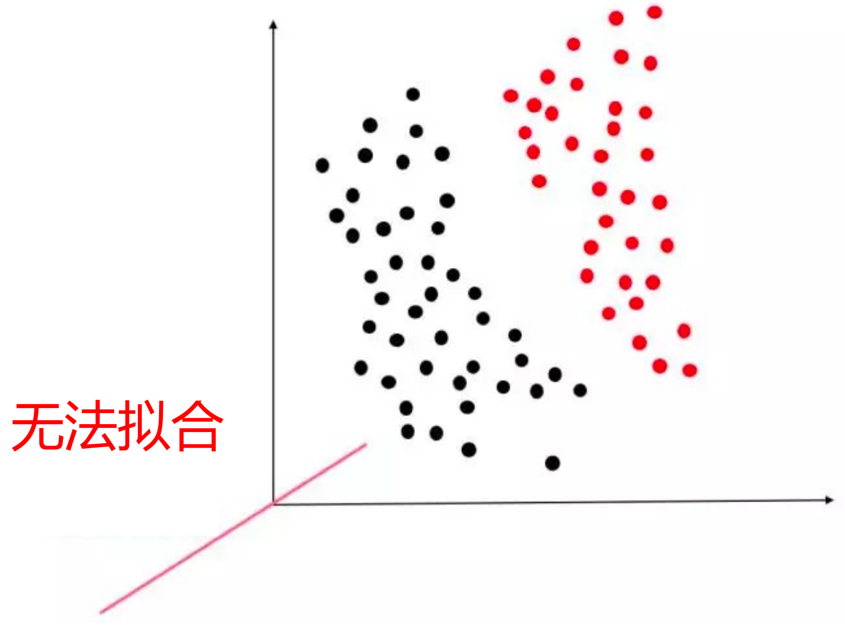

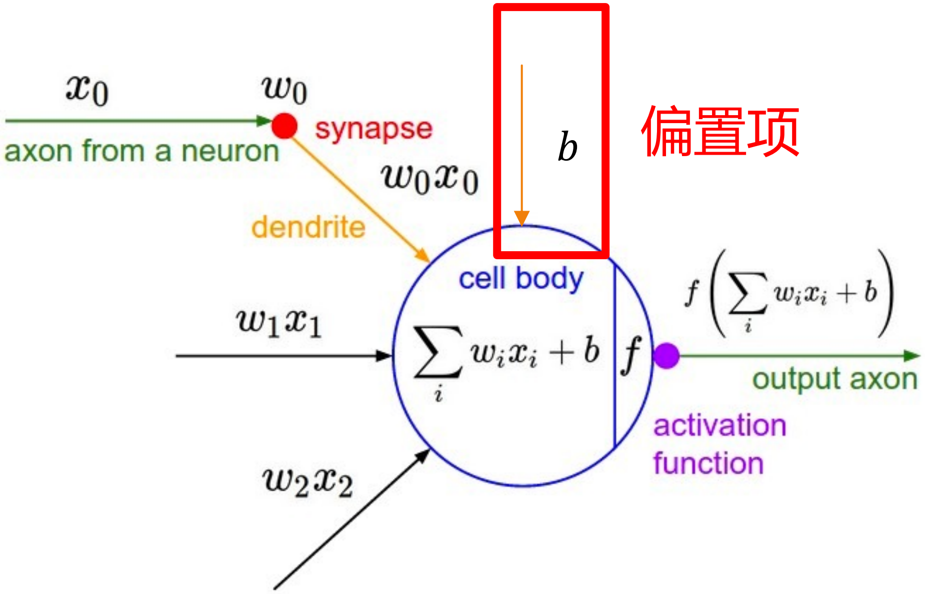

文本分类

- 文本分类（Text Classification）：将文本打上预定义的标签

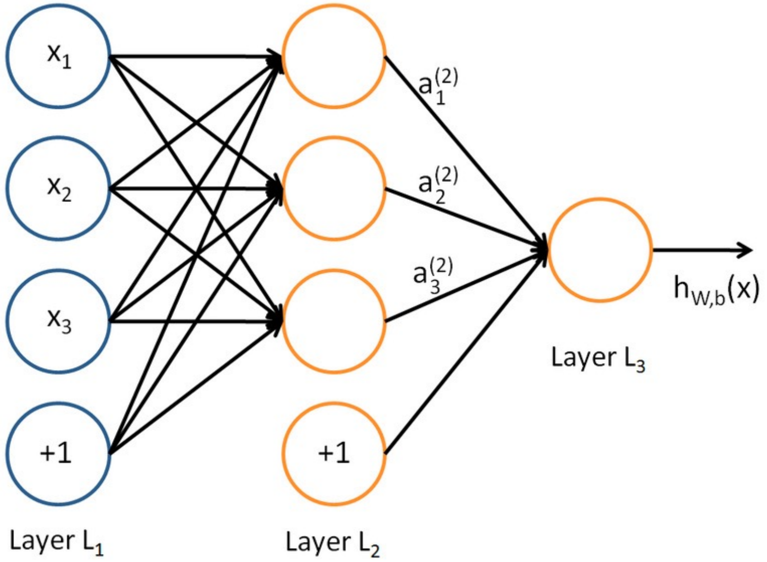

I like this book

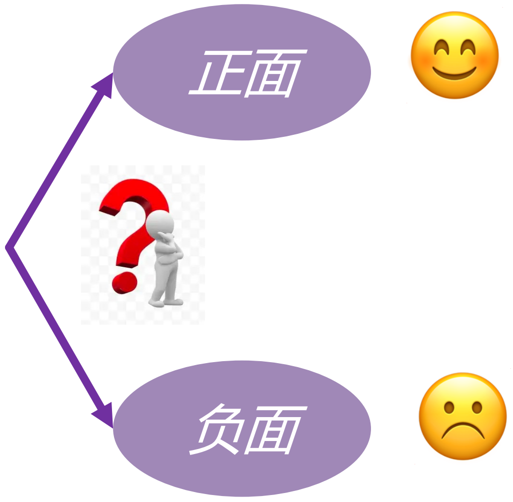

如何利用神经网络构建文本分类模型？

神经网络文本分类模型

损失函数 $$J(\theta) = -y\log\hat{y} + (1-y)\log(1-\hat{y})$$

$$\hat{y} = \frac{1}{1+e^{-s}}$$

$$s = u^T h$$

$$h = f(Wx+b)$$

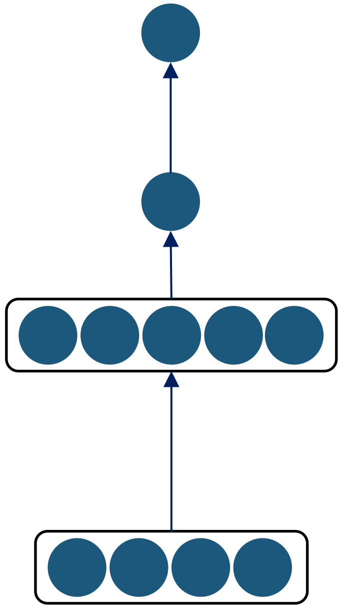

平均池化 $$x = \sum_{i=1}^{n} v_i/n$$

词向量 $v_1, \ldots, v_n$

输入文本 $w_1, \ldots, w_n$

如何训练模型？

- 梯度下降法

$$\theta^{new} = \theta^{old} - \alpha\nabla_\theta J(\theta)$$

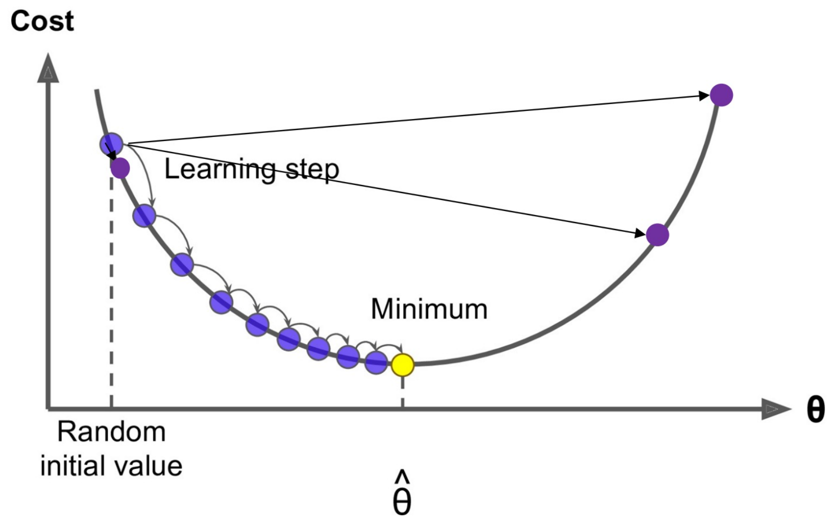

如何计算梯度?

- 链式法则

$$\frac{\partial J}{\partial W} = \frac{\partial J}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial s} \frac{\partial s}{\partial h} \frac{\partial h}{\partial W}$$

损失函数 $J(\theta) = -y \log \hat{y} + (1-y) \log(1-\hat{y})$

$$\hat{y} = \frac{1}{1+e^{-s}}$$

$$s = u^T h$$

$$h = f(Wx + b)$$

平均池化 $x = \sum_{i=1}^{n} v_i / n$

词向量 $v_1, \dots, v_n$

输入文本 $w_1, \dots, w_n$

反向传播算法

- 目前训练人工神经网络最常用且有效的算法
  - 前向传播（Forward Propagation）：将训练集数据输入到网络的输入层，经过隐藏层，最后达到输出层并输出结果；
  - 反向传播（Back Propagation）：计算预测值与实际值之间的误差，并将该误差（梯度）从输出层向隐藏层反向传播，直至传播到输入层，并更新参数；
  - 迭代上述过程，直至网络收敛。

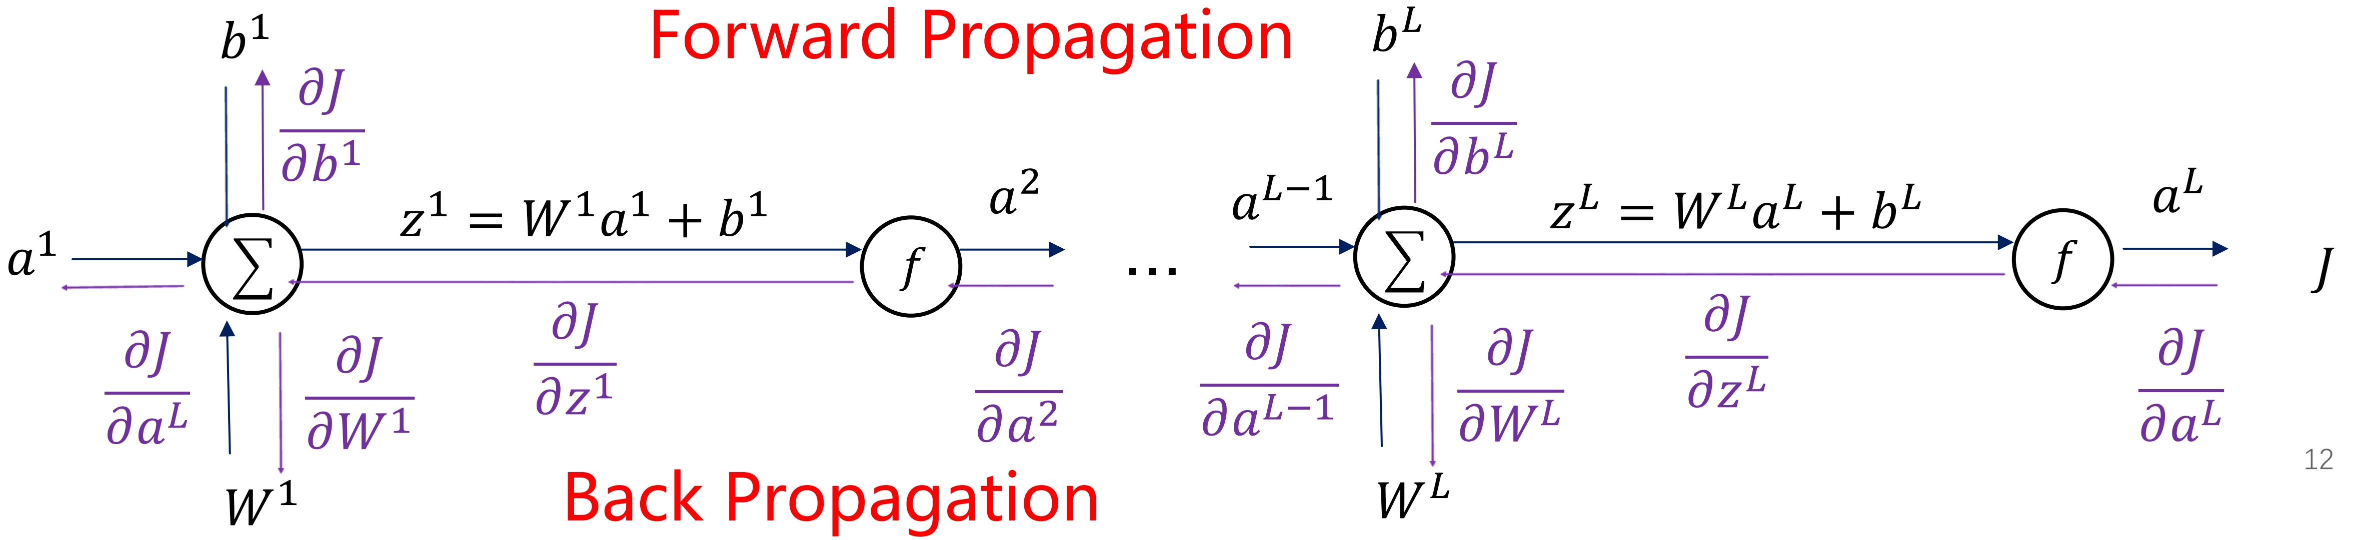

反向传播算法流程

- 变量定义
  - w_{jk}^{l} ：第$l-1$层的第k个神经元连接到第l层的第j个神经元的权重
  - b_j^l：第l层第j个神经元的偏置项
  - z_j^l：第l层第j个神经元的输入，即$z_j^l = \sum_k w_{jk}^l a_k^{l-1} + b_j^l$
  - a_j^l：第l层第j个神经元的输出，即$a_j^l = f\left(z_j^l\right) = f(\sum_k w_{jk}^l a_k^{l-1} + b_j^l)$

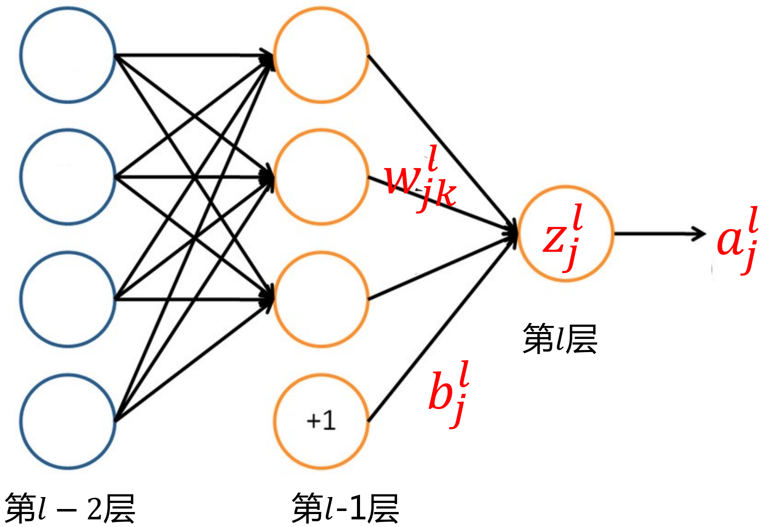

第l层第j个神经元产生的错误（实际值和预测值之间的误差）定义如下：

$$\delta_j^l \equiv \frac{\partial J}{\partial z_j^l}$$

反向传播算法流程

- 计算最后一层神经网络产生的误差δ^L：

$$\delta_j^L = \frac{\partial J}{\partial z_j^L} = \frac{\partial J}{\partial a_j^L}\frac{\partial a_j^L}{\partial z_j^L} = \frac{\partial J}{\partial a_j^L} f'(z_j^L)$$

$$a_j^l = f(z_j^l)$$

$$\delta^L = \nabla_{a^L} J \odot f'(z^L)$$

反向传播算法流程

NANJING UNIVERSITY

- 由后往前，计算每一层神经网络产生的误差δ^l：

$$\delta_j^l = \frac{\partial J}{\partial z_j^l} = \sum_k \frac{\partial J}{\partial z_k^{l+1}} \cdot \frac{\partial z_k^{l+1}}{\partial a_j^l} \cdot \frac{\partial a_j^l}{\partial z_j^l}$$

$$= \sum_k \delta_k^{l+1} \cdot \frac{\partial (w_{kj}^{l+1} a_j^l + b_k^{l+1})}{\partial a_j^l} \cdot f'(z_j^l)$$

$$= \sum_k \delta_k^{l+1} \cdot w_{kj}^{l+1} \cdot f'(z_j^l)$$

$$z_j^l = \sum_k w_{jk}^l a_k^{l-1} + b_j^l$$

$$a_j^l = f(z_j^l)$$

$$\delta^l = ((w^{l+1})^T \delta^{l+1}) \odot f'(z^l)$$

反向传播算法流程

- 计算权重的梯度$\frac{\partial J}{\partial w_{jk}^l}$：

$$\frac{\partial J}{\partial w_{jk}^l} = \frac{\partial J}{\partial z_j^l}\frac{\partial z_j^l}{\partial w_{jk}^l}$$

$$= \delta_j^l \frac{\partial f(w_{jk}^l a_k^{l-1} + b_j^l)}{\partial w_{jk}^l}$$

$$= a_k^{l-1}\delta_j^l$$

$$z_j^l = \sum_k w_{jk}^l a_k^{l-1} + b_j^l$$

反向传播算法流程

NANJING UNIVERSITY

- 计算偏置项的梯度$\frac{\partial J}{\partial b_j^l}$：

$$\frac{\partial J}{\partial b_j^l} = \frac{\partial J}{\partial z_j^l}\frac{\partial z_j^l}{\partial b_j^l}$$

$$= \delta_j^l \frac{\partial f(w_{jk}^l a_k^{l-1} + b_j^l)}{\partial b_j^l}$$

$$= \delta_j^l$$

利用反向传播算法训练网络

- 前向传播：

$$z^l = w^l a^{l-1} + b^l$$

$$a^l = f(z^l)$$

- 计算输出层的误差：

$$\delta^L = \nabla_{a^L} J \odot f'(z^L)$$

- 反向传播误差：

$$\delta^l = ((w^{l+1})^T \delta^{l+1}) \odot f'(z^l)$$

- 梯度下降，更新参数：

$$w^l \leftarrow w^l - \alpha \cdot \boxed{\delta^l (a^{l-1})^T}$$

$$b^l \leftarrow b^l - \alpha \cdot \boxed{\delta^l}$$

NANJING UNIVERSITY

02 循环神经网络和语言模型

RECURRENT NEURAL NETWORK AND LANGUAGE MODEL

语言模型

- 语言模型（Language Model，LM）：衡量一句话出现概率的模型

The students opened their ____

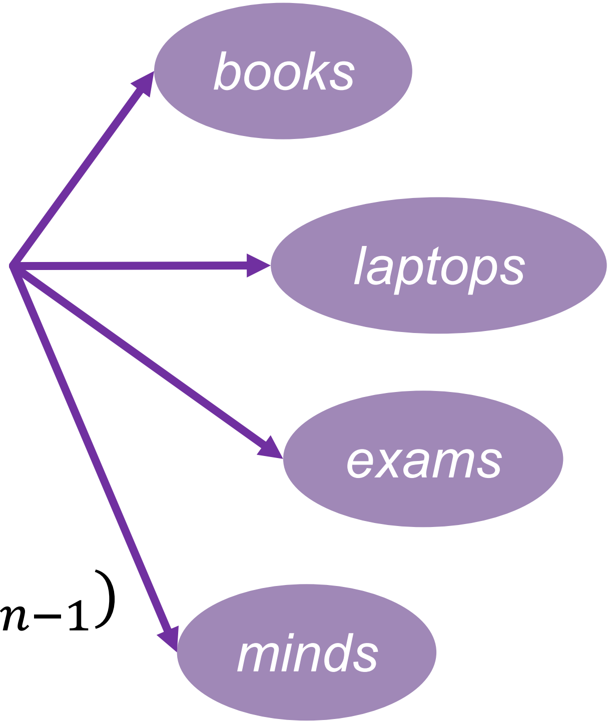

$$
\begin{aligned}
P(s) &= P(w_1, \ldots, w_n) \\
&= P(w_1) \times P(w_2 | w_1) \times \cdots \times P(w_n | w_1, \ldots, w_{n-1}) \\
&= \prod_{i=1}^{n} \boxed{P(w_i | w_1, \ldots, w_{i-1})}
\end{aligned}
$$

统计语言模型

- 马尔可夫假设：当前词出现的概率只和它前面的k个词相关

$$P(w_i|w_1,\dots,w_{i-1}) = P(w_i|\boxed{w_{i-k},\dots,w_{i-1}})$$

- 缺点：
  - N-gram模型的稀疏性问题
  - N-gram模型的存储问题

基于4-GRAM的神经网络语言模型

预测概率： $\hat{y} = \text{sofmax}(Uh + b_2) \in \mathbb{R}^{|V|}$

隐层表示： $h = f(We + b_1)$

拼接词向量： $e = [e_1, e_2, e_3, e_4]$

输入单词序列： x_1, x_2, x_3, x_4

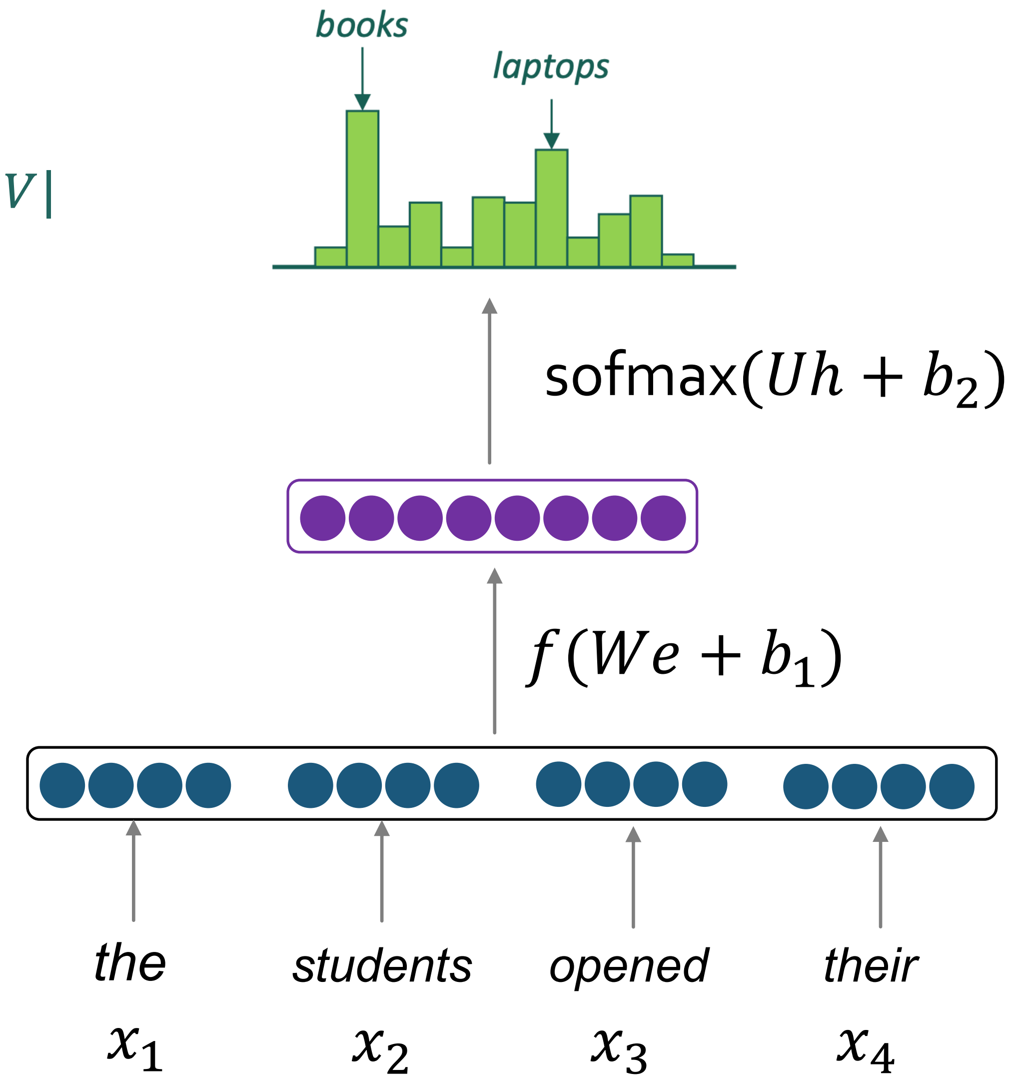

基于N-GRAM的神经网络语言模型

- 优点
  - 不会有稀疏性问题
  - 不需要存储所有的n-grams
- 不足
  - 视野有限，无法建模长距离语义
  - 窗口越大，参数规模越大

能否构建处理任意长度的神经网络模型？

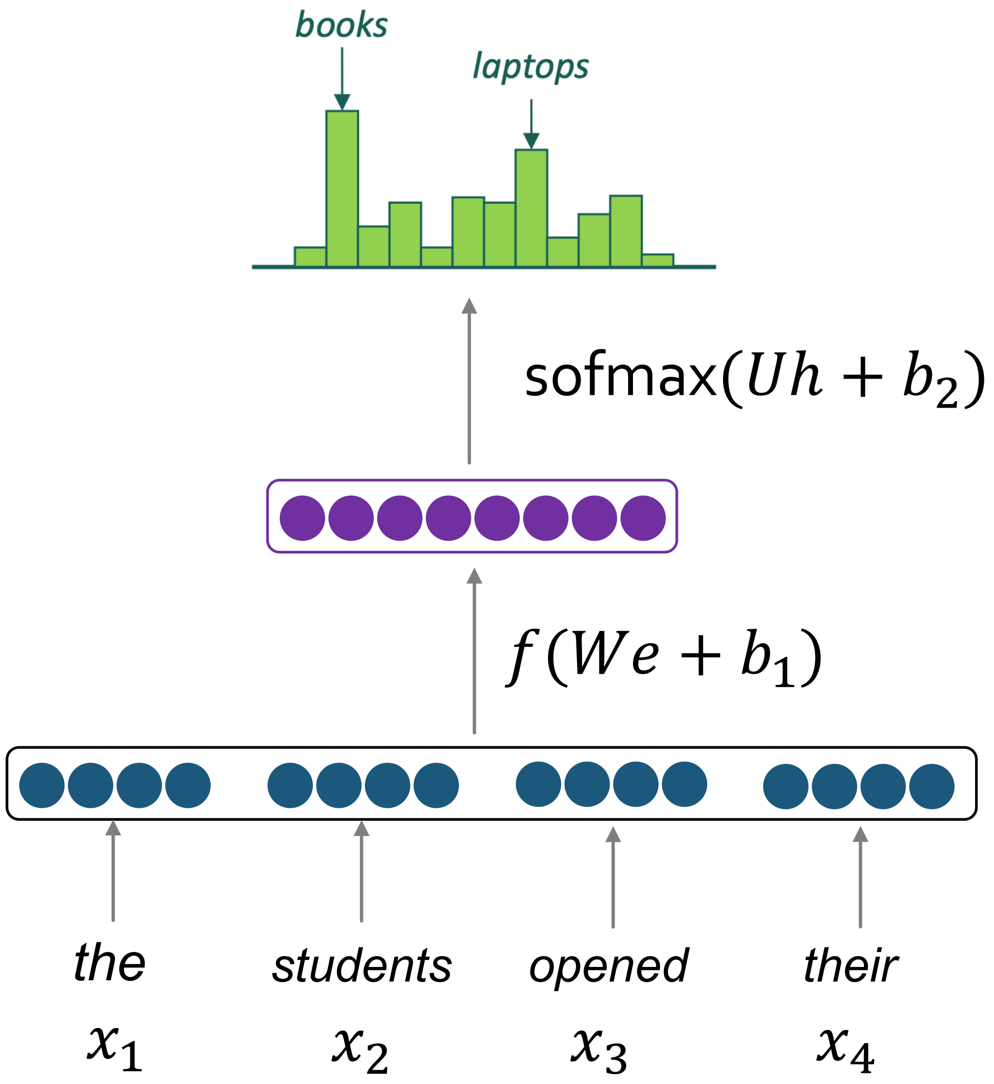

循环神经网络

- 循环神经网络（Recurrent Neural Network，RNN）
  - 重复使用隐层参数
  - 可处理任意序列长度

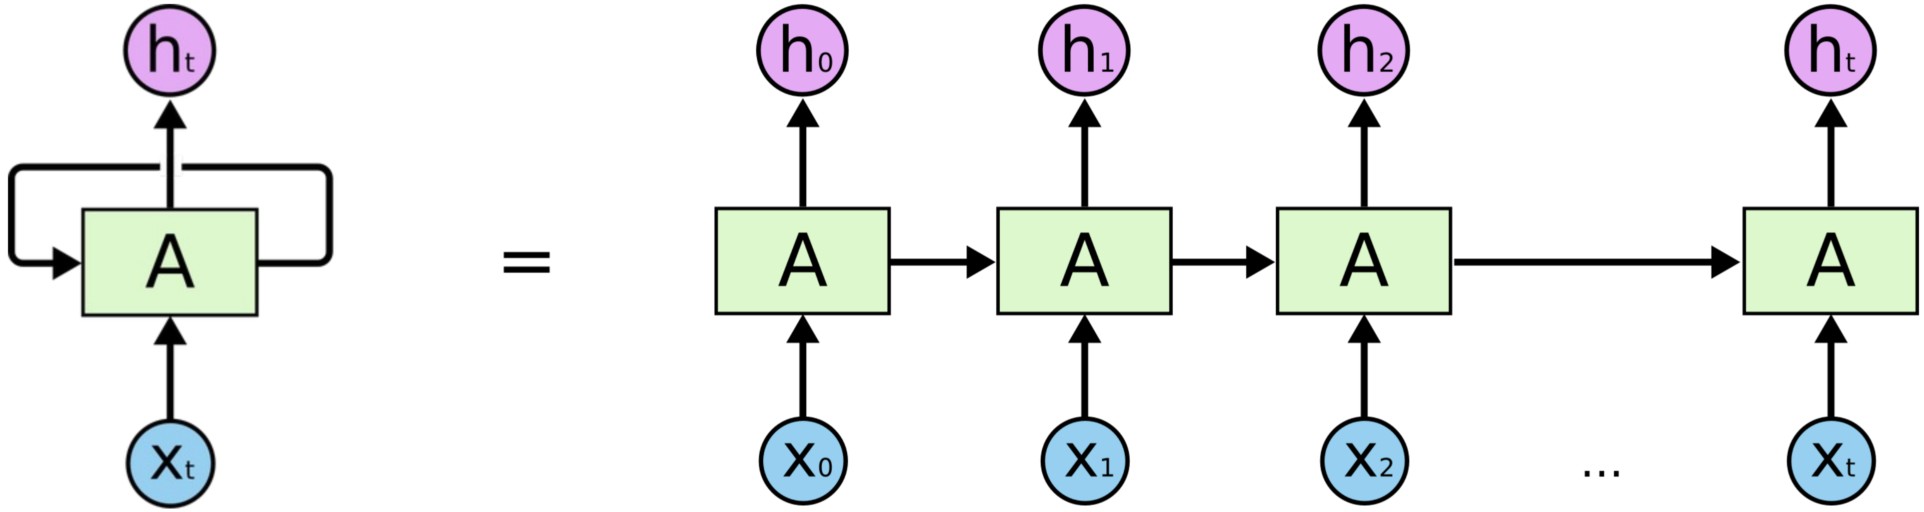

$$h_t = f(W_h h_{t-1} + W_x x_t + b)$$

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

循环神经网络语言模型

预测概率： $\hat{y} = \mathrm{sofmax}(Uh + b_2) \in \mathbb{R}^{|V|}$

隐层表示： $h_t = f(W_h h_{t-1} + W_x e_t + b)$

输入词向量序列：e_1, e_2, e_3, e_4

输入单词序列： x_1, x_2, x_3, x_4

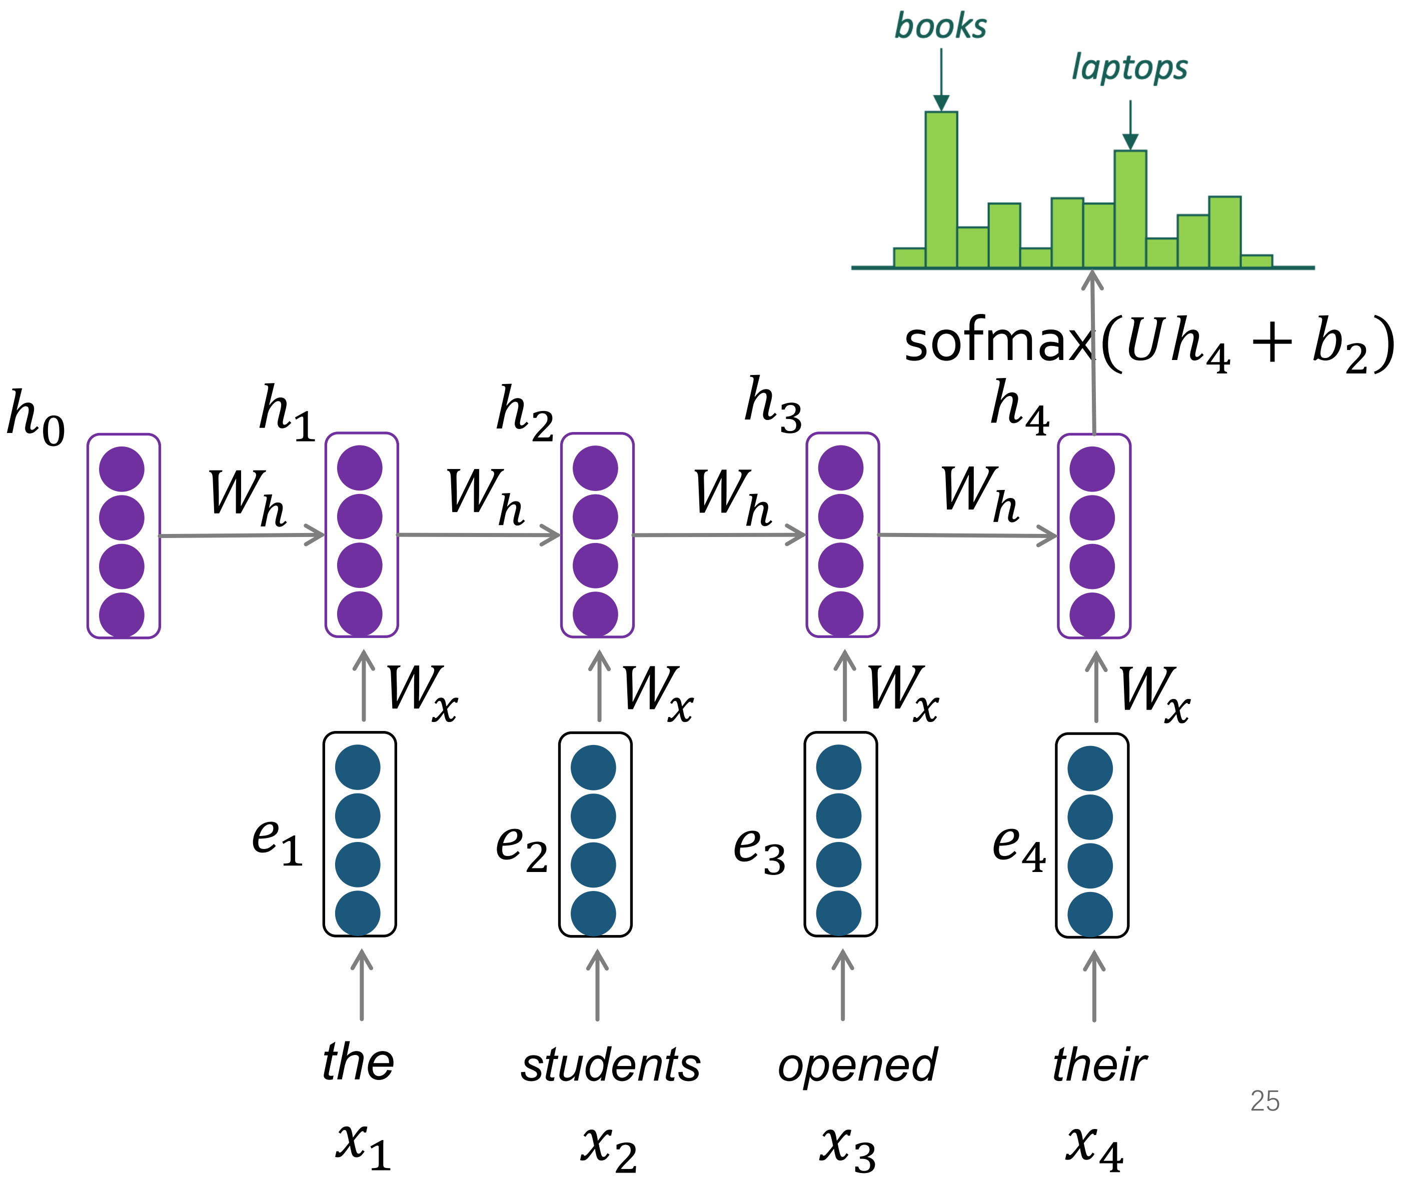

循环神经网络语言模型

- 优点
  - 能够处理任意长度序列
  - 能够使用历史信息
  - 模型参数量不随序列长度增加
- 不足
  - 逐步计算，速度较慢
  - 长期依赖问题

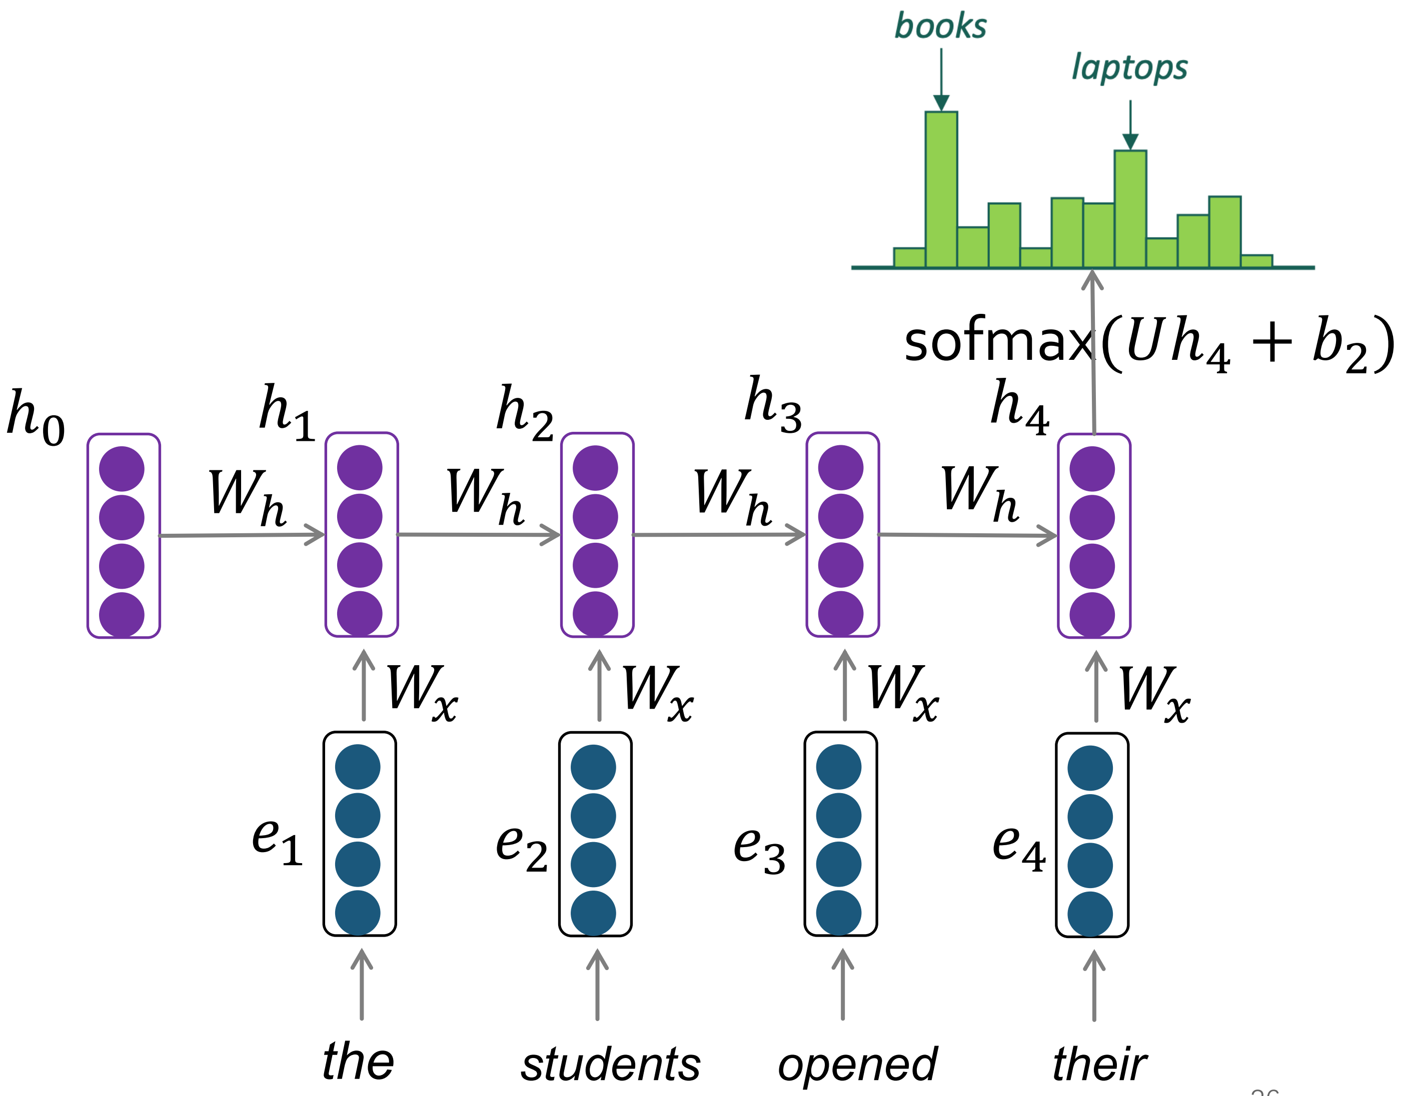

RNN-LM模型训练

- 给定长度为T的输入文本：$x_1, \cdots, x_T$；
- 将文本输入到RNN-LM，计算每一步预测的单词分布$\hat{y}^t$；
- 计算每一步预测单词的概率分布$\hat{y}^t$和真实单词y^t（one-hot向量）之间的交叉熵：

$$J^t(\theta) = \mathrm{CE}(y^t, \hat{y}^t) = -\sum_{w \in V} y_w^t \log \hat{y}_w^t = -\log \hat{y}_{x_{t+1}}^t$$

- 模型在输入文本上的训练损失为：

$$J(\theta) = \frac{1}{T}\sum_{t=1}^{T} J^t(\theta) = \frac{1}{T}\sum_{t=1}^{T} -\log \hat{y}_{x_{t+1}}^t$$

RNN-LM模型训练

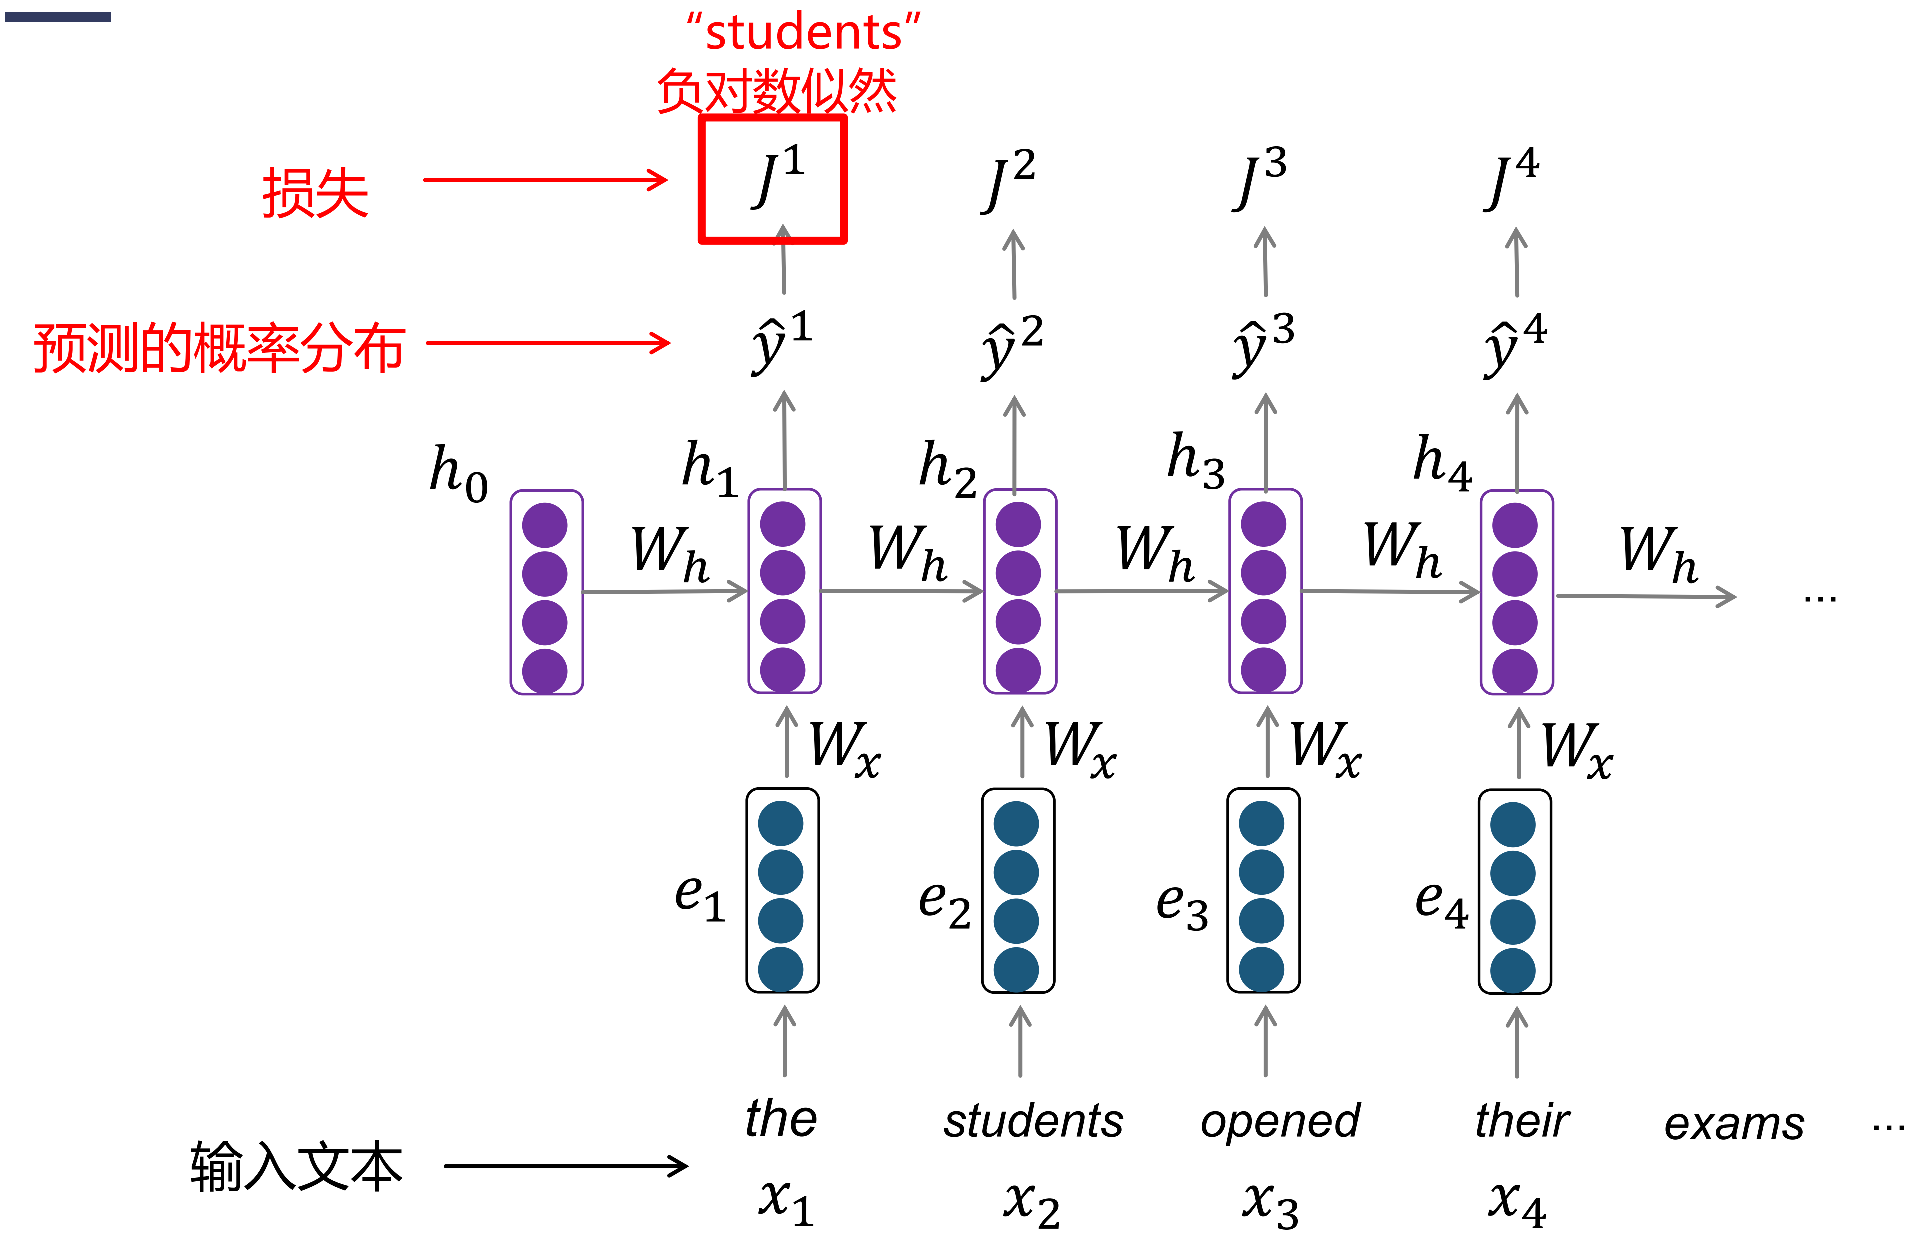

"students"
负对数似然
损失
J^1
J^2
J^3
J^4
预测的概率分布
$\hat{y}^1$
$\hat{y}^2$
$\hat{y}^3$
$\hat{y}^4$
h_0
h_1
h_2
h_3
h_4
W_h
…
W_x
e_1
e_2
e_3
e_4
输入文本
the
students
opened
their
exams
…
x_1
x_2
x_3
x_4

RNN-LM模型训练

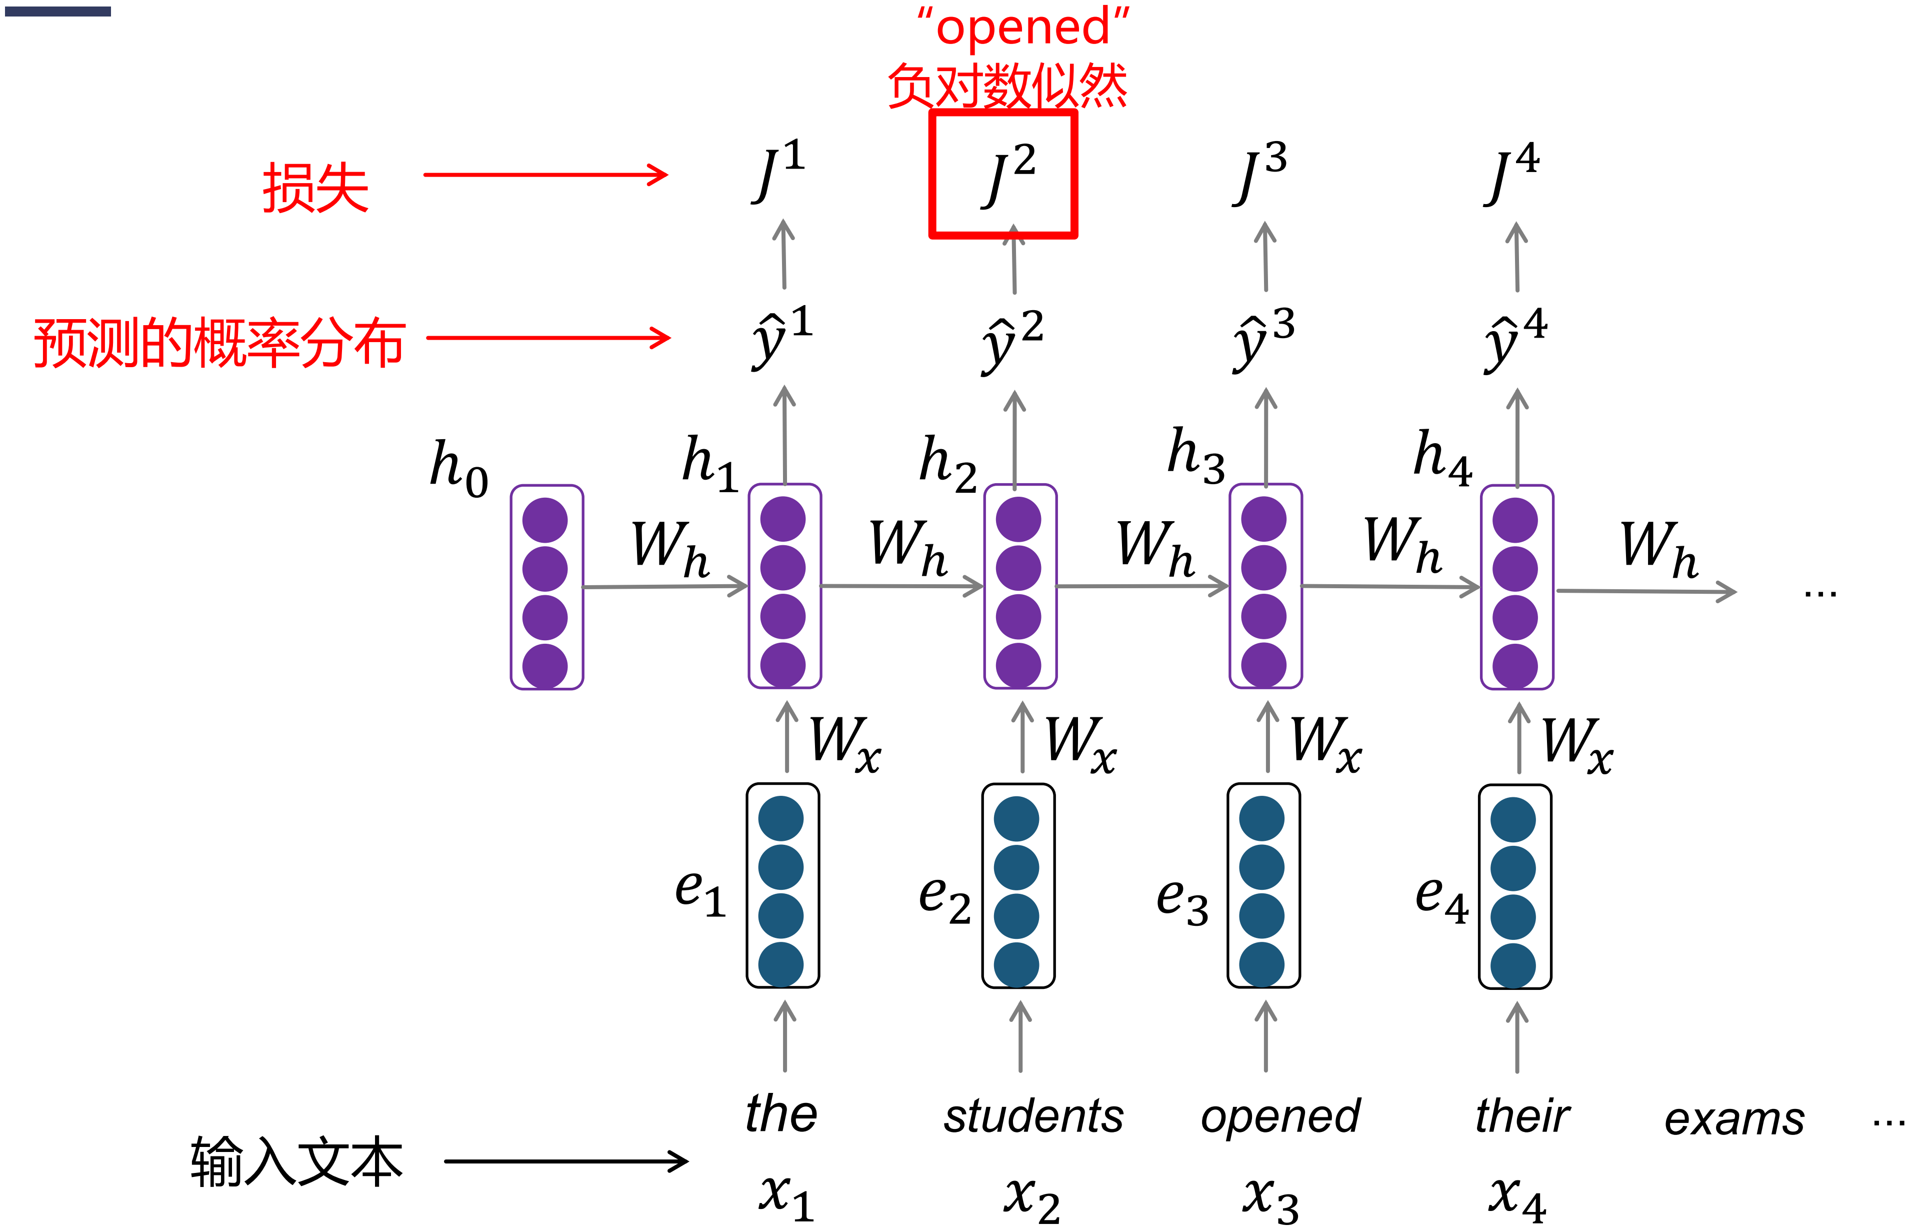
"opened"
负对数似然
损失
J^1 J^2 J^3 J^4
预测的概率分布
$\hat{y}^1$ $\hat{y}^2$ $\hat{y}^3$ $\hat{y}^4$
h_0 h_1 h_2 h_3 h_4
W_h
W_x
e_1 e_2 e_3 e_4
…
输入文本
the students opened their exams …
x_1 x_2 x_3 x_4

RNN-LM模型训练

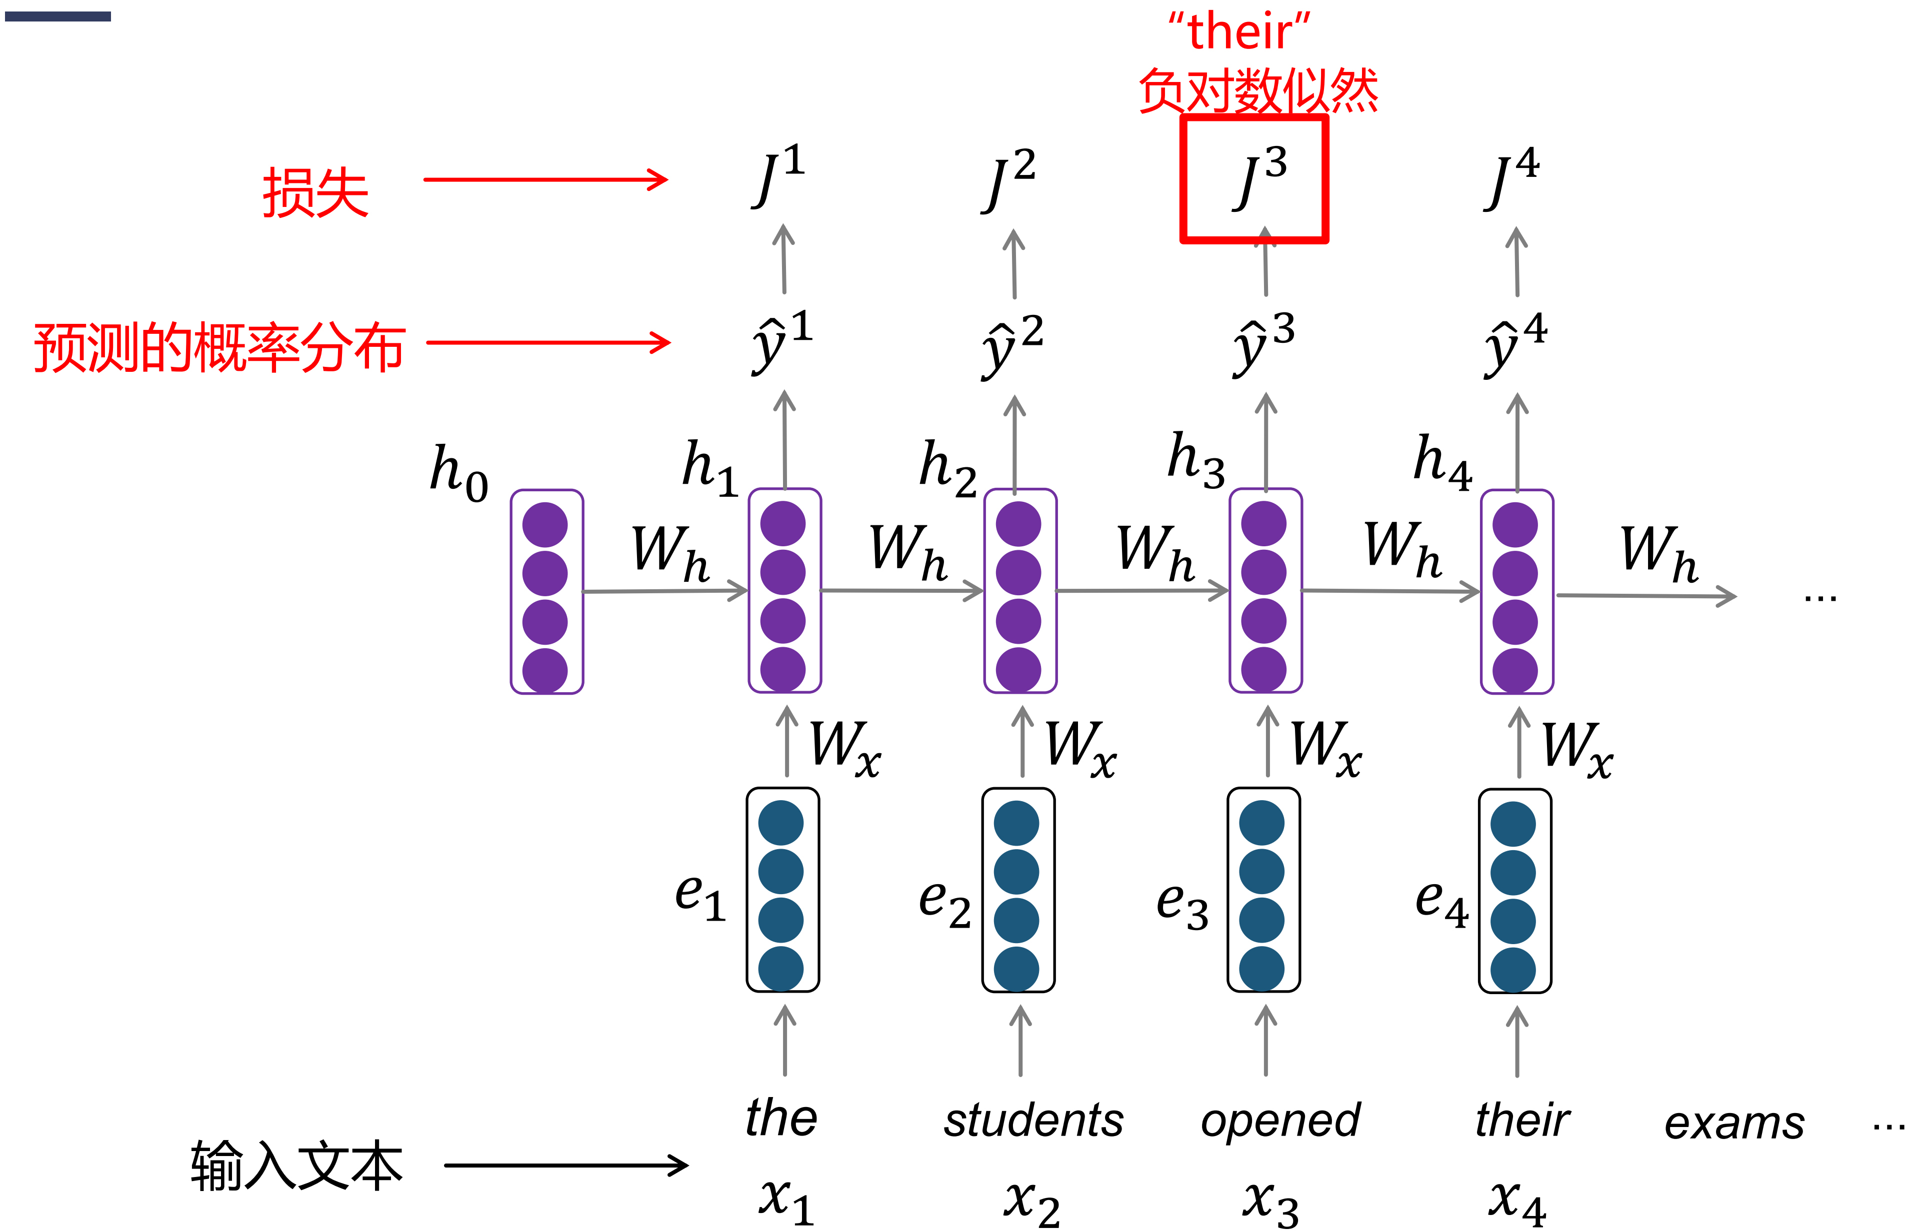

"their"
负对数似然
损失
J^1 J^2 J^3 J^4
预测的概率分布
$\hat{y}^1$ $\hat{y}^2$ $\hat{y}^3$ $\hat{y}^4$
h_0 h_1 h_2 h_3 h_4
W_h
W_x
e_1 e_2 e_3 e_4
…
输入文本
the students opened their exams …
x_1 x_2 x_3 x_4

RNN-LM模型训练

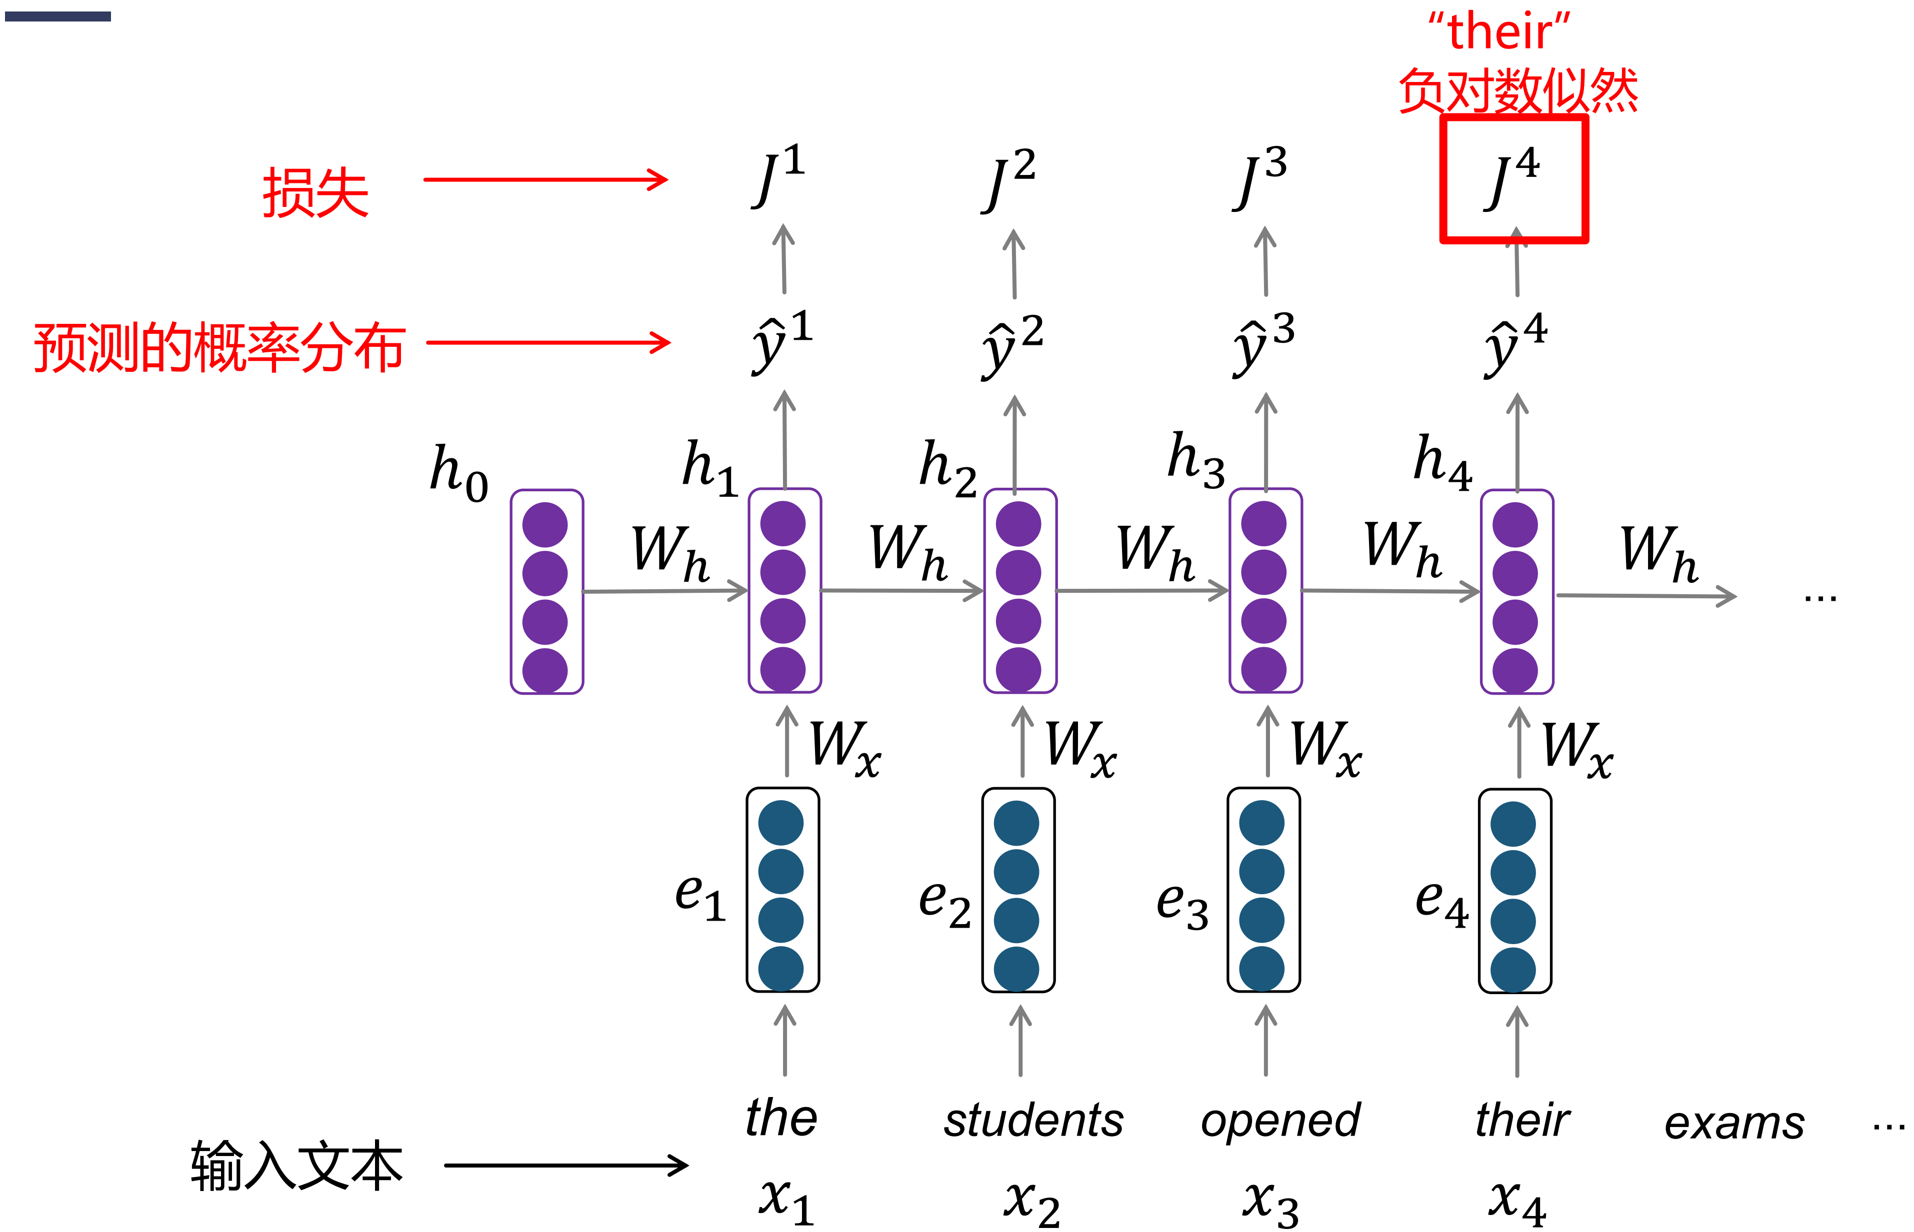

"their"
负对数似然
损失
J^1 J^2 J^3 J^4
预测的概率分布
$\hat{y}^1$ $\hat{y}^2$ $\hat{y}^3$ $\hat{y}^4$
h_0 h_1 h_2 h_3 h_4
W_h
…
W_x
e_1 e_2 e_3 e_4
输入文本
the students opened their exams …
x_1 x_2 x_3 x_4

RNN-LM模型训练

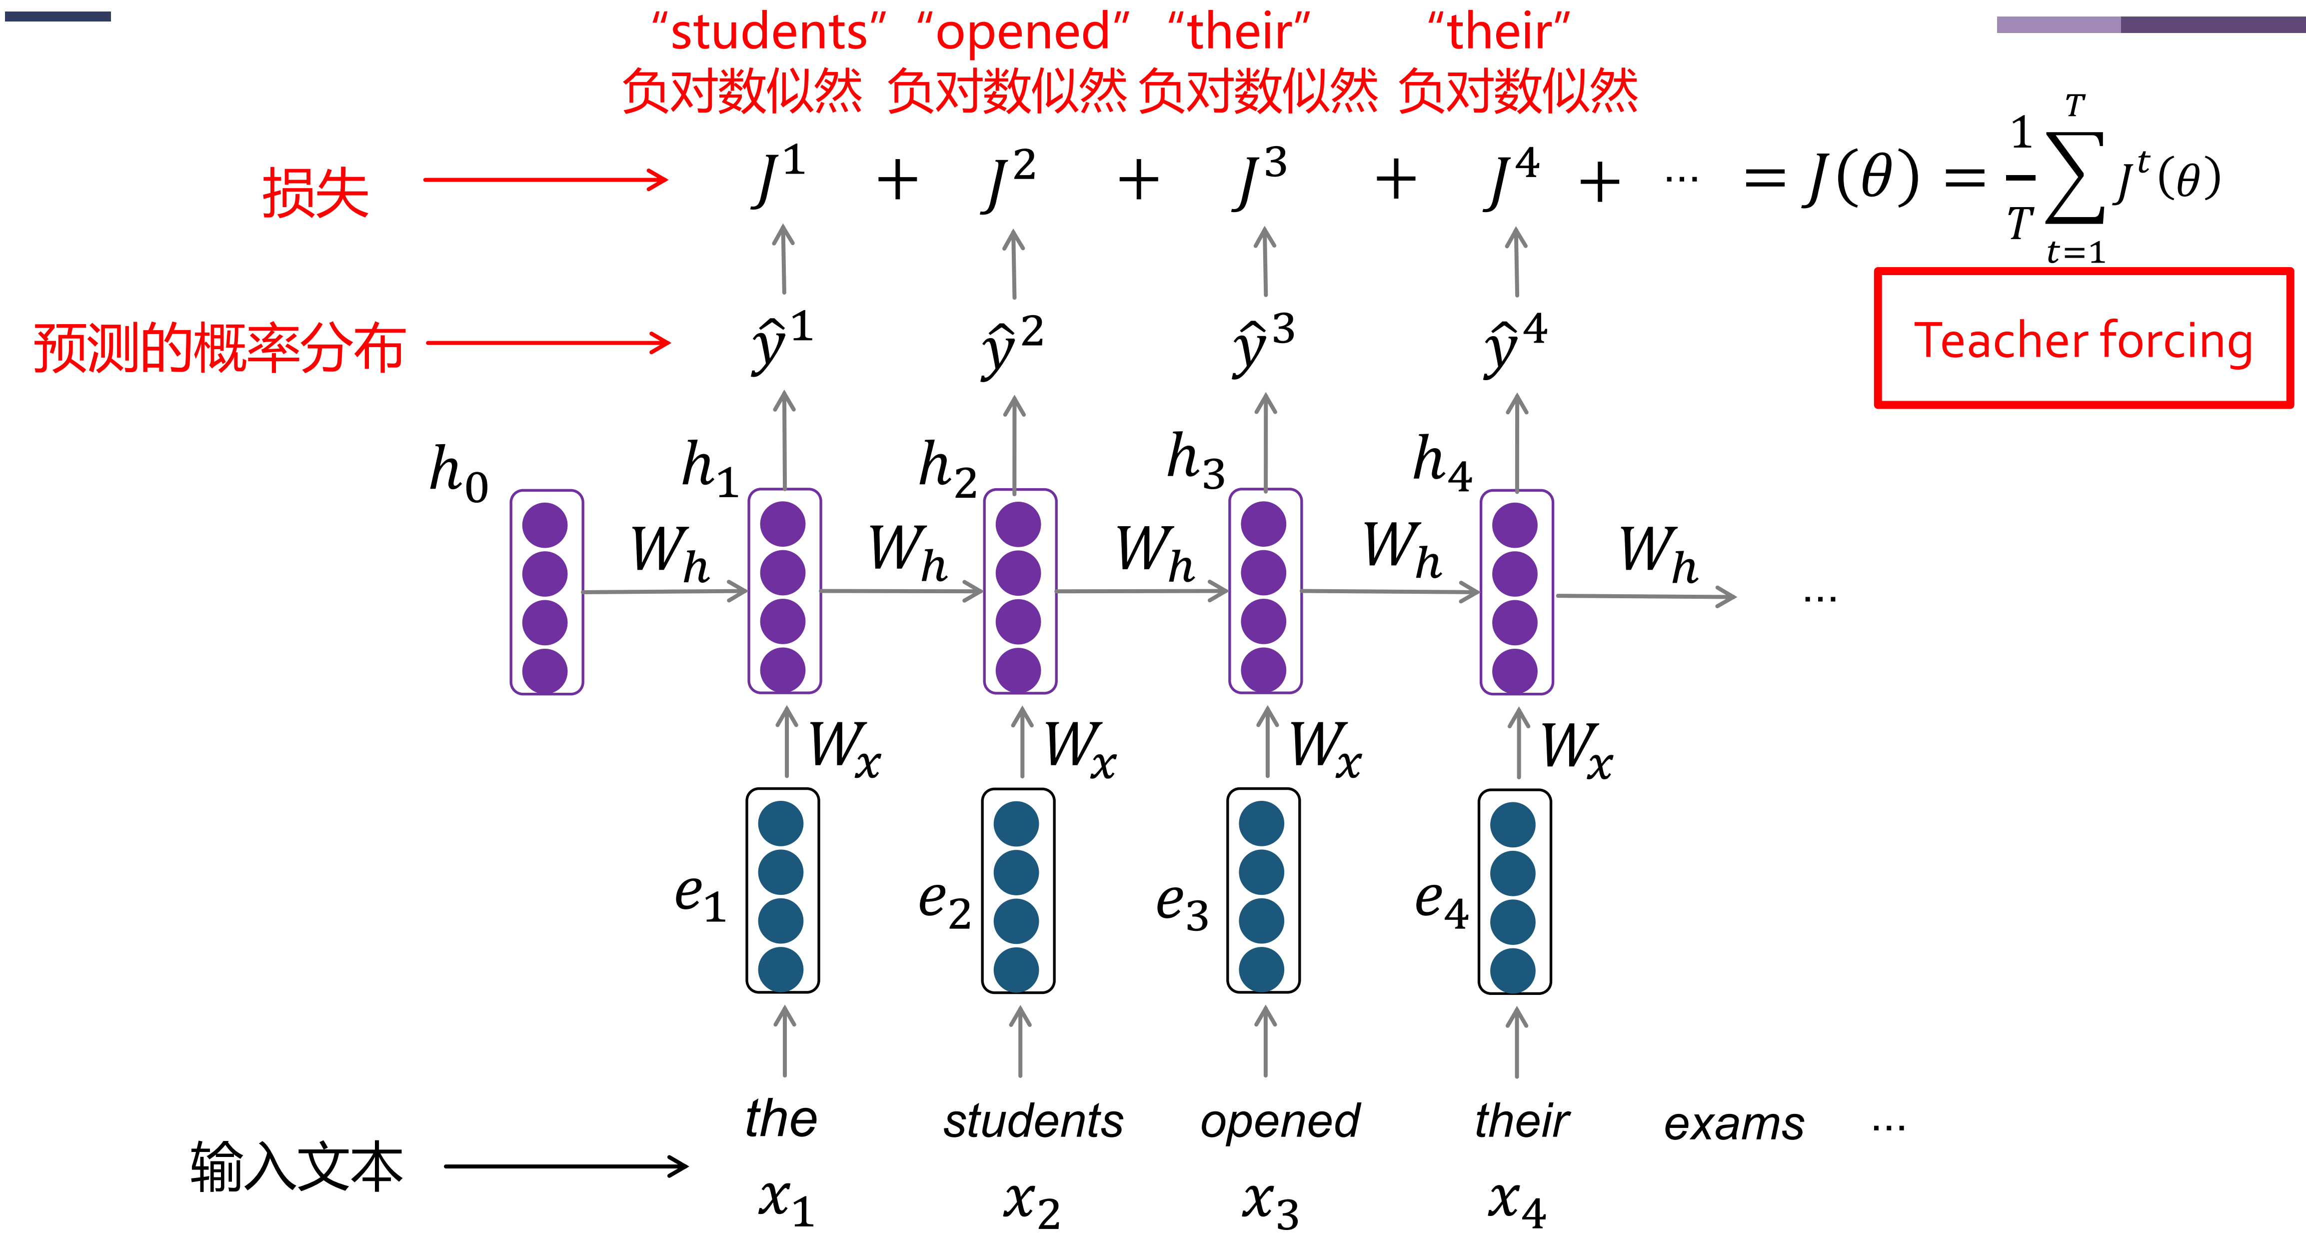
"students" "opened" "their" "their"
负对数似然 负对数似然 负对数似然 负对数似然
损失
$J^1 + J^2 + J^3 + J^4 + \cdots = J(\theta) = \frac{1}{T}\sum_{t=1}^{T} J^t(\theta)$
Teacher forcing
预测的概率分布
$\hat{y}^1$ $\hat{y}^2$ $\hat{y}^3$ $\hat{y}^4$
h_0 h_1 h_2 h_3 h_4
W_h
W_x
e_1 e_2 e_3 e_4
输入文本
the students opened their exams …
x_1 x_2 x_3 x_4

RNN：梯度爆炸、梯度消失

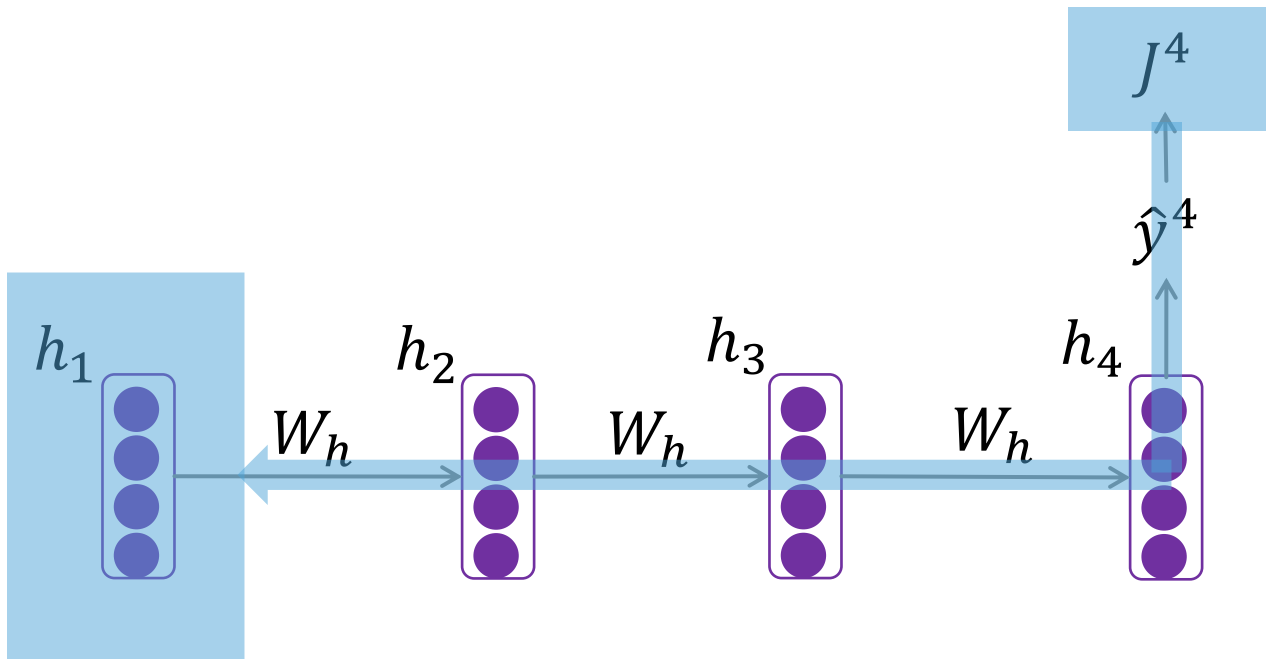

$$\frac{\partial J^4}{\partial h^1}$$

RNN：梯度爆炸、梯度消失

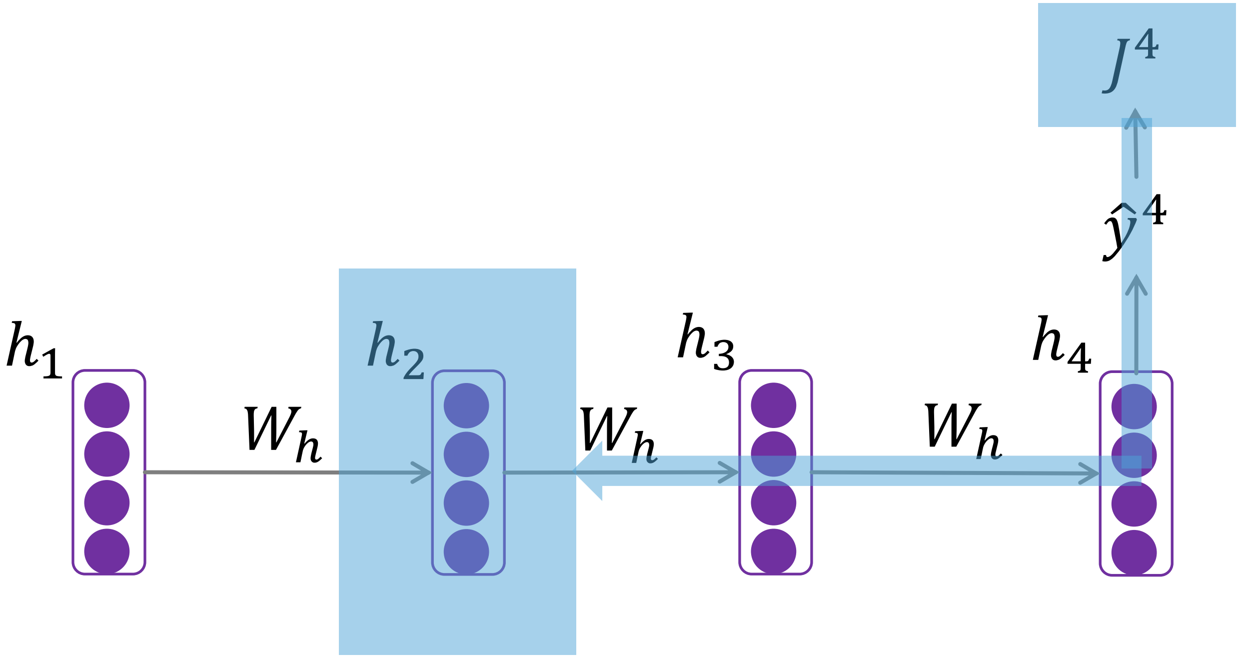

$$\frac{\partial J^4}{\partial h^1} = \frac{\partial h^2}{\partial h^1} \times \frac{\partial J^4}{\partial h^2}$$

RNN：梯度爆炸、梯度消失

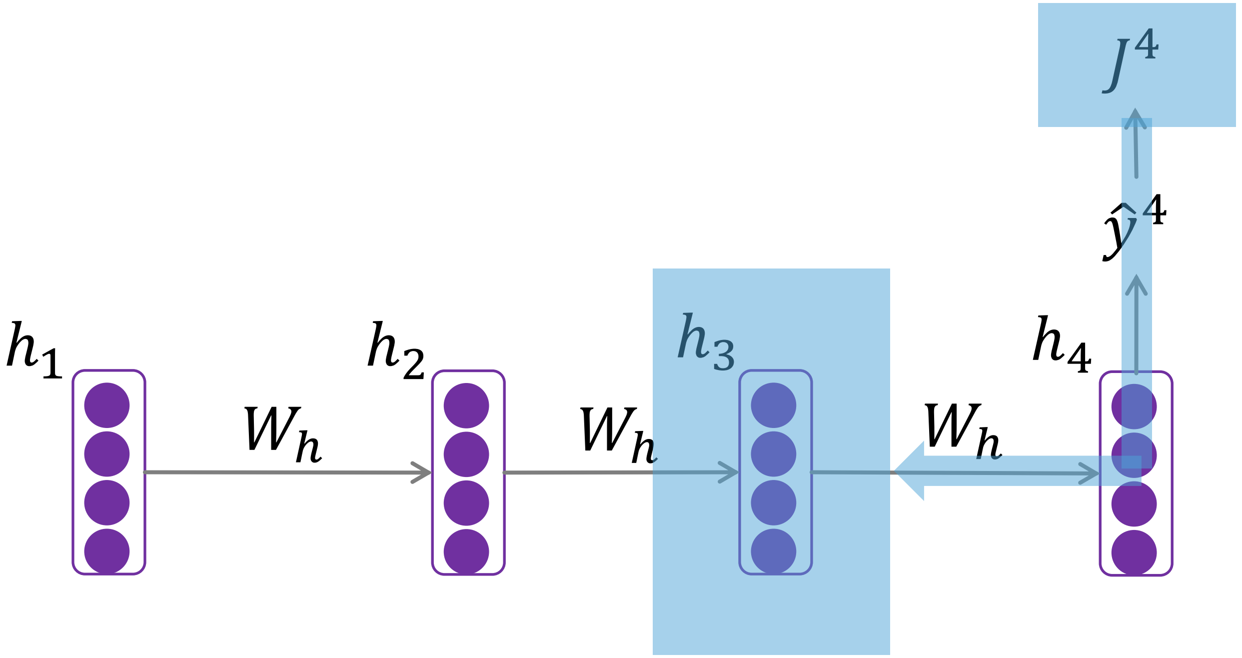

$$\frac{\partial J^4}{\partial h^1} = \frac{\partial h^2}{\partial h^1} \times \frac{\partial h^3}{\partial h^2} \times \frac{\partial J^4}{\partial h^3}$$

RNN：梯度爆炸、梯度消失

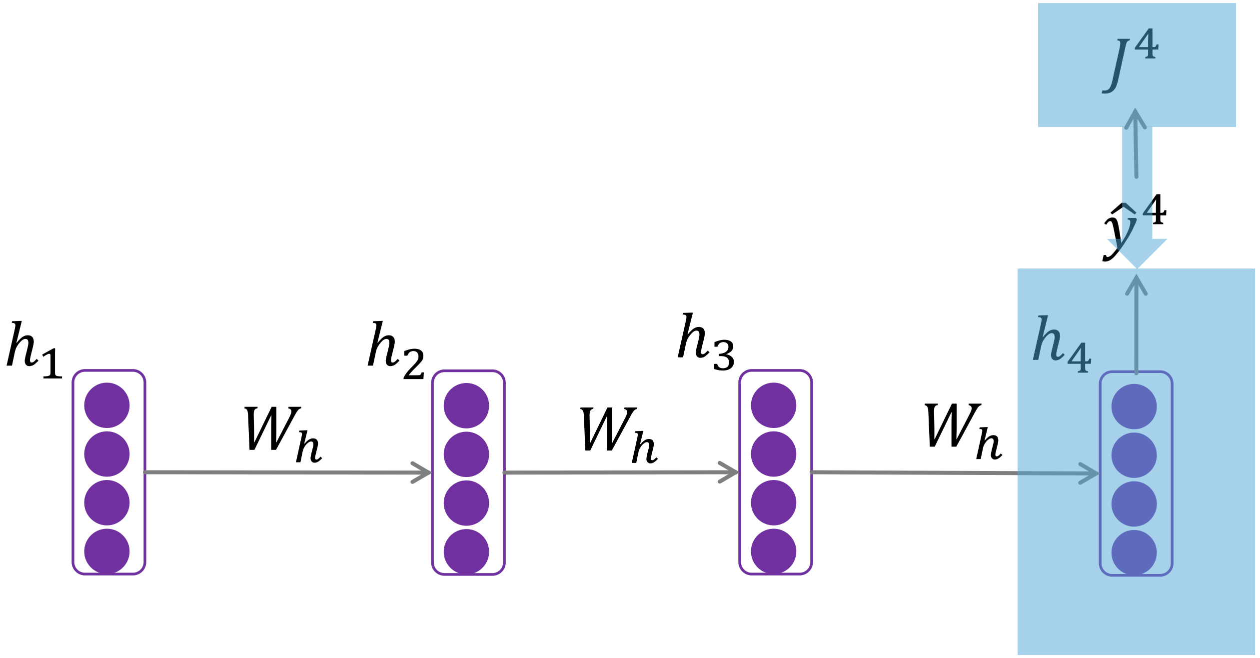

$$\frac{\partial J^4}{\partial h^1} = \frac{\partial h^2}{\partial h^1} \times \frac{\partial h^3}{\partial h^2} \times \frac{\partial h^4}{\partial h^3} \times \frac{\partial J^4}{\partial h^4}$$

RNN：梯度爆炸、梯度消失

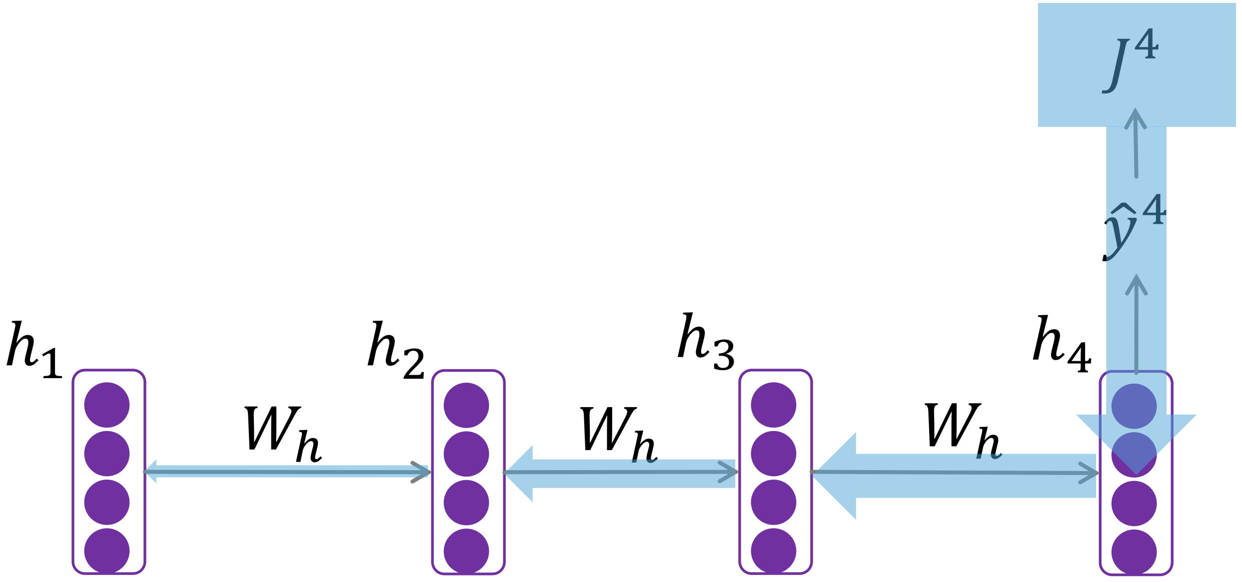

$$\frac{\partial J^4}{\partial h^1} = \frac{\partial h^2}{\partial h^1} \times \frac{\partial h^3}{\partial h^2} \times \frac{\partial h^4}{\partial h^3} \times \frac{\partial J^4}{\partial h^4}$$

如果这些梯度很大或者很小怎么办？

03

高级循环神经网络

ADVANCED RNN

长短期记忆网络

- 长短期记忆网络（ Long Short-Term Memory，LSTM ）：引入三个门和一个细胞状态来控制神经元的信息流动
  - 遗忘门f_t ：控制哪些信息应该从之前的细胞状态中遗忘
  - 输入门i_t ：控制哪些信息应该被更新到细胞状态中
  - 输出门o_t ：控制哪些信息应该被输出到隐层状态中
  - 细胞状态C_t ：容纳神经元信息

$$f_t = \sigma(W_f h_{t-1} + U_f x_t + b_f)$$

$$i_t = \sigma(W_i h_{t-1} + U_i x_t + b_i)$$

$$o_t = \sigma(W_o h_{t-1} + U_o x_t + b_o)$$

$$\hat{C}_t = \tanh(W_c h_{t-1} + U_c x_t + b_c)$$

$$C_t = f_t * C_{t-1} + i_t * \hat{C}_t$$

$$h_t = o_t * \tanh(C_t)$$

长短期记忆网络

- 长短期记忆网络图例

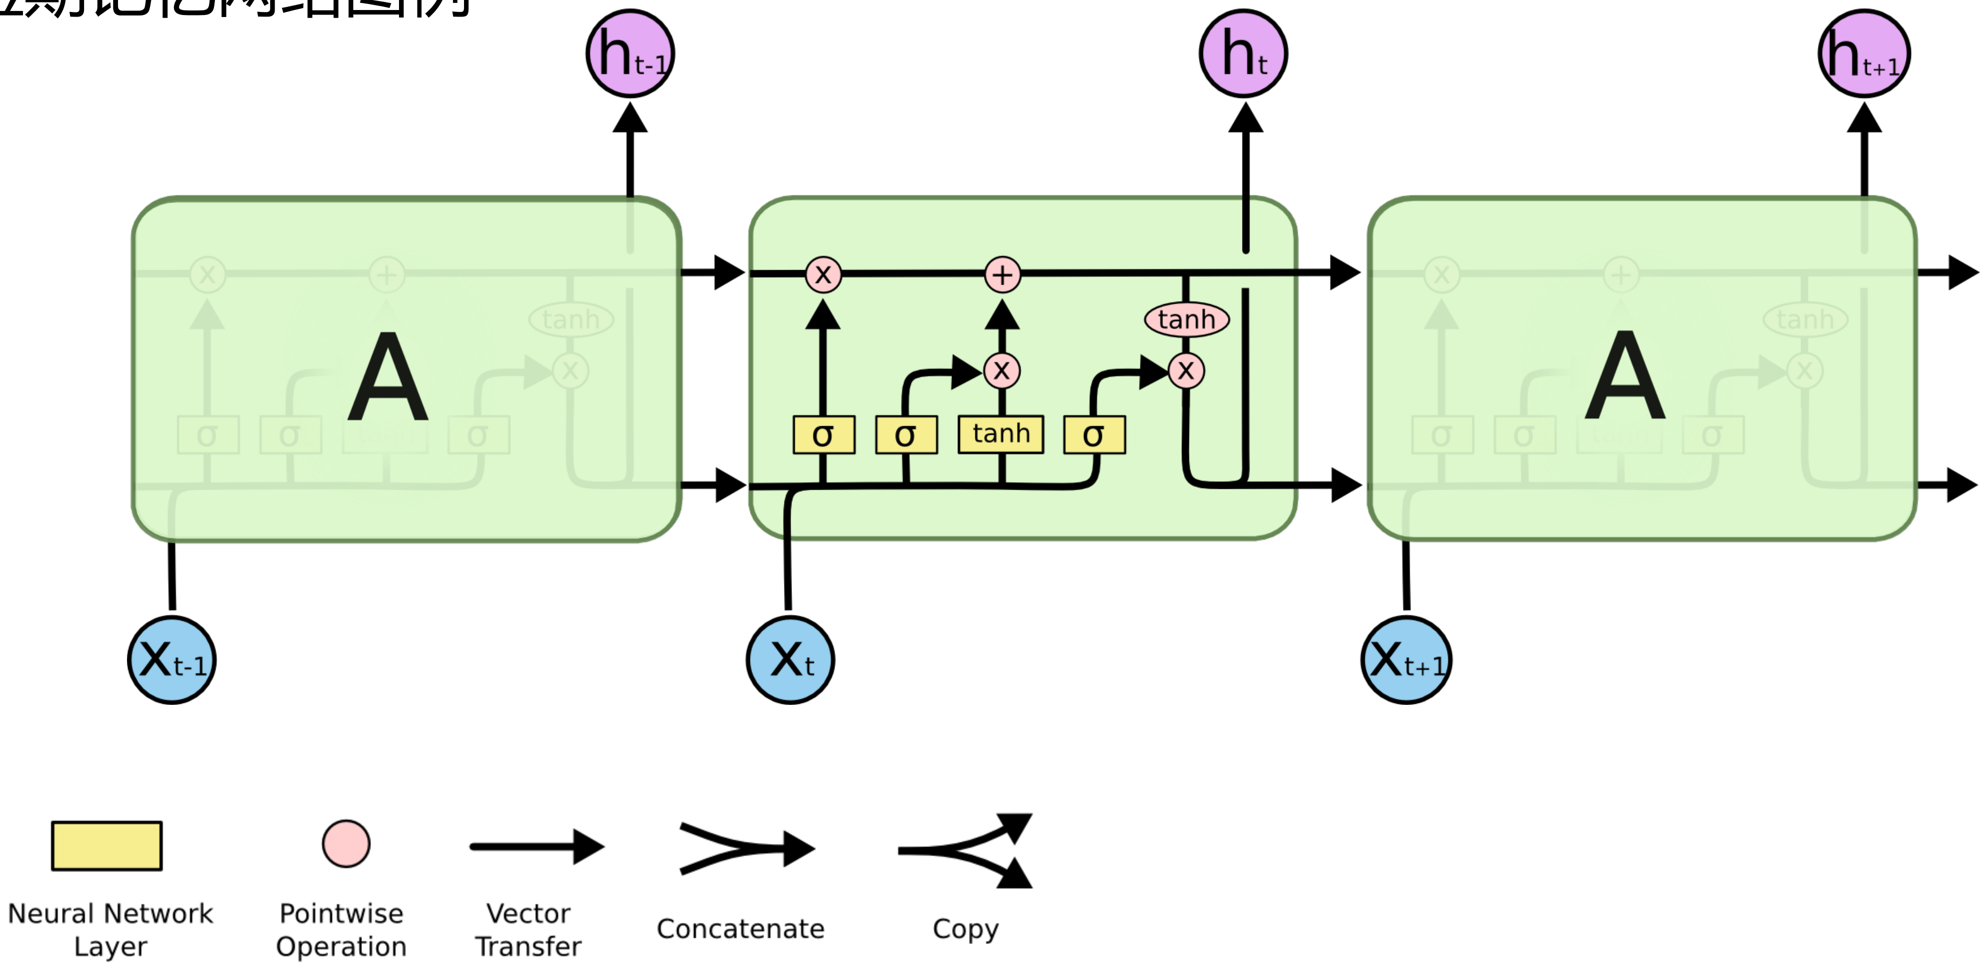

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

长短期记忆网络

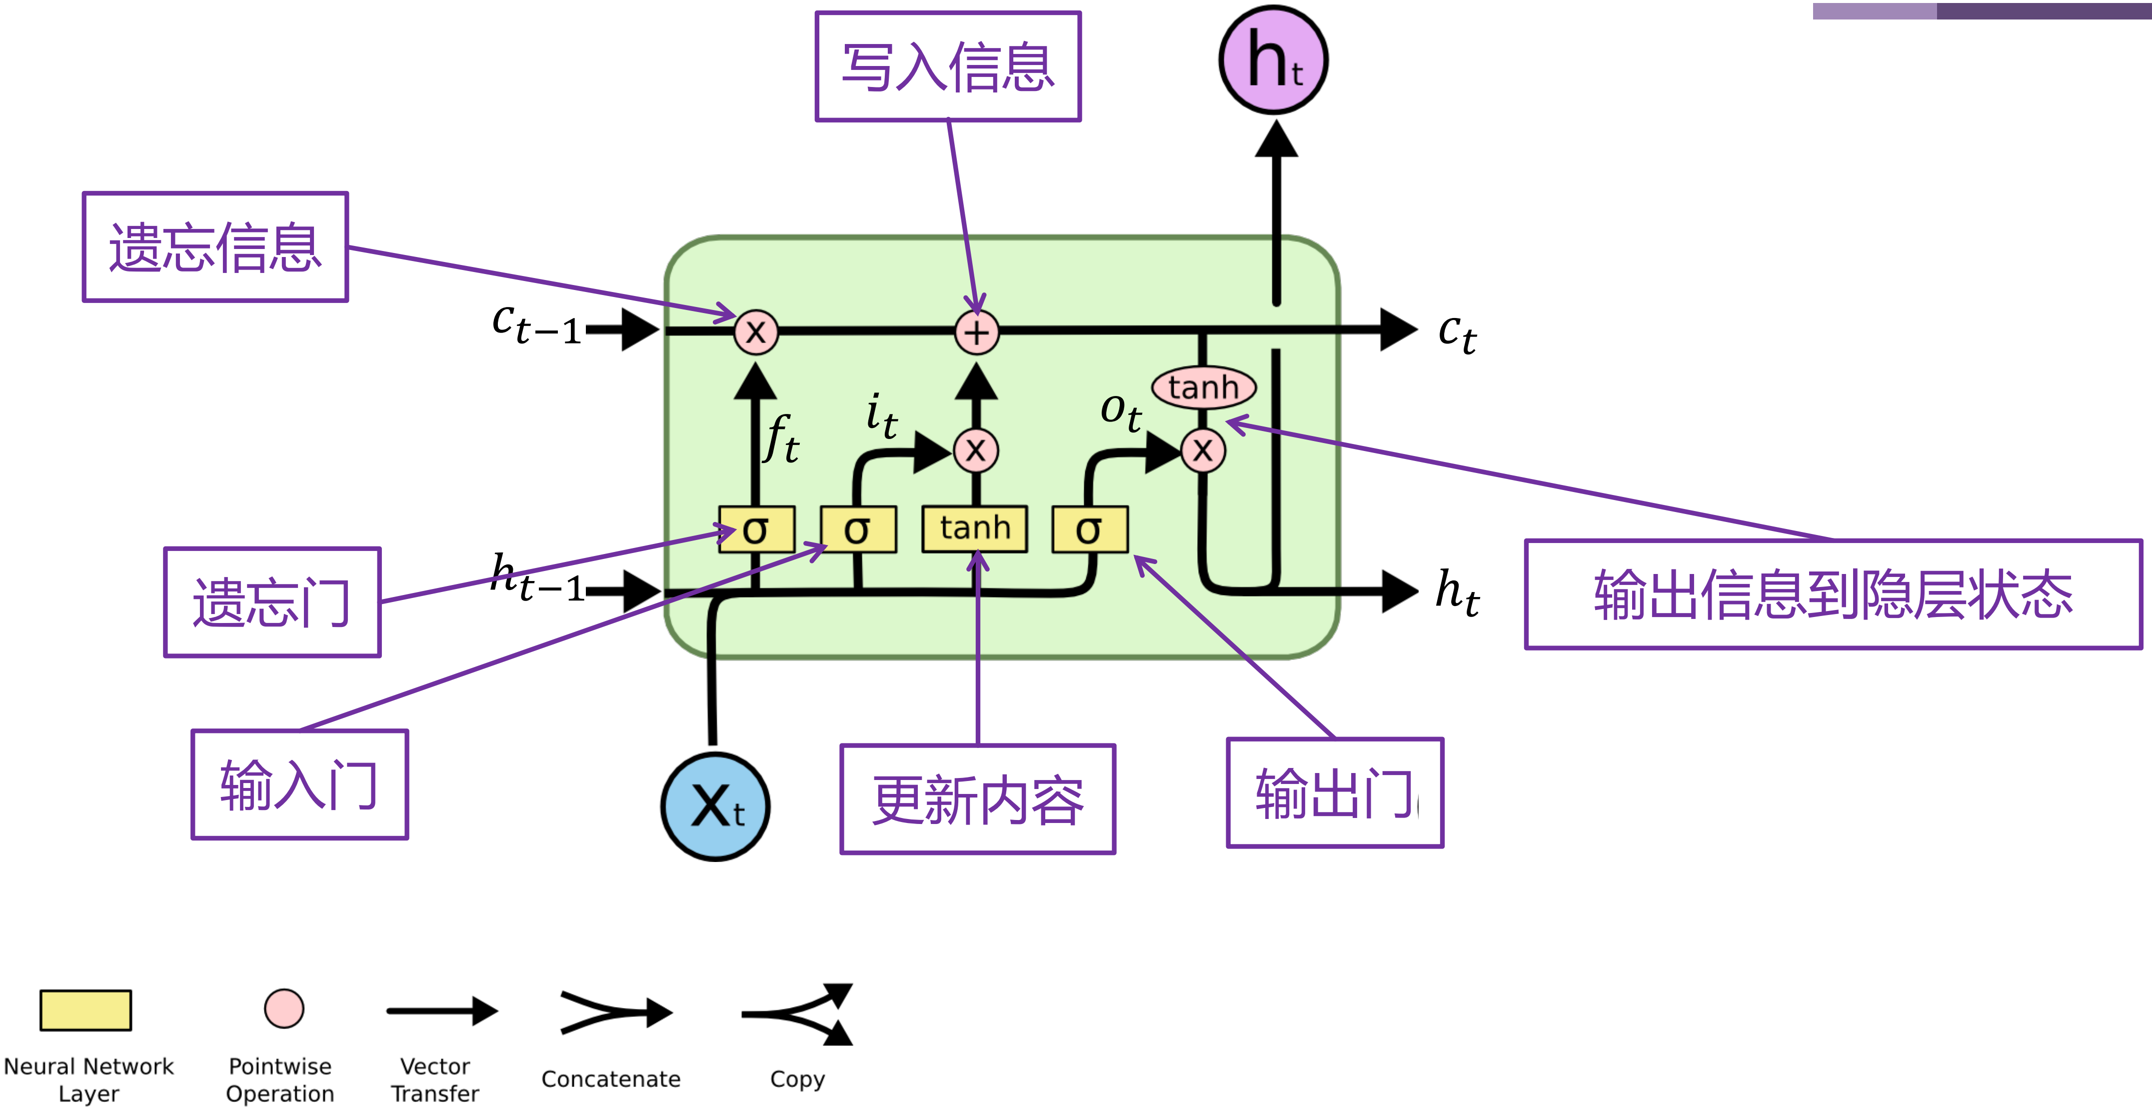

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

长短期记忆网络

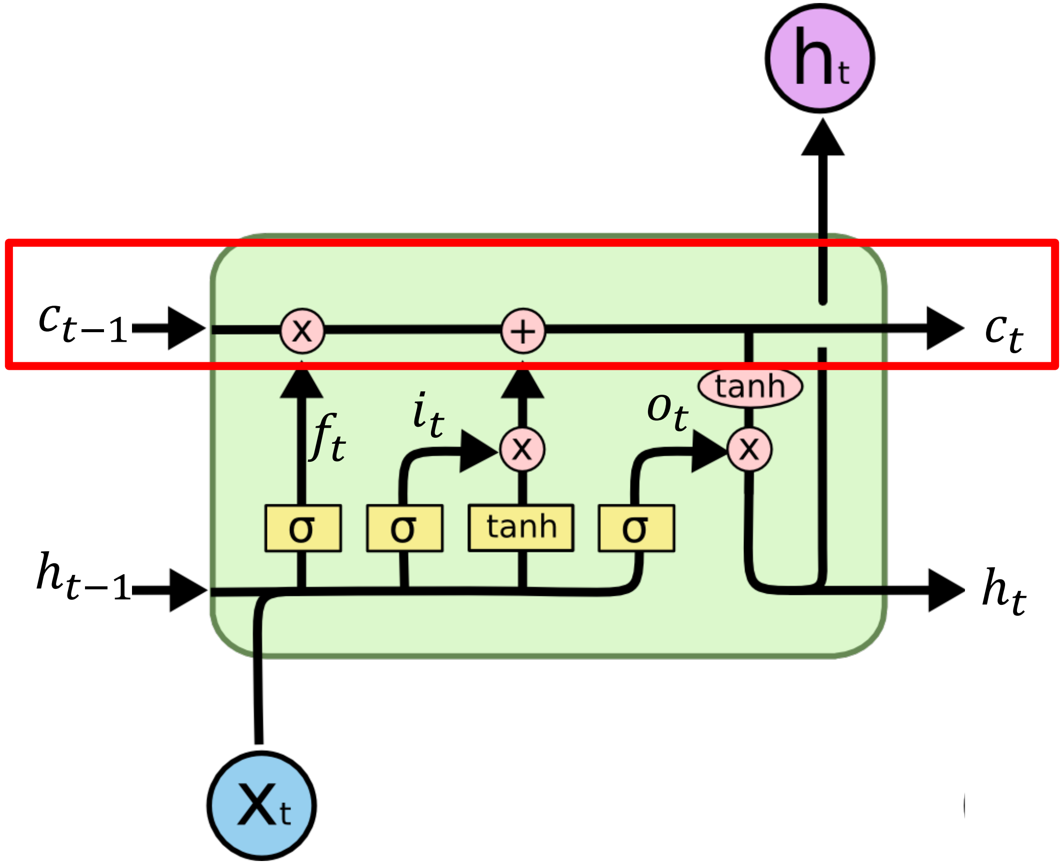

线性变换，缓解远程梯度爆炸和梯度消失问题

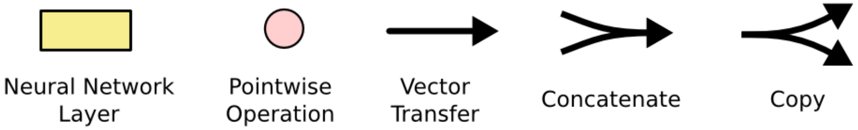

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

门控循环单元

- 门控循环单元（ Gated Recurrent Unit，GRU ）：不使用细胞状态
  - 更新门z_t ：控制哪些信息应该被更新
  - 重置门r_t ：控制哪些信息应该被重置
  - 更新内容$\tilde{h}_t$ ：从之前的隐层状态中筛选的信息
  - 隐层状态h_t ：神经元输出的信息

$$z_t = \sigma(W_u h_{t-1} + U_u x_t + b_u)$$

$$r_t = \sigma(W_r h_{t-1} + U_r x_t + b_r)$$

$$\tilde{h}_t = \tanh(W_h(r_t * h_{t-1}) + U_h x_t + b_h)$$

$$h_t = (1 - u_t) * h_{t-1} + z_t * \tilde{h}_t$$

门控循环单元

- 门控循环单元图例

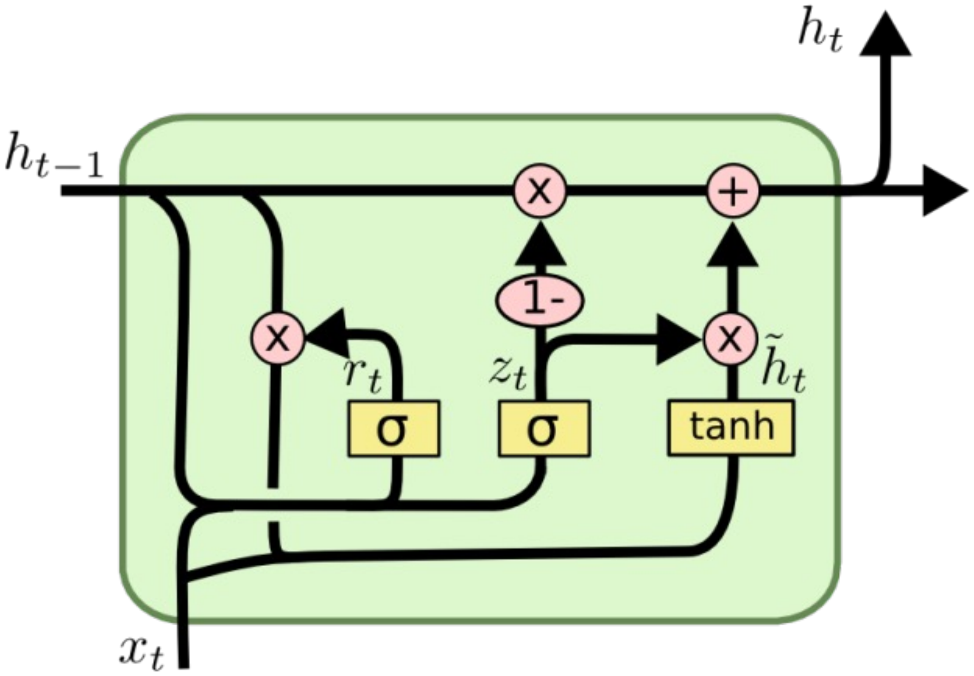

$$z_t = \sigma(W_u h_{t-1} + U_u x_t + b_u)$$

$$r_t = \sigma(W_r h_{t-1} + U_r x_t + b_r)$$

$$\tilde{h}_t = \tanh(W_h(r_t * h_{t-1}) + U_h x_t + b_h)$$

$$h_t = (1 - u_t) * h_{t-1} + z_t * \tilde{h}_t$$

相比于LSTM，参数更少，速度更快

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

双向循环神经网络（BI-RNN）

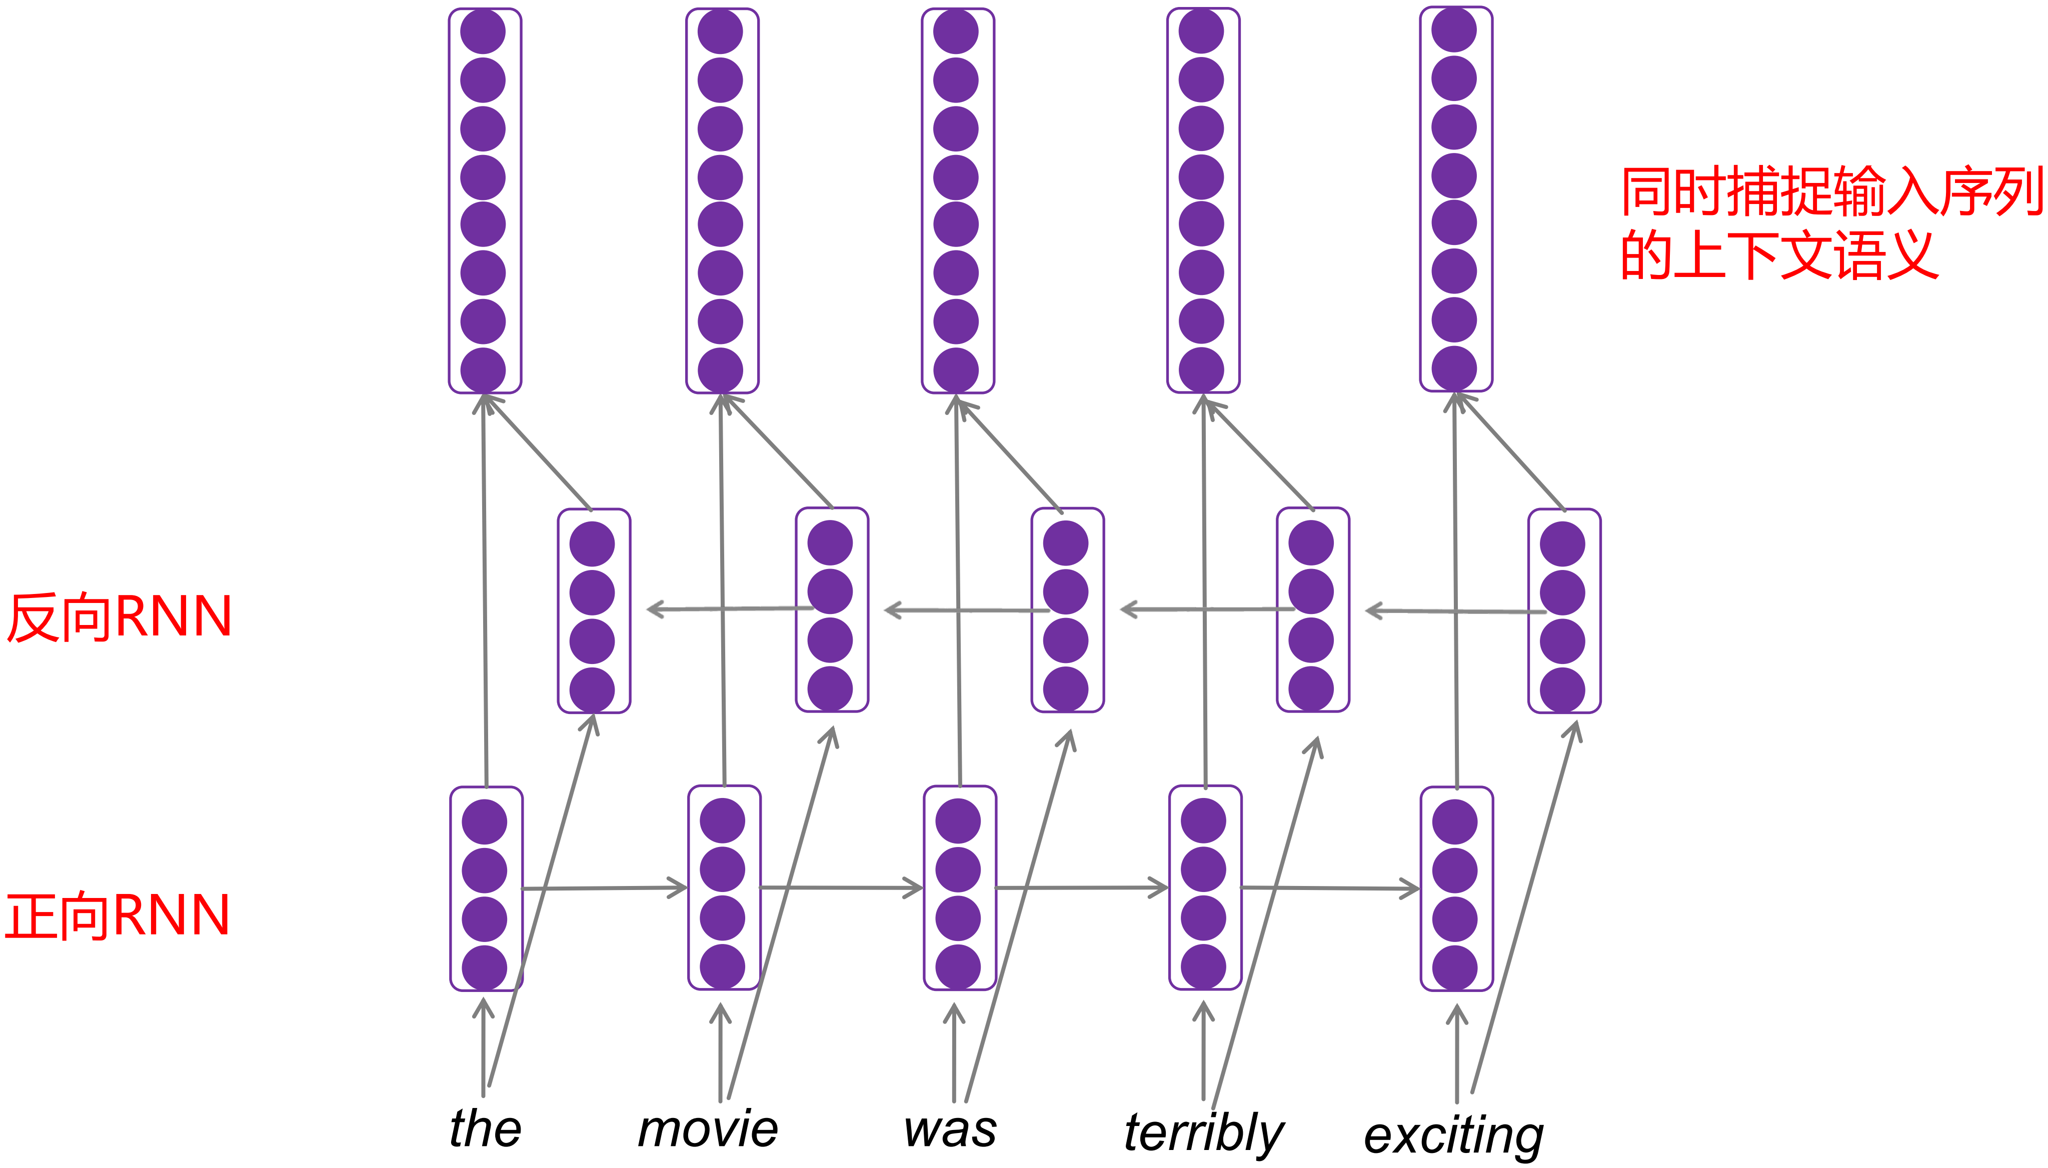

多层循环神经网络（STACKED-RNN）

NANJING UNIVERSITY

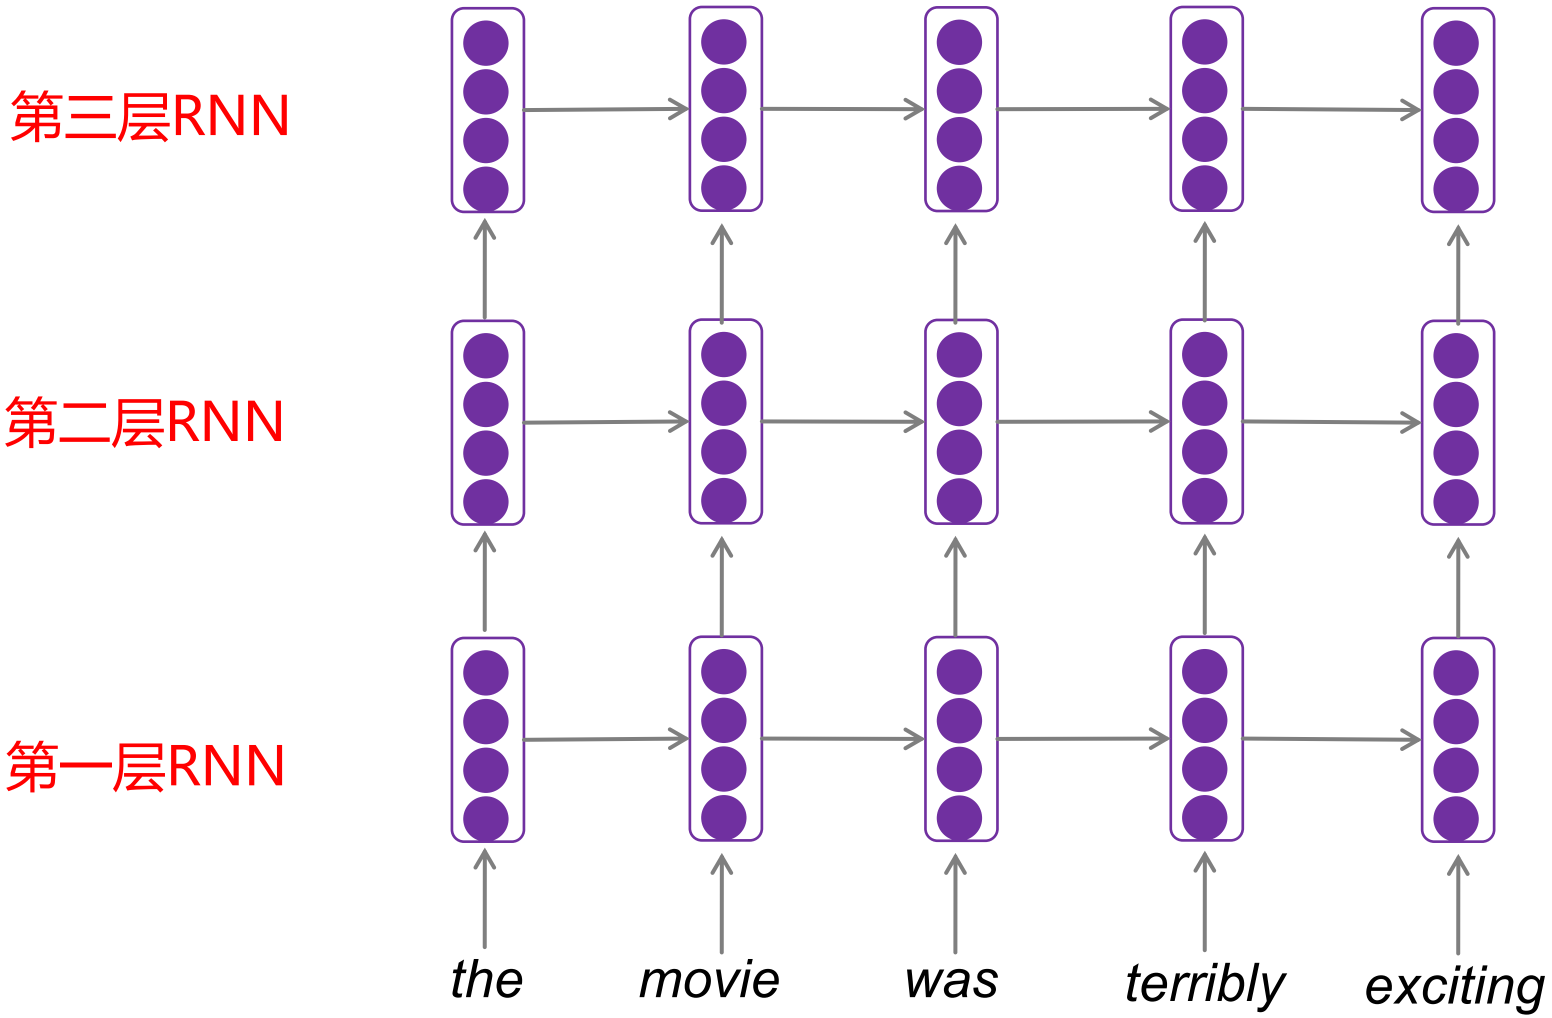

捕捉输入序列
的深层语义信息

应用：利用RNN-LM生成文本

- 对预测结果进行采样，并作为下一时刻的输入

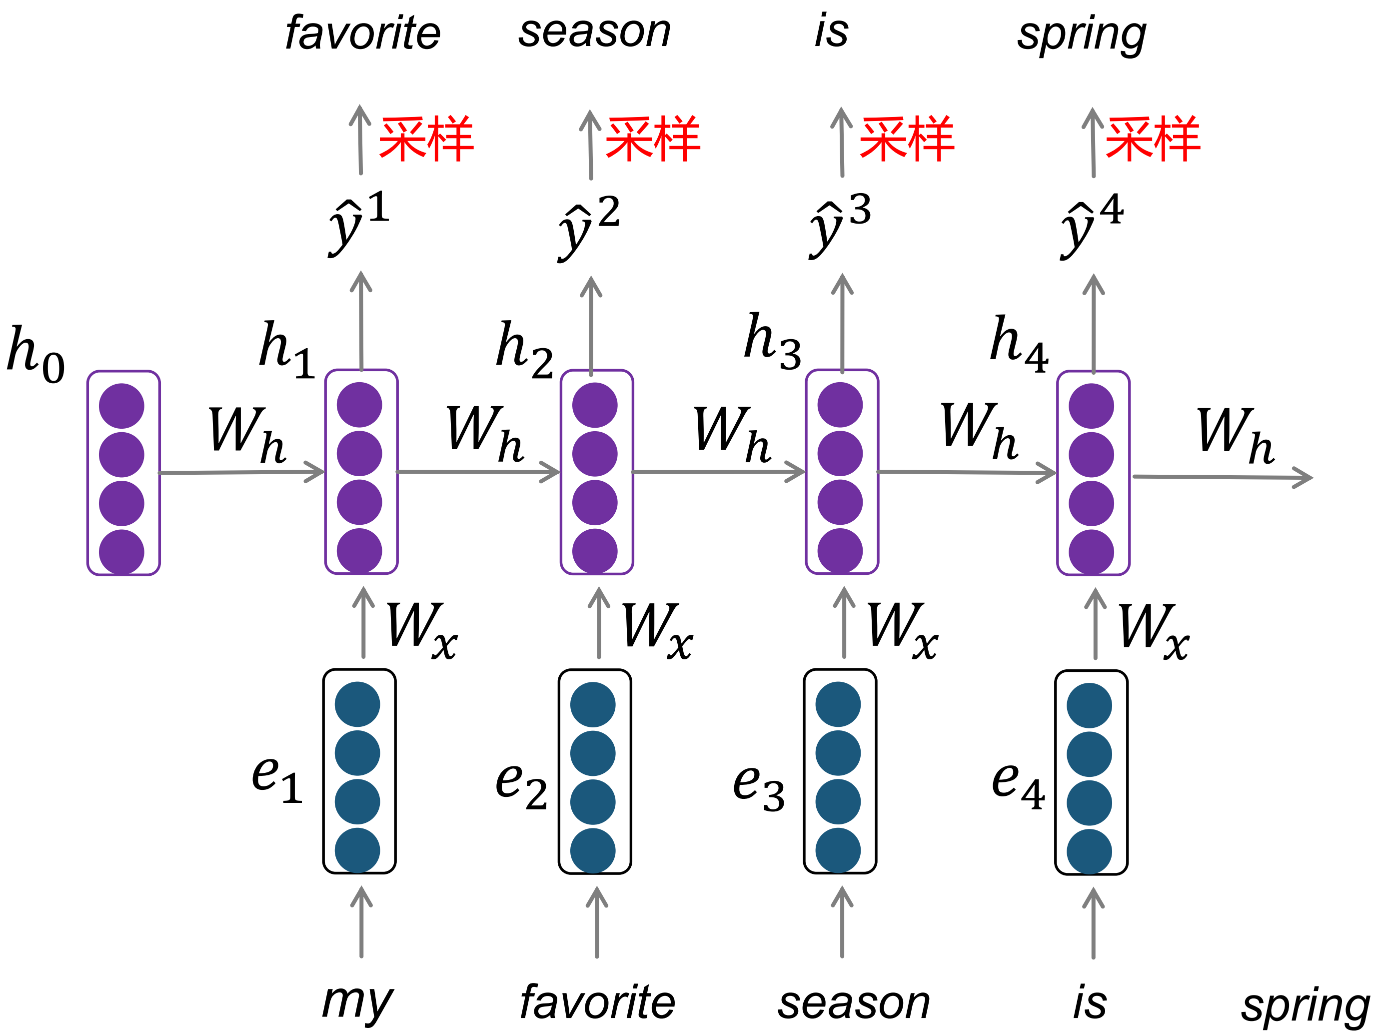

讨论：仅仅RNN有梯度问题吗？

- 神经网络都有可能会产生梯度问题
  - 前馈神经网络、卷积神经网络、循环神经网络……
- 深层网络更容易产生梯度问题
  - 梯度连乘后容易接近0（消失）或者爆炸
- 梯度消失常用解决方案
  - ReLU、残差连接…
- 梯度爆炸常用解决方案
  - 梯度裁剪（Clipping）

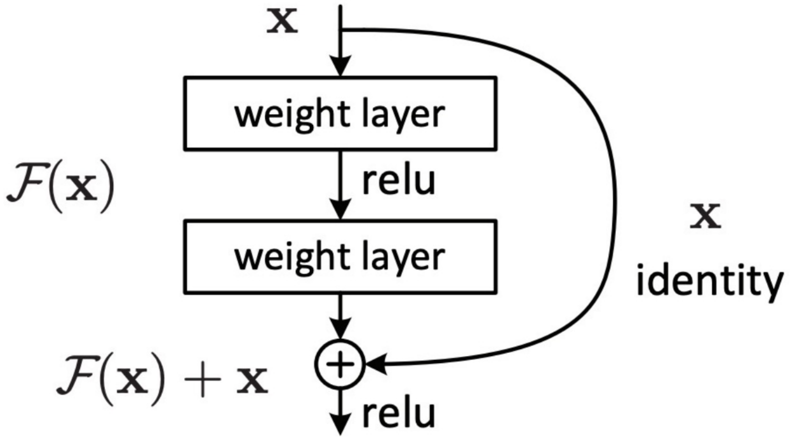

"Deep Residual Learning for Image Recognition", He et al, 2015. https://arxiv.org/pdf/1512.03385.pdf

REFERENCE

NANJING UNIVERSITY

- Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model. Interspeech. 2010, 2(3): 1045-1048.
- Pascanu R, Mikolov T, Bengio Y. On the difficulty of training recurrent neural networks. International conference on machine learning. PMLR, 2013: 1310-1318.
- Hochreiter S, Schmidhuber J. Long short-term memory. Neural computation, 1997, 9(8): 1735-1780.
- Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv preprint arXiv:1406.1078, 2014.

Q&A