南京大學
NANJING UNIVERSITY

自然语言处理

机器翻译

吴震

wuz@nju.edu.cn

2023年5月

自然语言处理中典型的任务形式

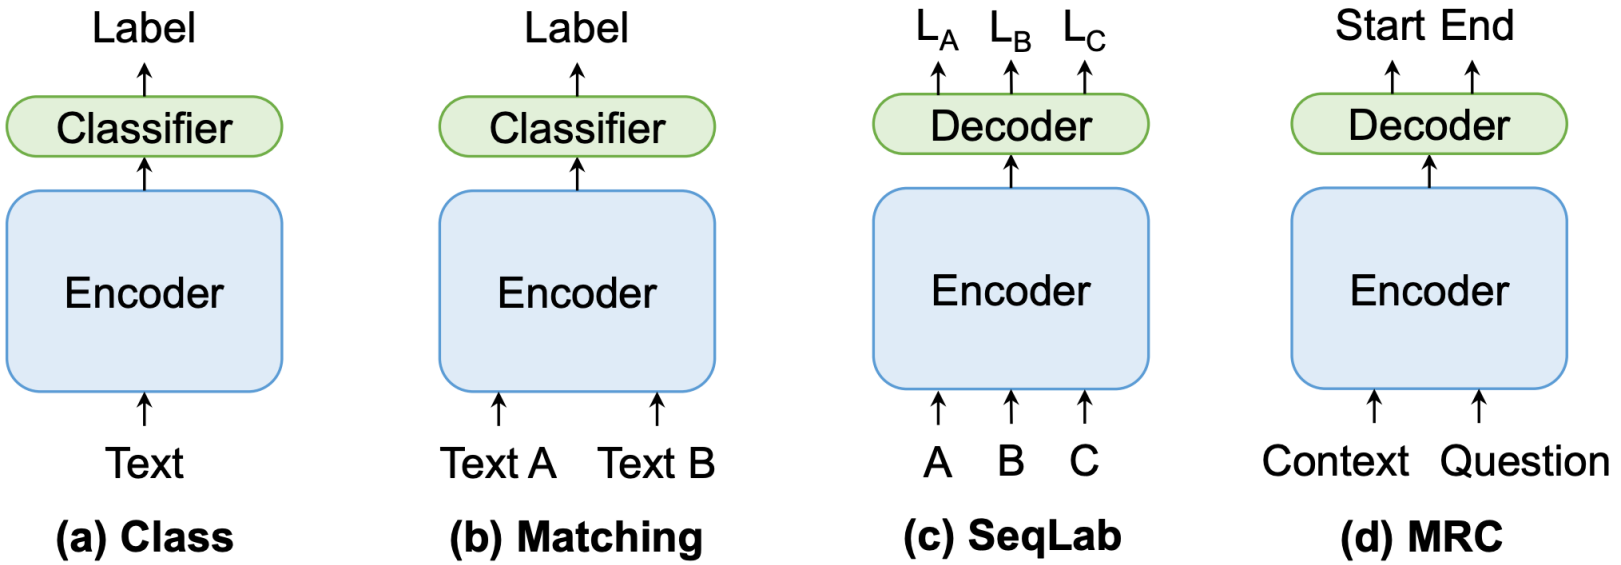

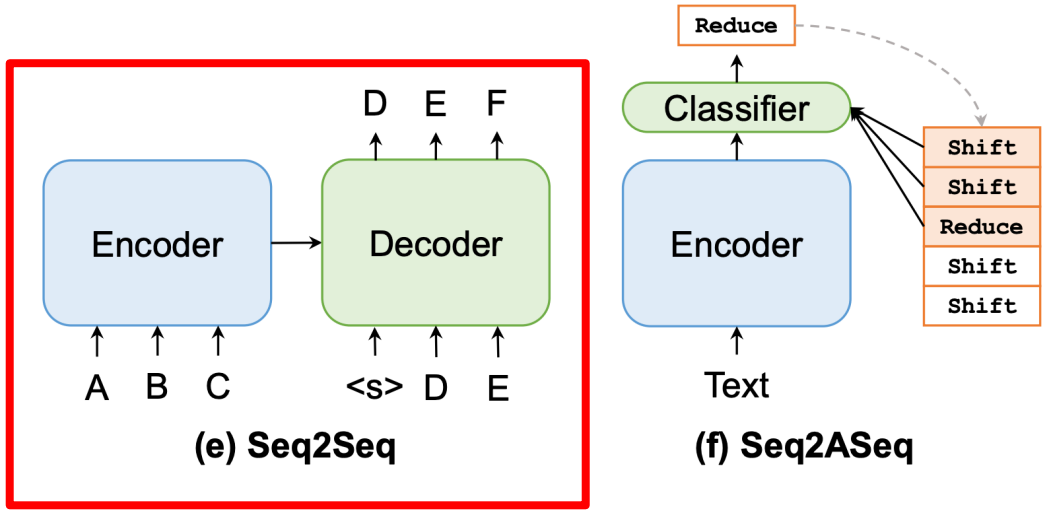

目录

01

背景介绍

INTRODUCTION

机器翻译

- 机器翻译（Machine Translation）是一个将源语言的句子x翻译成目标语言句子y（译文）的任务。

$$\text{argmax}_y P(y|x)$$

发展历史

- 1947， Warren Weaver提出机器翻译概念（人工智能概念尚未提出）；
- 1954，第一个公开展示的俄英翻译系统，走向热潮；
- 1966，美国科学院发布ALPAC报告，走入低谷；
- 1970s，实用机器翻译系统TAUM-METEO，将英文天气翻译为法文，重燃希望；
- 1990s-2000s，统计机器翻译，逐渐火热；
- 2004，Google发布多语言在线翻译引擎，走向应用；
- 2014-至今，神经机器翻译，全面繁荣。

1954 MT system video:
https://voiceinthemachine.com/2012/06/18/can-machines-really-think/

理性主义 VS 经验主义

- 理性主义：以生成语言学为基础，依靠人类先验知识
  - 基于规则的机器翻译
- 经验主义：以数据驱动为基础，从数据中学习经验和知识
  - 基于实例的机器翻译
  - 统计机器翻译
  - 神经机器翻译

02

基于规则的机器翻译

RULE-BASED MACHINE TRANSLATION

翻译步骤

- 分析
  - 将源语言句子解析成一种深层的结构表示
- 转换
  - 将源语言句子的深层结构表示转换成目标语言的深层结构表示
- 生成
  - 根据目标语言的深层结构表示生成对应的目标语言句子

翻译层次

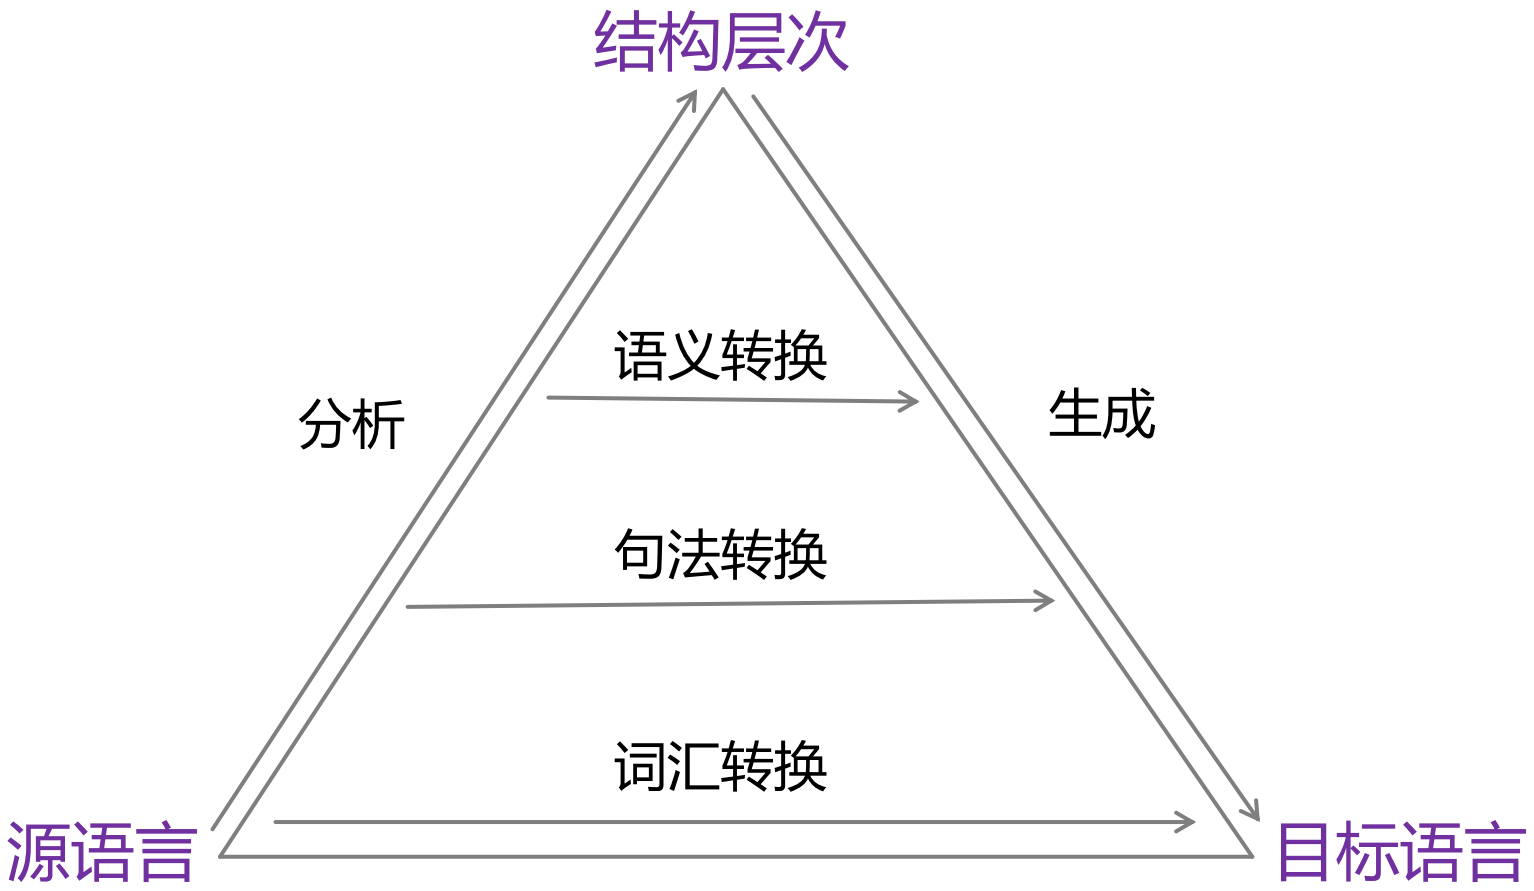

翻译样例-词汇层次

- 词汇转换规则
  - 他 → He，在 → in，北京 → Beijing，工作 → works

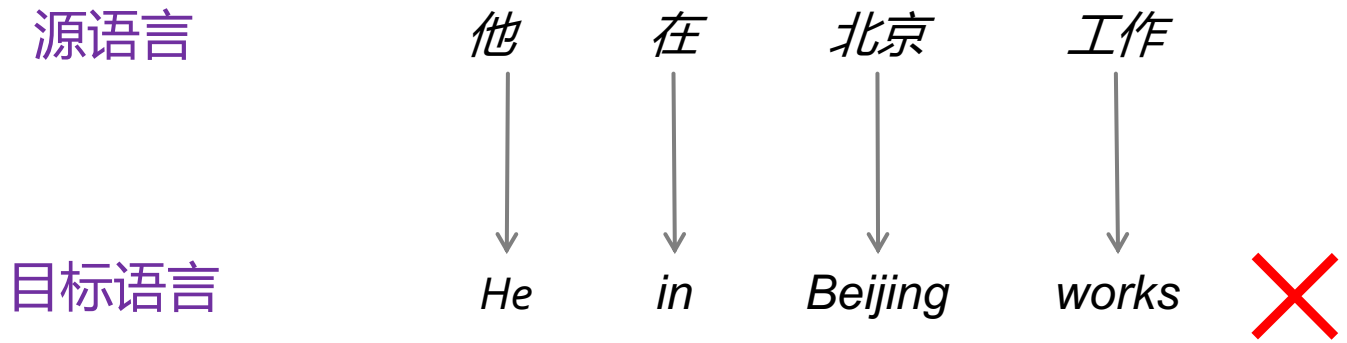

翻译样例-句法层次

- 分析规则
  - NP → 他， PP → 在北京， VP → 工作， VP → PP VP， S → NP VP
- 句法转换规则
  - S (NP VP) → S (NP VP)， VP (PP VP) → VP(VP PP)
- 词汇转换规则
  - 他 → He，在 → in，北京 → Beijing，工作 → works

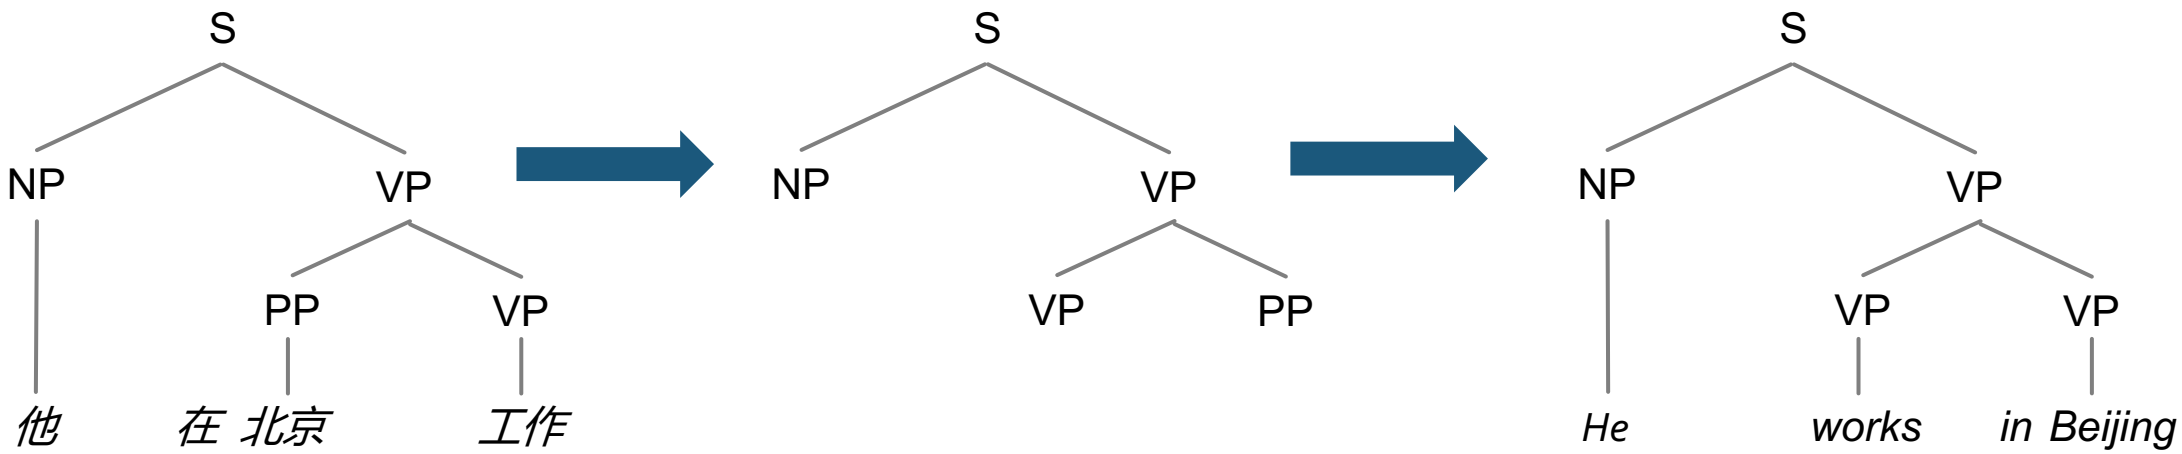

系统样例

- 南京大学日汉规则翻译系统
  - 国家七五科技攻关计划、863计划
  - 基于短语结构文法和格语法的日语句法、语义分析与转换，一体化的汉语生成技术等
  - 6万余词基本词典，10万余词领域词典，10万余人名地名词典等；
  - 句法规则1000余条，动词格框架1800余条，通用格框架60余条，转换/生成规则大约有800余条，40万句对翻译记忆体

国家七五科技攻关重大成果奖

江苏省科技进步三等奖

南京大学日汉机器翻译系统:
http://nlp.nju.edu.cn/homepage/introduction.html

规则方法的问题

- 规则质量依赖于语言学家的知识和经验，获取成本高
- 大规模规则系统维护难度大
- 规则之间容易发生冲突

"Anytime a linguist leaves the group the recognition rate goes up."

- Frederick Jelinek, 1988

Frederick Jelinek (1932-2010)
Researcher in Information Theory, Speech Recognition, and Natural Language Processing
Professor at Cornell 1962-1974
Head of Continuous Speech Recognition group, IBM T.J. Watson 1972-1993
Head of Center for Language and Speech Processing, JHU 1993-2010

03

基于实例的机器翻译

ANALOGY-BASED MACHINE TRANSLATION

基于实例的机器翻译

- 从双语语料库中学习翻译实例 [Nagao, 1984]
  - 利用类比思想（analogy），避免复杂的结构分析
  - 从语料库中查找与待翻译句子相近的实例，通过逐词替换进行翻译

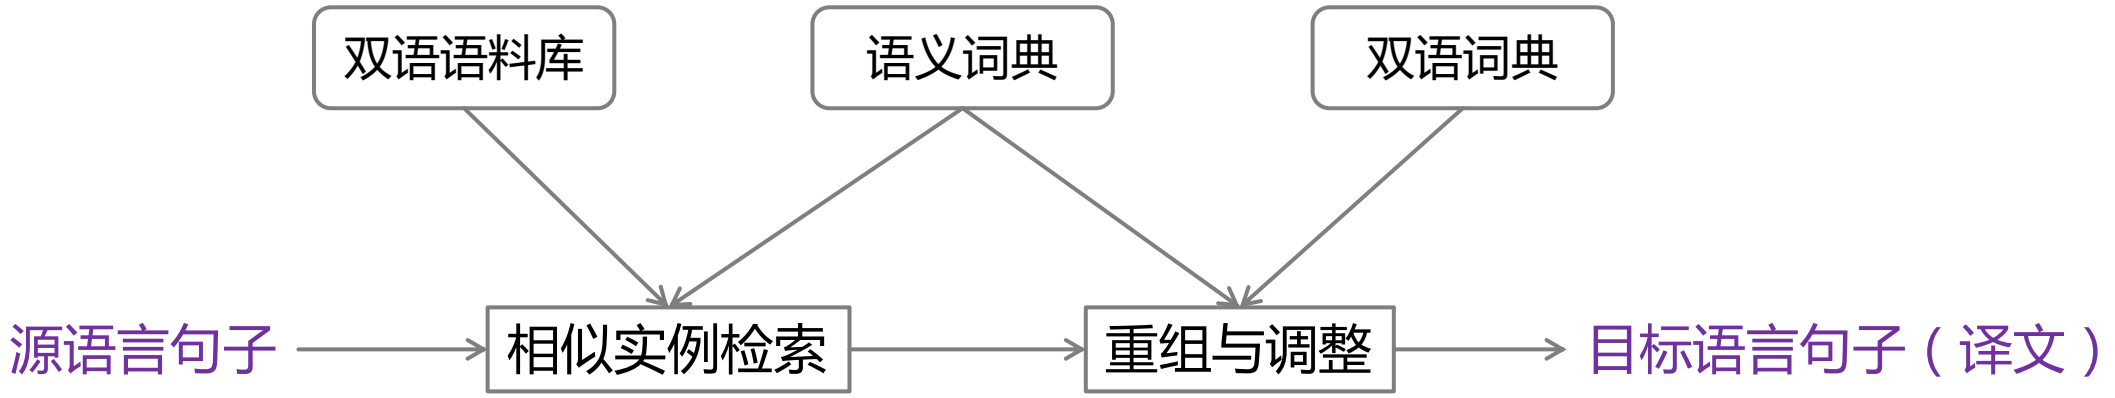

翻译样例

- 双语语料库

中文	英文
他 喜欢 北京	He likes Beijing
他 在 南京 居住	He lives in Nanjing
……	……

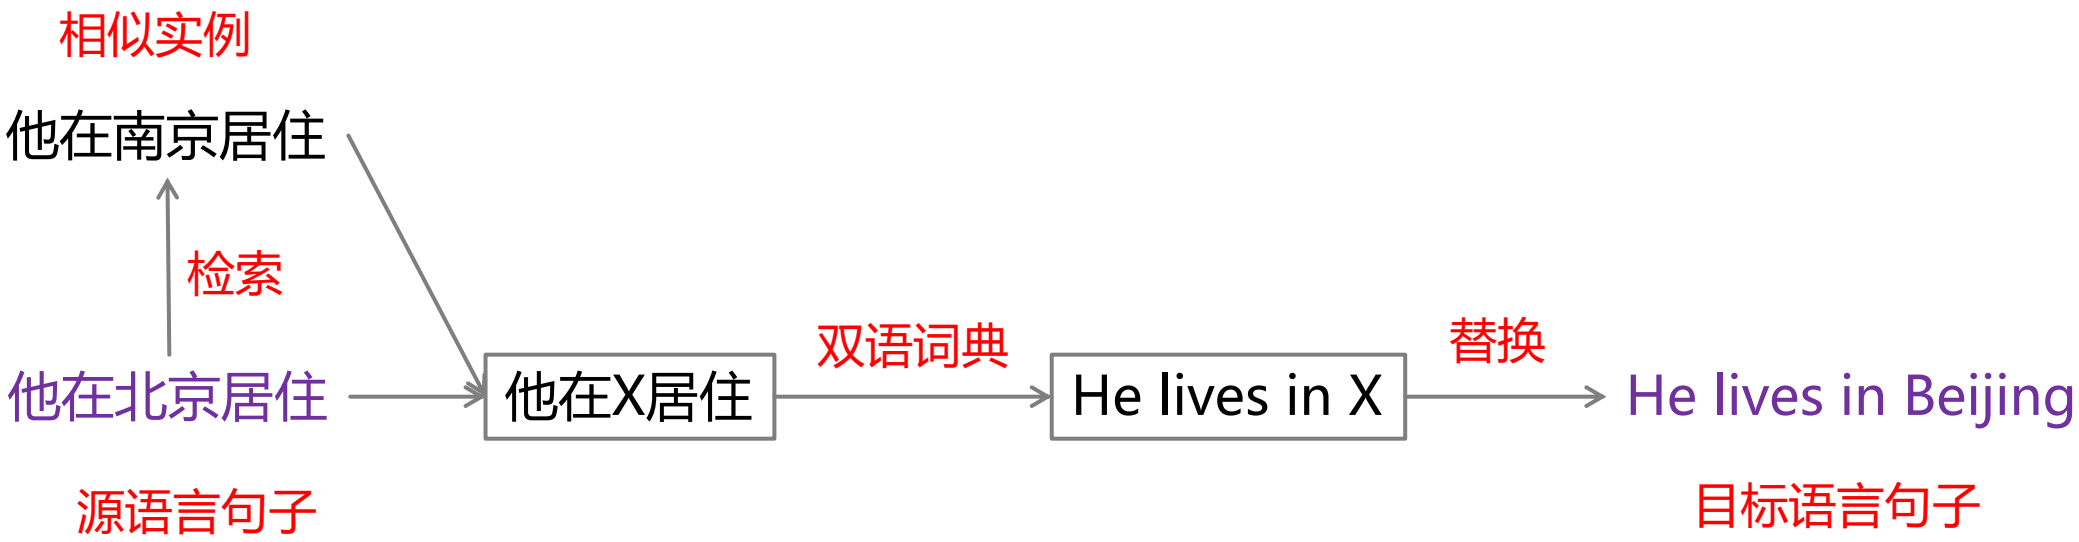

基于实例翻译的问题

- 检索的实例粒度一般为句子，无法支持较长文本的翻译
- 实例相似度较低时翻译欠佳

04

统计机器翻译

STATISTICAL MACHINE TRANSLATION

翻译目标

- 将源语言的句子x翻译成目标语言句子y（译文）

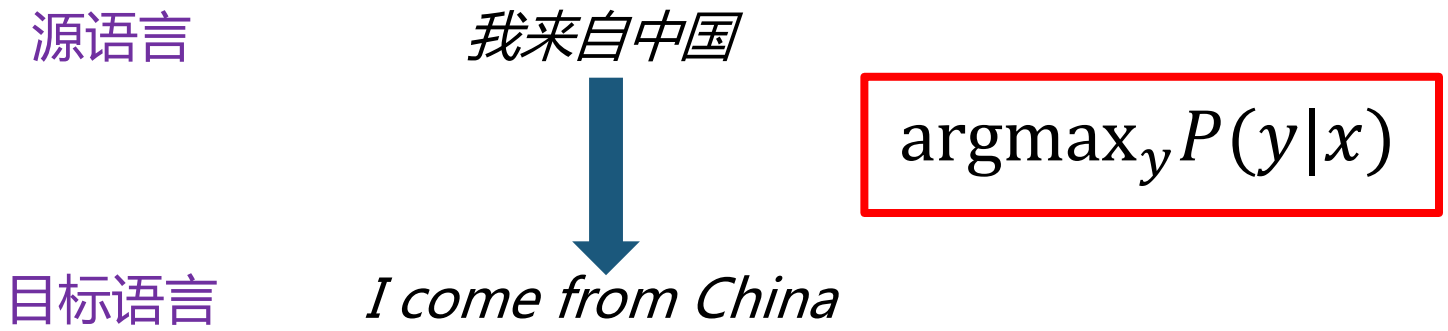

噪声信道模型（ NOISY CHANNEL ）

- 描述源语言的句子x是如何由目标语言句子y生成的（生成式模型）
  - 原始信号y经过“噪声”扰动，变成了观测信号x
  - 根据观测信号x，推测出原始信号y

贝叶斯公式

$$\text{argmax}_y P(y|x) = \text{argmax}_y \frac{P(y)P(x|y)}{P(x)}$$

$$= \text{argmax}_y P(y)P(x|y)$$

源模型 信道模型

语言模型 翻译模型

三个问题

- 1. 如何估计语言模型的概率$P(y)$?
- 2. 如何估计翻译模型概率$P(x|y)$?
- 3. 如何快速解码目标语言y，使得$P(y)P(x|y)$最大？

$$\text{argmax}_y P(y|x) = \text{argmax}_y P(y)P(x|y)$$

语言模型$P(y)$

- 对于由m个单词构成的目标语言句子$y = y_1 \dots y_m$，其语言模型概率$P(y)$为：

$$P(y) = P(y_1)P(y_2|y_1) \dots P(y_m|y_1 \dots y_{m-1})$$

可用统计语言模型建模（ngram模型）

翻译模型$P(x|y)$

- IBM Model：引入对齐概念来帮助计算翻译模型

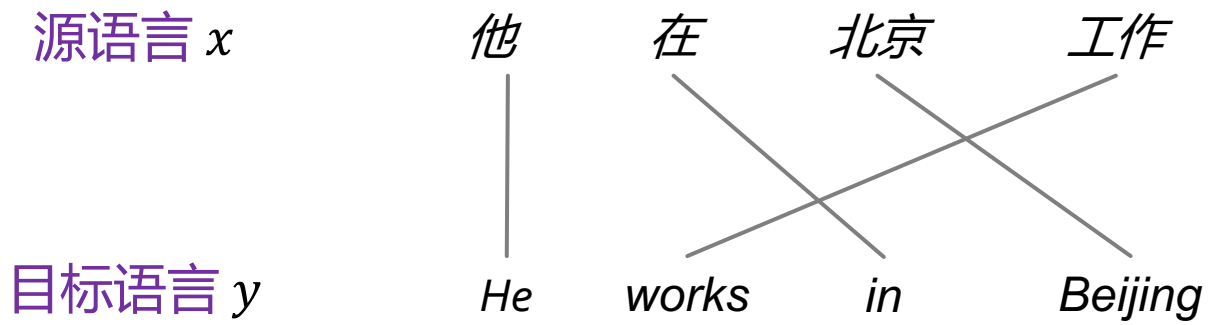

- 假设源语言句子x和目标语言句子y之间的一种对齐方式为$a = a_1 \dots a_n$，其中$a_n \in [0,1, \dots, m]$， n和m分别为源语言句子和目标语言句子长度，则：

$$P(x|y) = \sum_a P(x, a|y)$$

翻译模型$P(x|y)$

- 计算$P(x,a|y)$

$$P(x,a|y)=P(n|y)P(a|y,n)P(x|y,a,n)$$

$$=P(n|y)\prod_{j=1}^{n}(P(a_j|a_1\dots a_{j-1},x_1\dots x_{j-1},y,n)\times P(x_j|a_1\dots a_{j-1},x_1\dots x_{j-1},y,n))$$

长度生成模型　　词语对齐模型　　词对翻译模型

翻译模型$P(x|y)$

- IBM Model1假设：
  - $P(n|y)=c$，即长度生成概率是一个常量
  - $a_j \sim uniform(0,1,\dots,m)$，即词语对齐模型服从均匀分布，词语对齐概率

    $P(a_j|a_1 \dots a_{j-1}, x_1 \dots x_{j-1}, y, n) = \frac{1}{m+1}$
  - $x_j \sim Categorical(\theta_{y_{a_j}})$，即词对翻译概率服从类别分布，词对翻译概率

    $P(x_j|a_1 \dots a_{j-1}, x_1 \dots x_{j-1}, y, n) = P(x_j|y_{a_j})$

翻译模型$P(x|y)$

- 计算$P(x,a|y)$

$$P(x,a|y) = \frac{c}{(m+1)^n}\prod_{j=1}^{n} p(x_j|y_{a_j})$$

- 计算$P(x|y)$

$$P(x|y) = \sum_a P(x,a|y) = \frac{c}{(m+1)^n}\prod_{j=1}^{n}\sum_{i=0}^{m} P(x_j|y_i)$$

IBM Model：https://zhuanlan.zhihu.com/p/154262144
EM算法： https://zhuanlan.zhihu.com/p/78311644

解码出y使$P(y)P(x|y)$最大

- Viterbi 算法（动态规划算法）

假设给定隐式马尔可夫模型（HMM）状态空间 S，共有k个状态，初始状态 i 的概率为 π_i ，从状态 i 到状态 j 的转移概率为 $a_{i,j}$。 令观察到的输出为 $y_1, \ldots, y_T$。 产生观察结果的最有可能的状态序列 $x_1, \ldots, x_T$ 由递推关系给出：[2]

$$
\begin{aligned}
V_{1,k} &= \mathrm{P}\left(y_1 \mid k\right) \cdot \pi_k \\
V_{t,k} &= \max_{x \in S} \left(\mathrm{P}\left(y_t \mid k\right) \cdot a_{x,k} \cdot V_{t-1,x}\right)
\end{aligned}
$$

此处 $V_{t,k}$ 是前 t 个最终状态为 k 的观测结果最有可能对应的状态序列的概率。 通过保存向后指针记住在第二个等式中用到的状态 x 可以获得维特比路径。声明一个函数 $\mathrm{Ptr}(k, t)$ ，它返回若 $t > 1$时计算 $V_{t,k}$ 用到的 x 值 或若 $t = 1$时的k . 这样:

$$
\begin{aligned}
x_T &= \arg\max_{x \in S}(V_{T,x}) \\
x_{t-1} &= \mathrm{Ptr}(x_t, t)
\end{aligned}
$$

这里我们使用了arg max（英语：arg max）的标准定义 算法复杂度为 $O(T \times |S|^2)$

Viterbi算法：https://en.wikipedia.org/wiki/Viterbi_algorithm

05

神经机器翻译

NEURAL MACHINE TRANSLATION

神经机器翻译

- 神经机器翻译（Neural Machine Translation）：用端到端（end-to-end）的神经网络来建模机器翻译任务。
- 编码器-解码器框架（Encoder-decoder）
  - Seq2Seq
  - 编码器（encoder）：用来编码源语言的输入
  - 解码器（decoder）：用来生成目标语言的输出

编码器-解码器框架

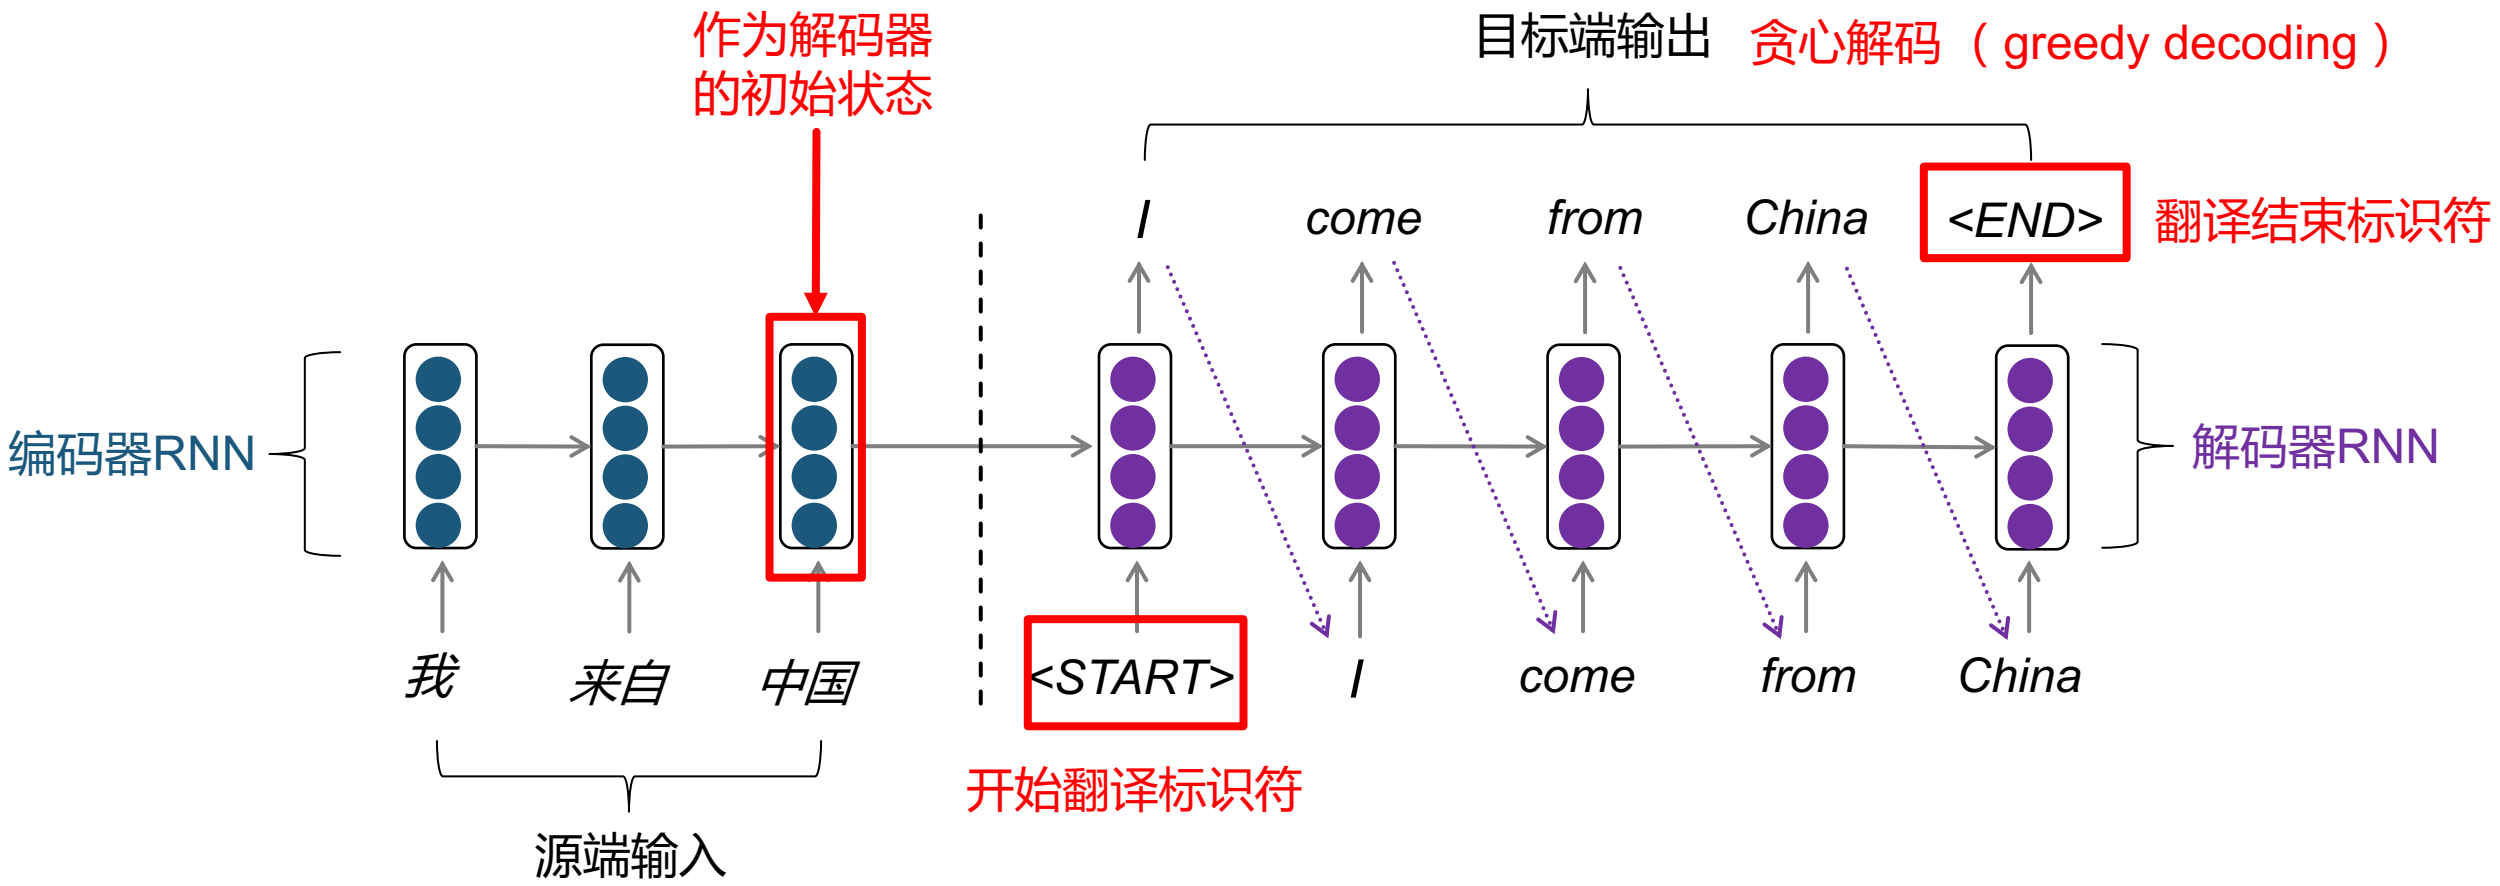

编码器RNN编码了源端句子的上下文信息

解码器RNN是一个给定输入编码条件下的语言模型

编码器-解码器框架的问题

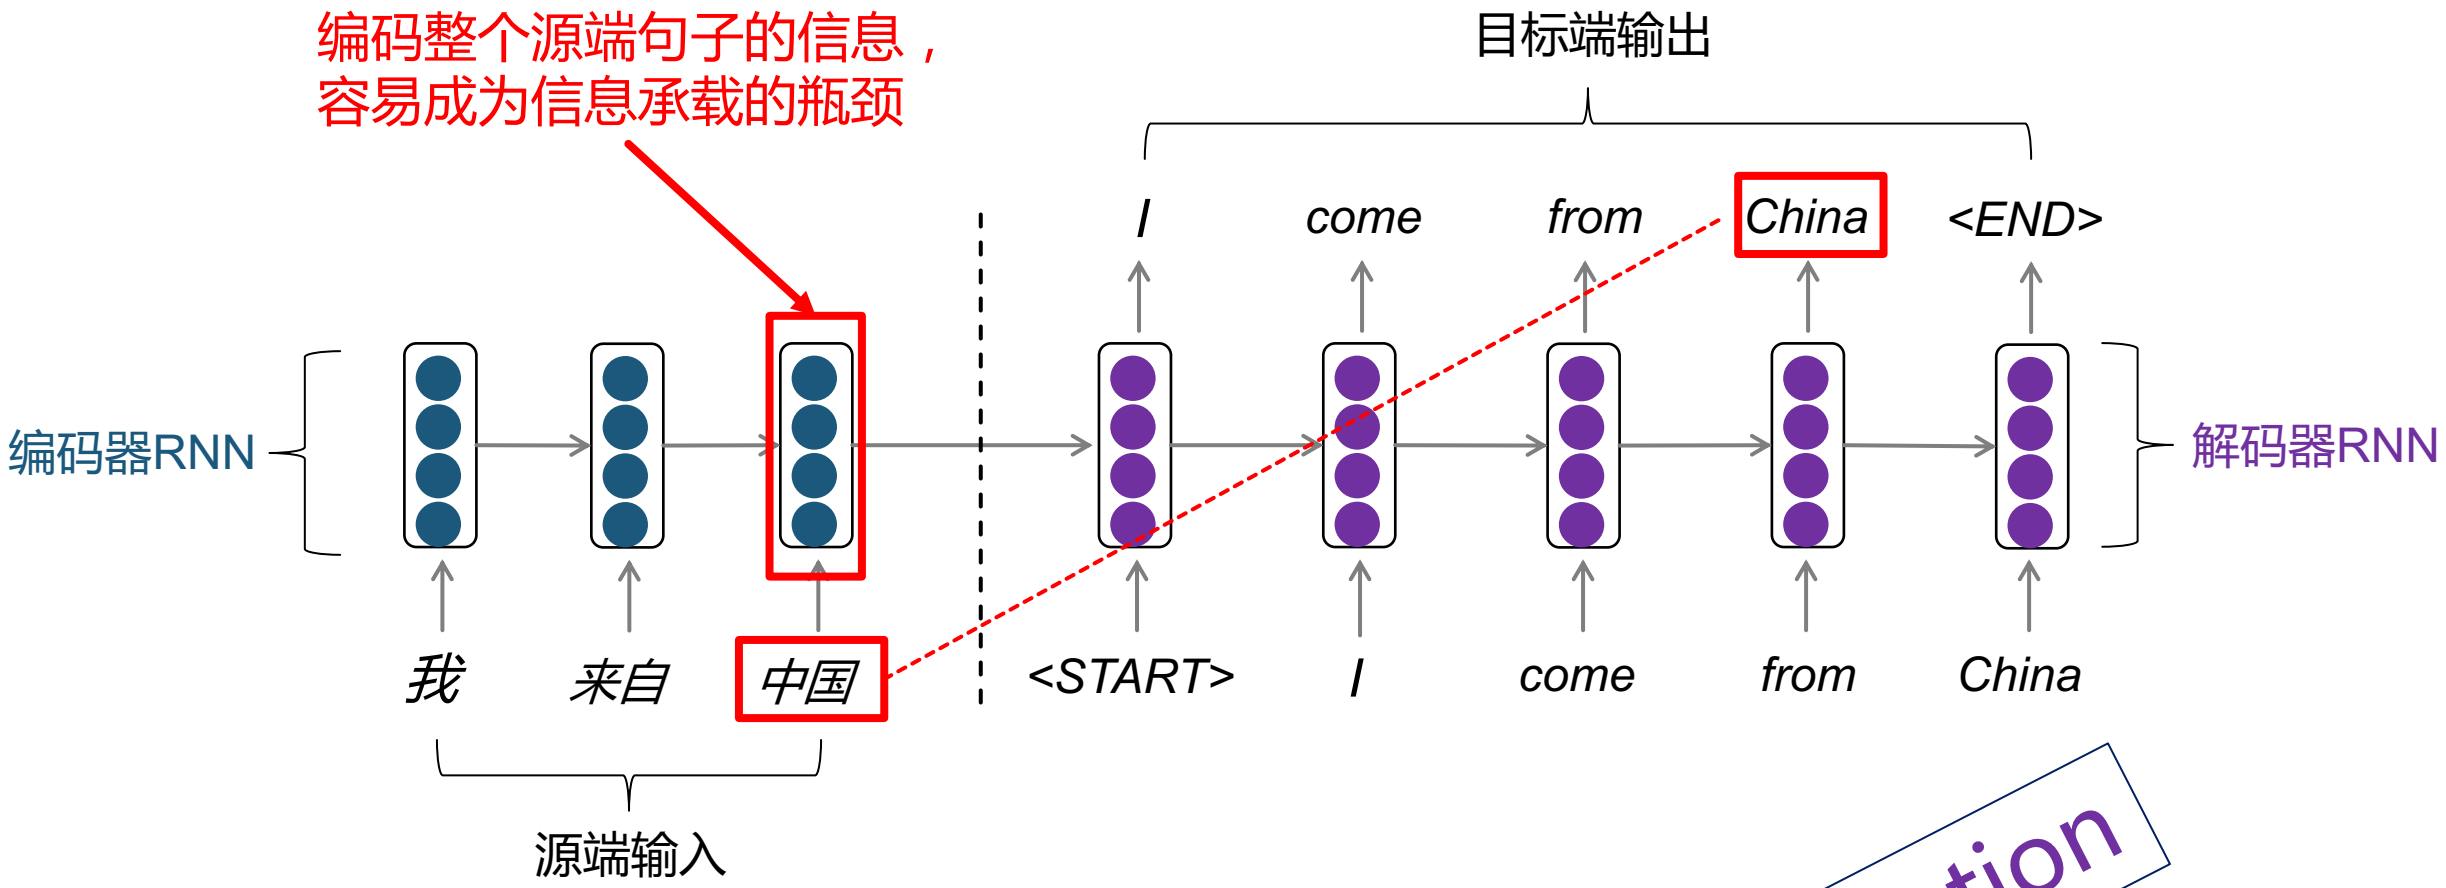

翻译过程不具有可解释性

目标端解码某个特定单词时，应该重点关注源端相关的单词

Attention

基于注意力机制的编码器-解码器框架

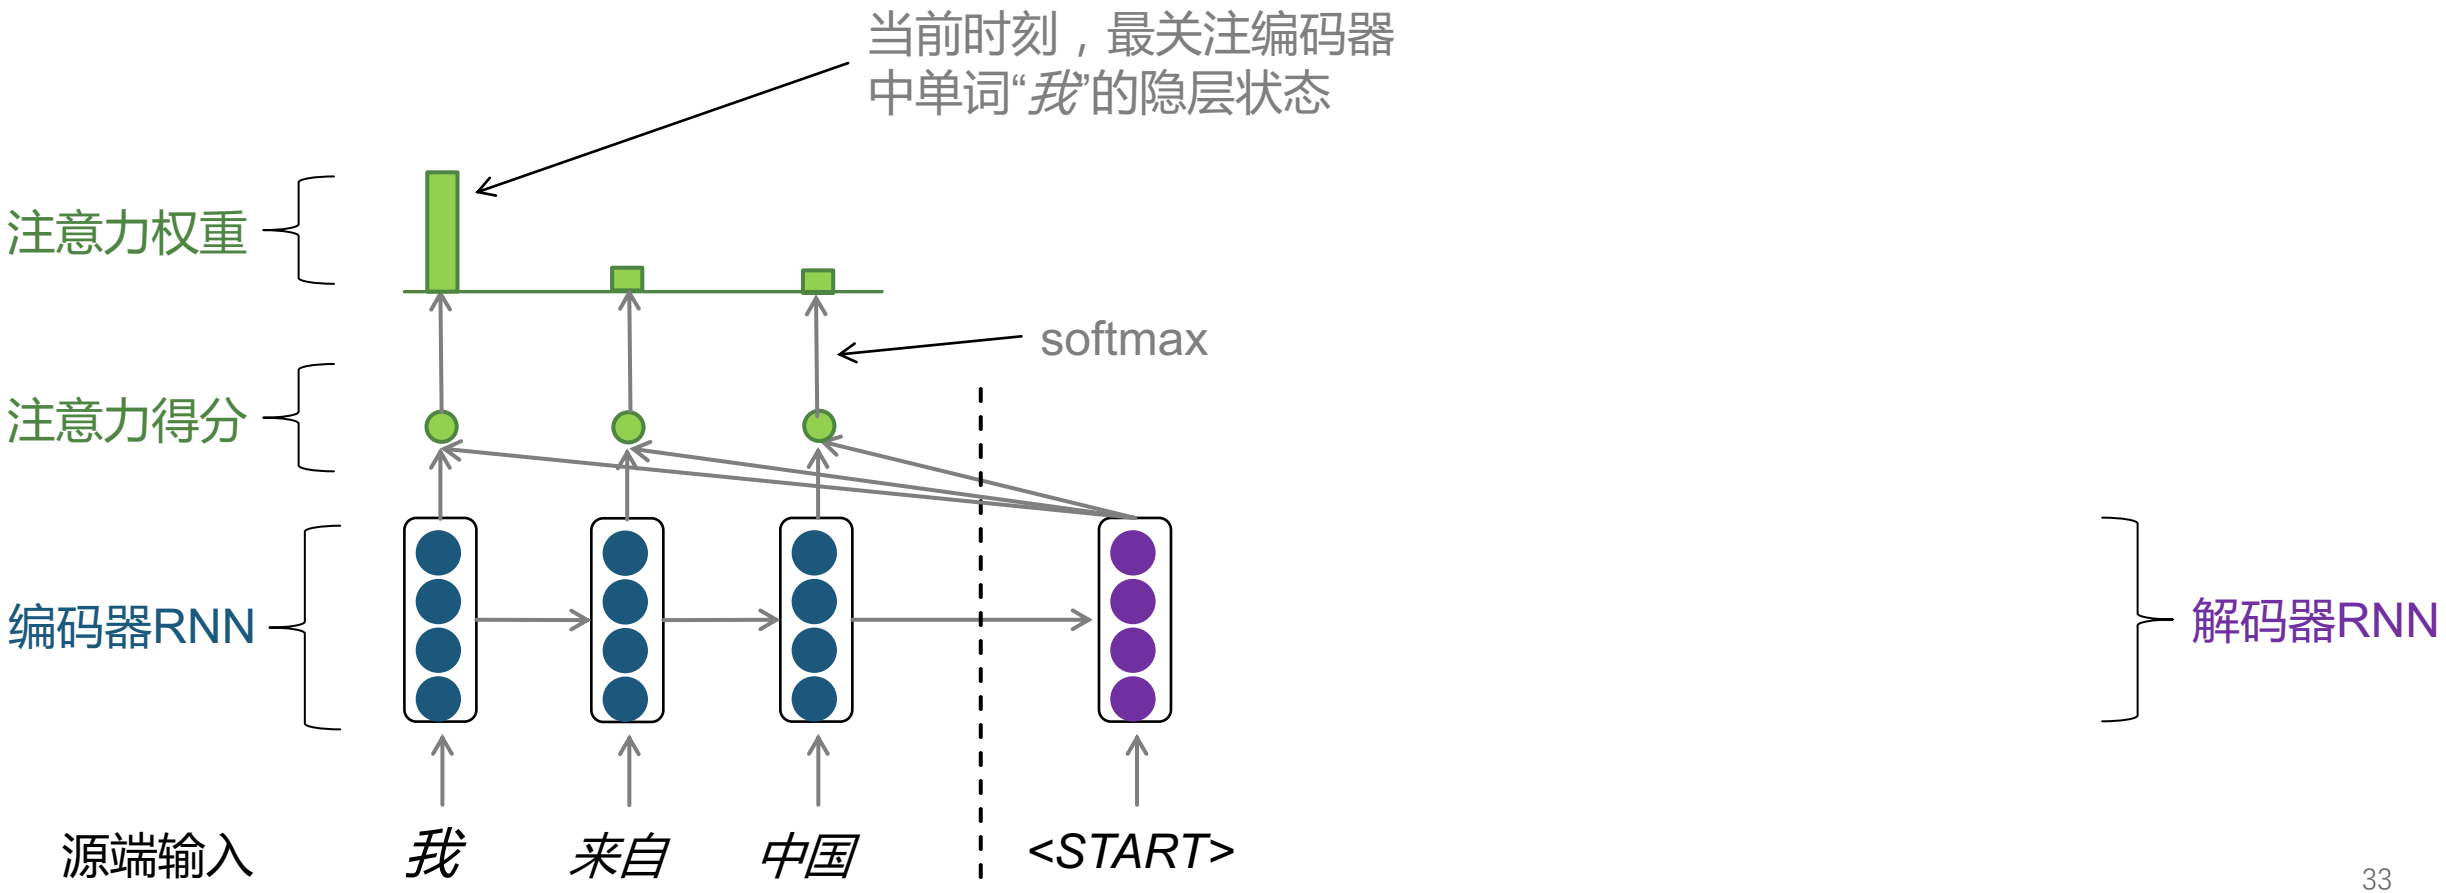

基于注意力机制的编码器-解码器框架

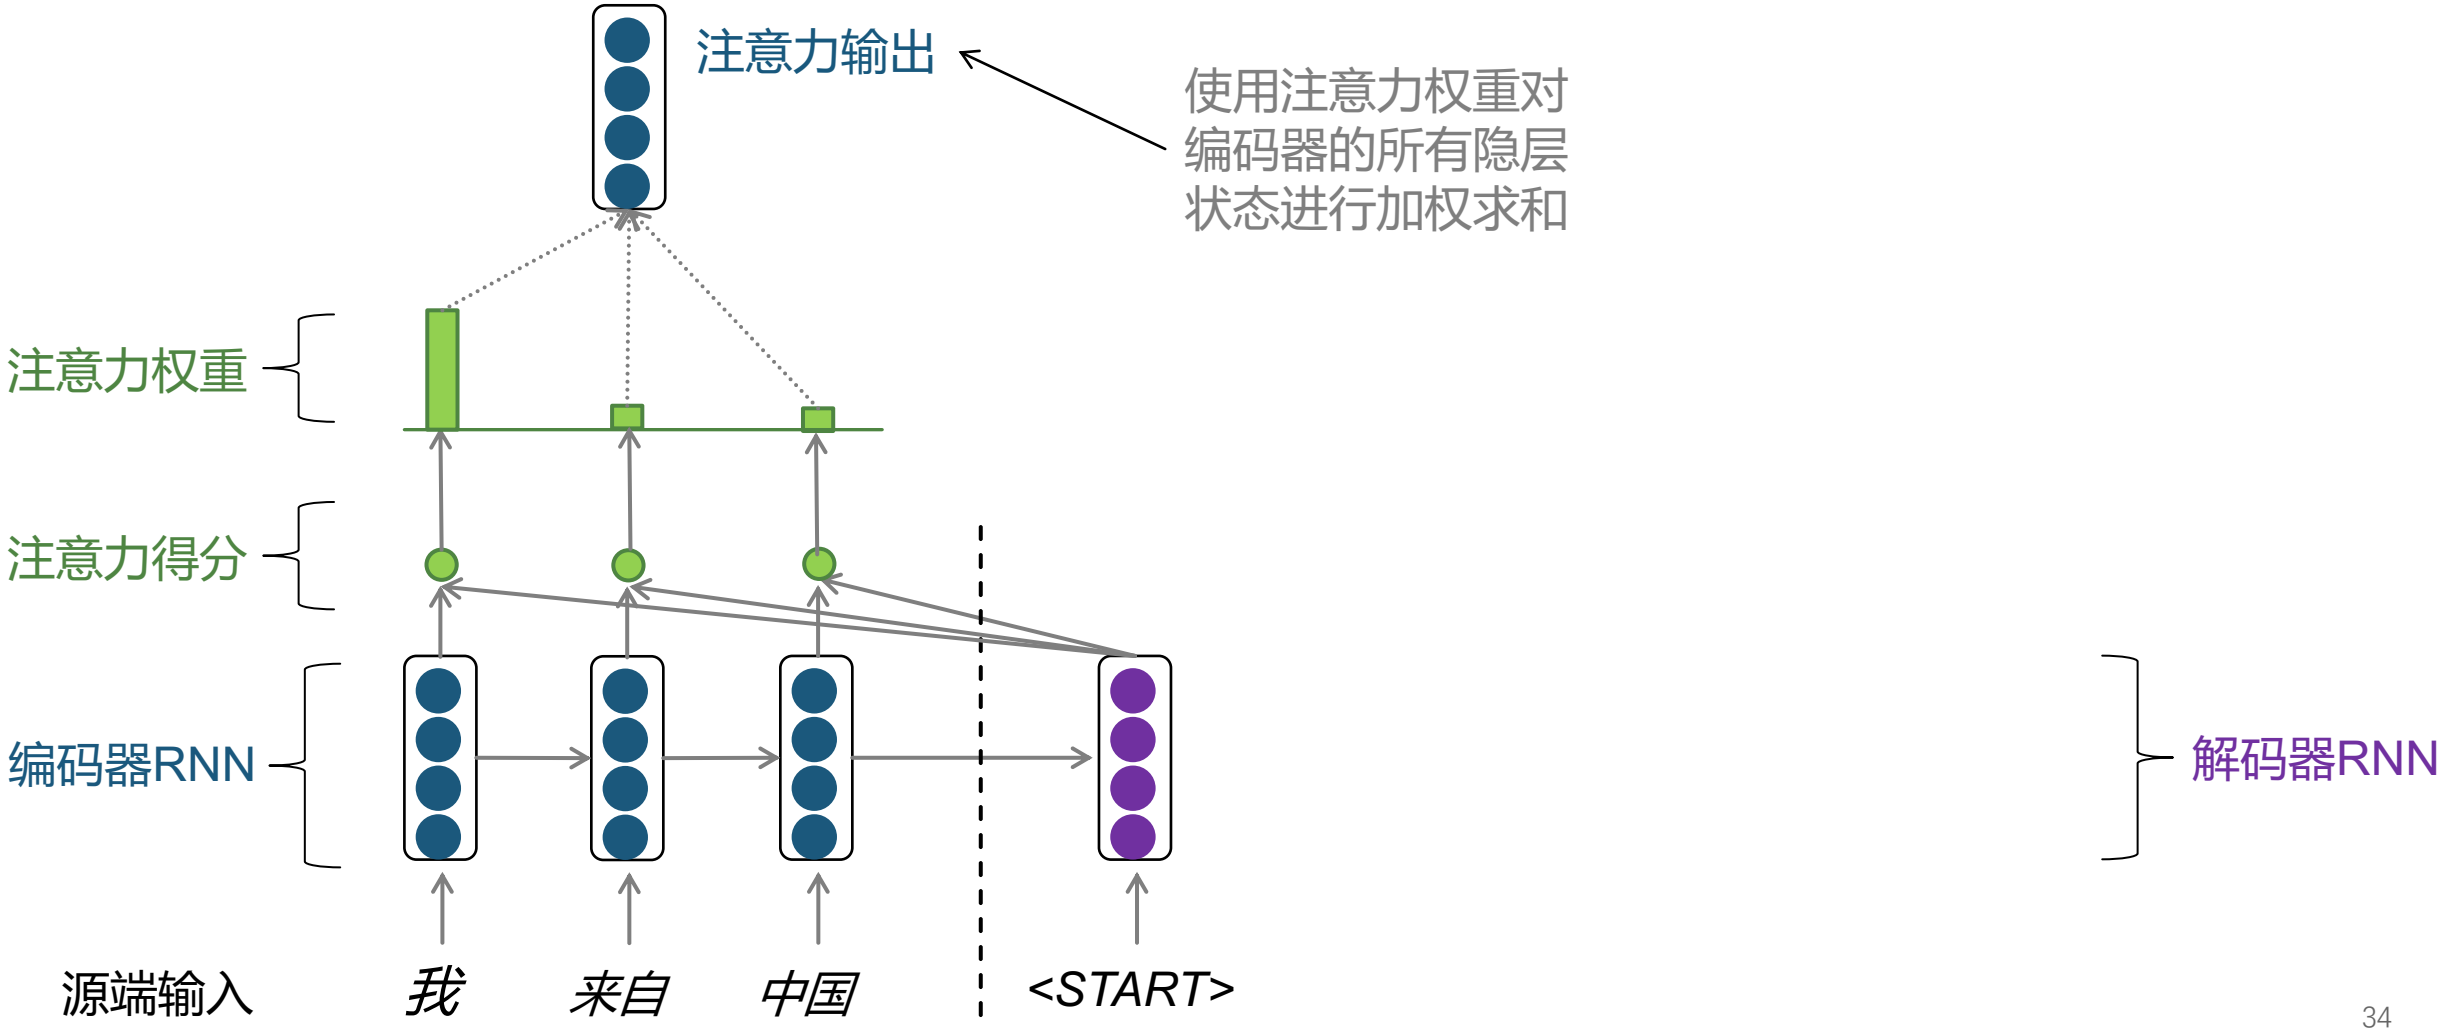

基于注意力机制的编码器-解码器框架

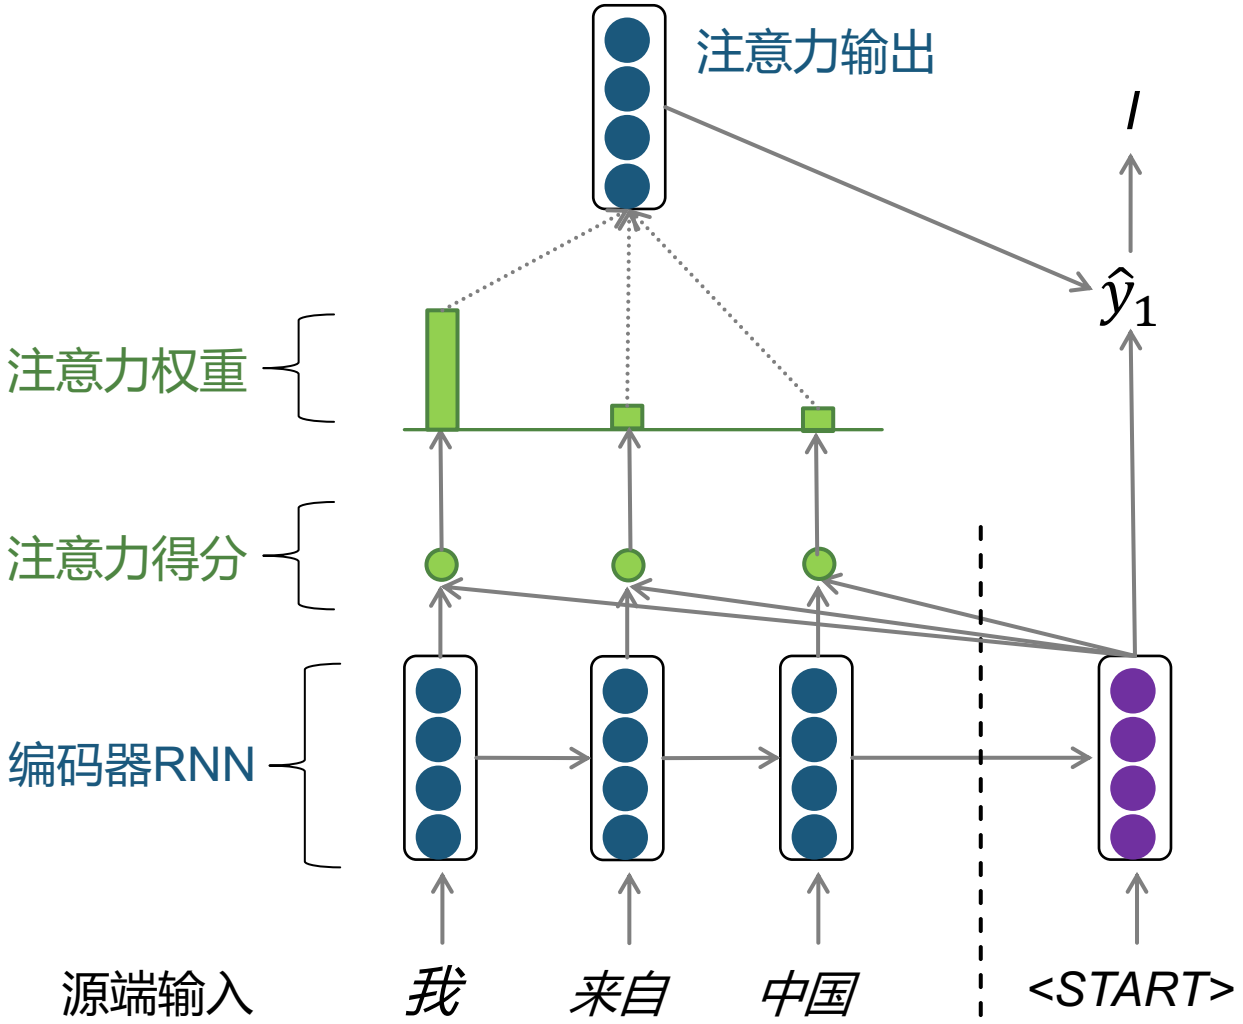

解码器RNN

基于注意力机制的编码器-解码器框架

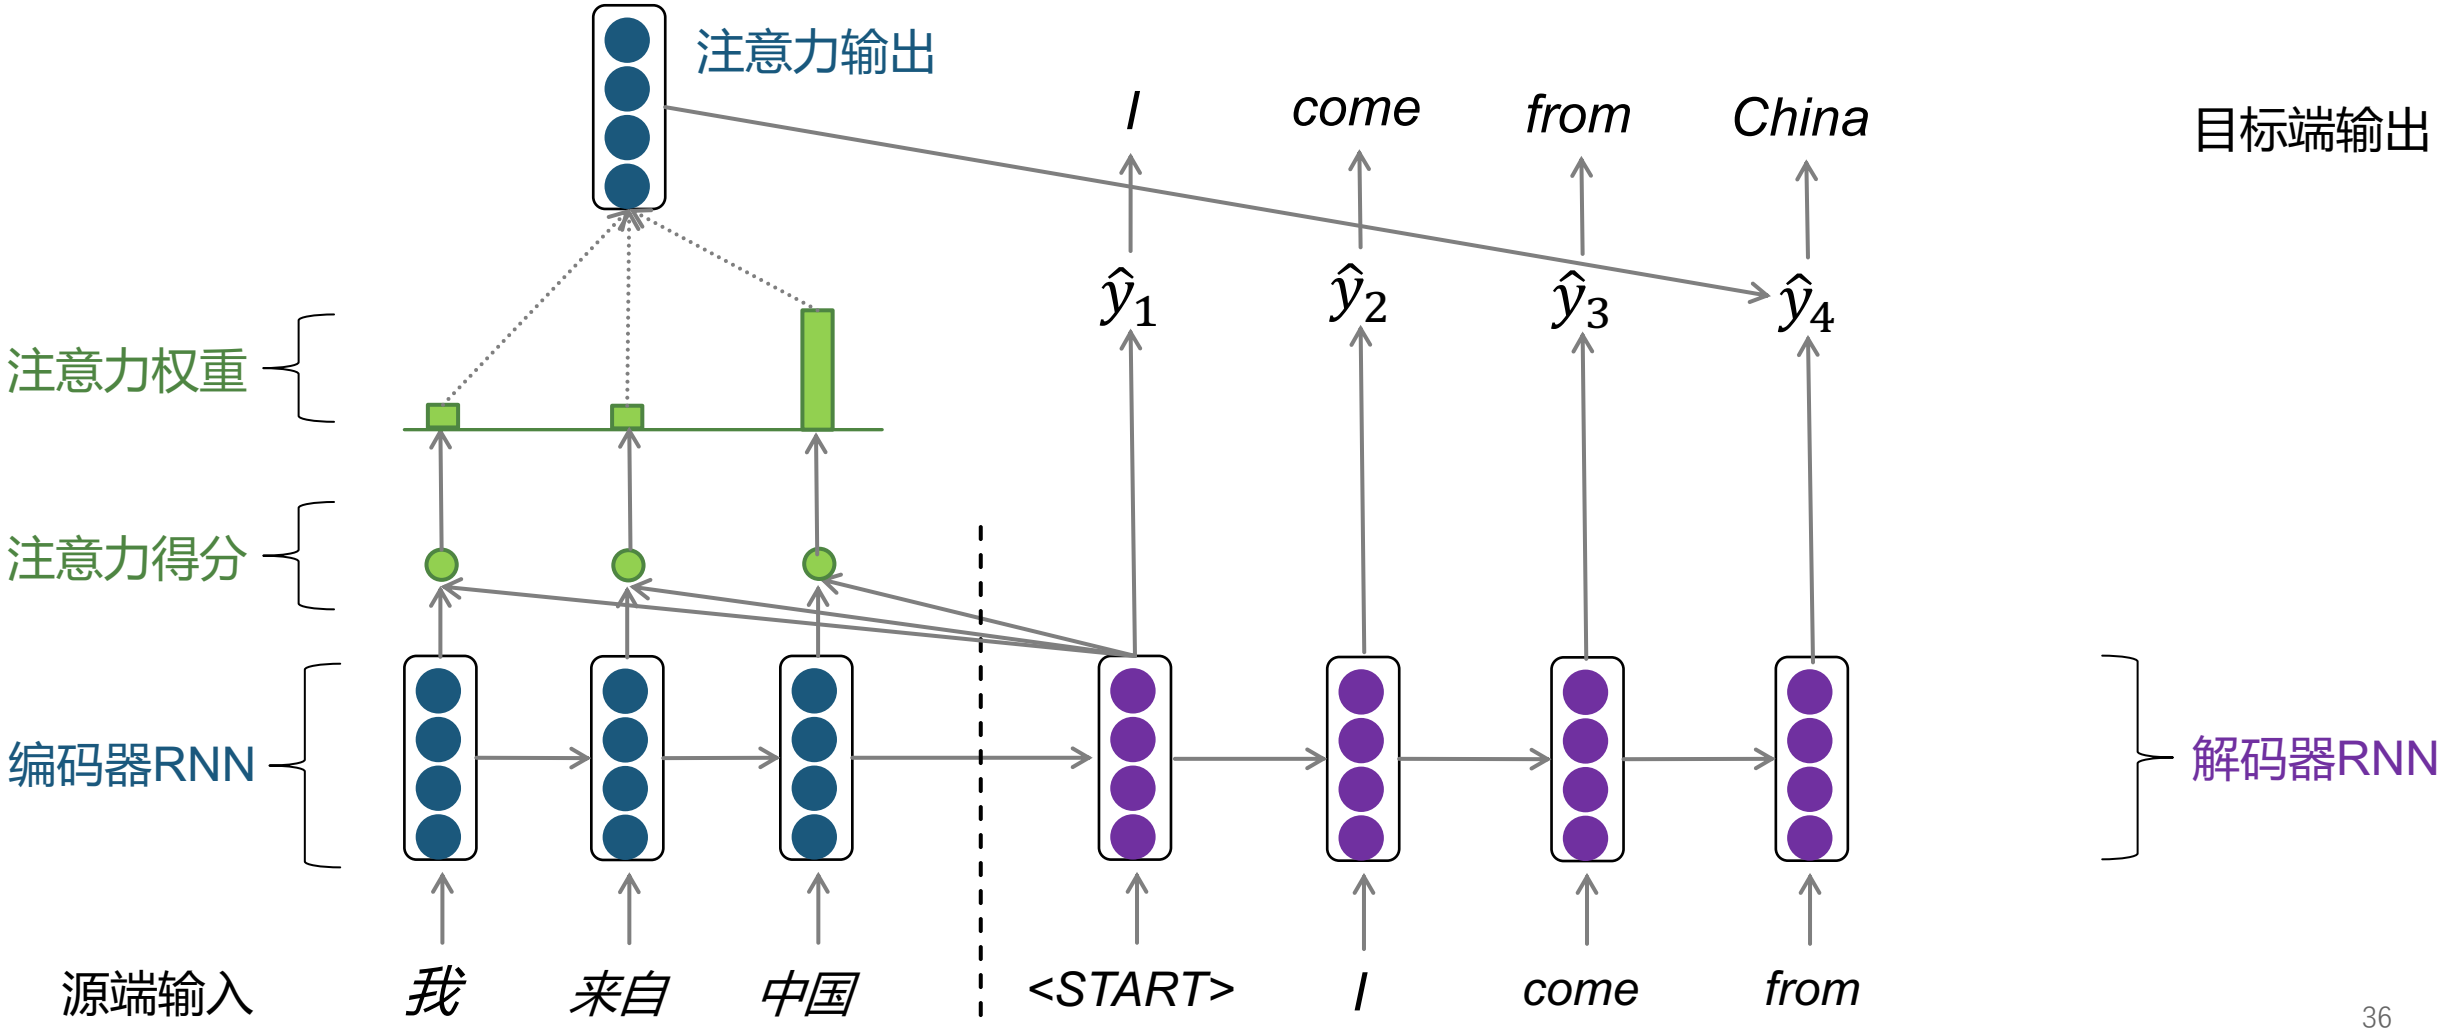

基于RNN的编码器-解码器问题

- 有限的信息交互距离
  - RNN能捕捉局部信息，但无法很好地解决长距离依赖关系（long-distance dependency）
  - 不能很好地建模序列中的非线性结构关系
- 无法并行
  - RNN的隐层状态具有序列依赖性
  - 时间消耗随序列长度的增加而增加

Attention

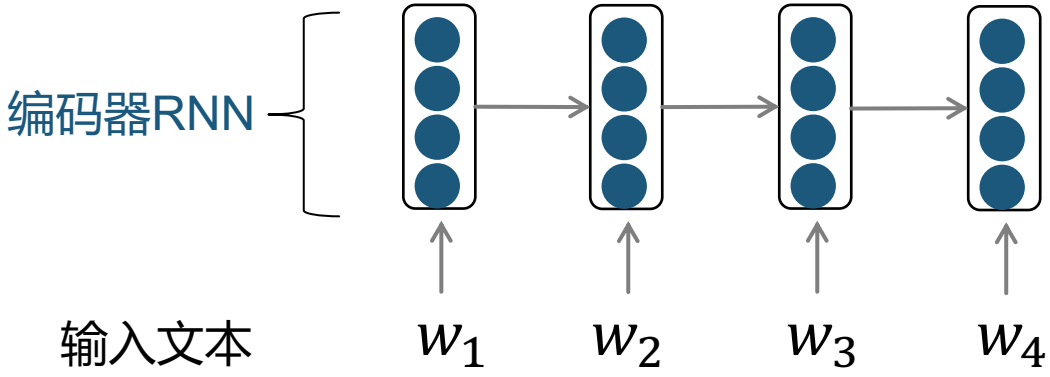

ATTENTION IS ALL YOU NEED

- Transformer [Vaswani et al., 2017]
  - 完全基于attention机制
  - 建模输入序列的全局依赖关系、并行计算
  - 一个基于attention机制的编码器
  - 一个基于attention机制的解码器

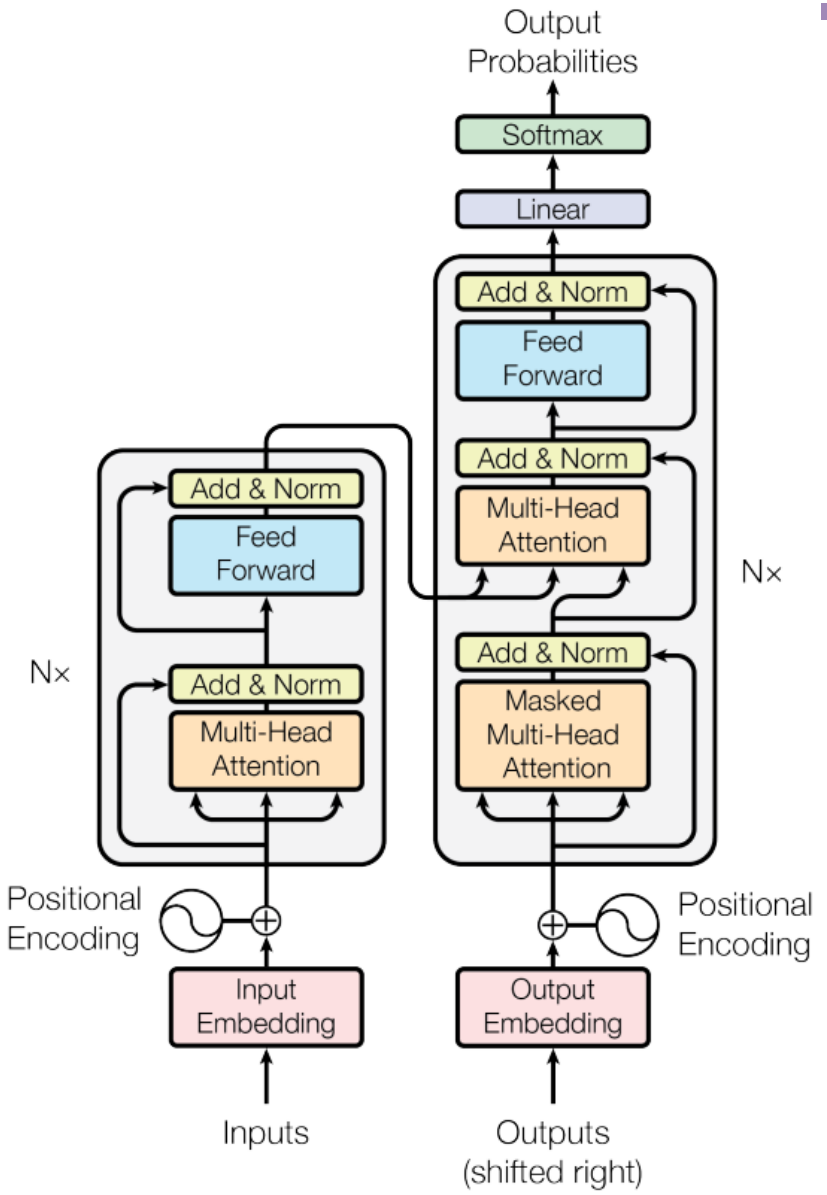

TRANSFORMER编码器

- 编码器
  - 输入编码+位置编码
  - 多头注意力机制
  - 残差连接&层正则
  - 前馈神经网络
  - 残差连接&层正则

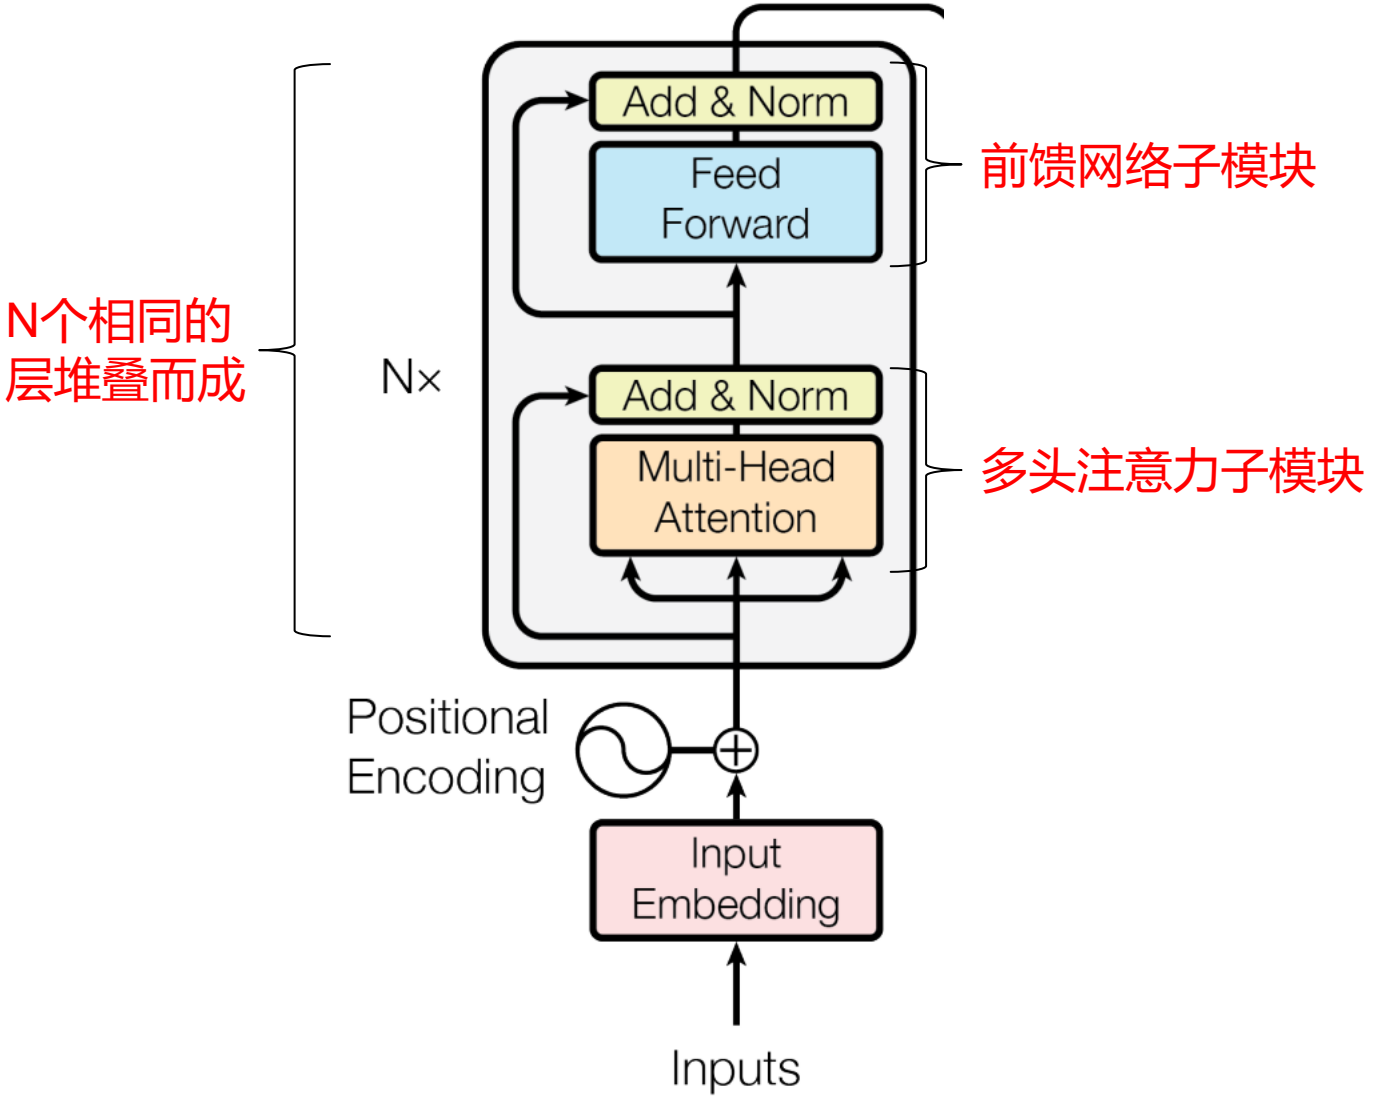

TRANSFORMER解码器

- Cross Attention
  - 解码时需要关注源端信息
- Masked Attention
  - 解码时（训练）不应该看到未来的信息

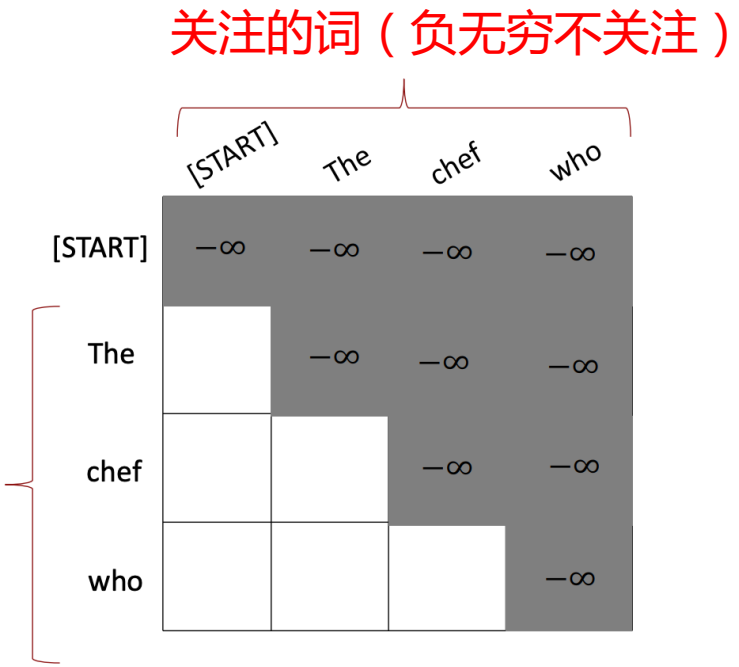

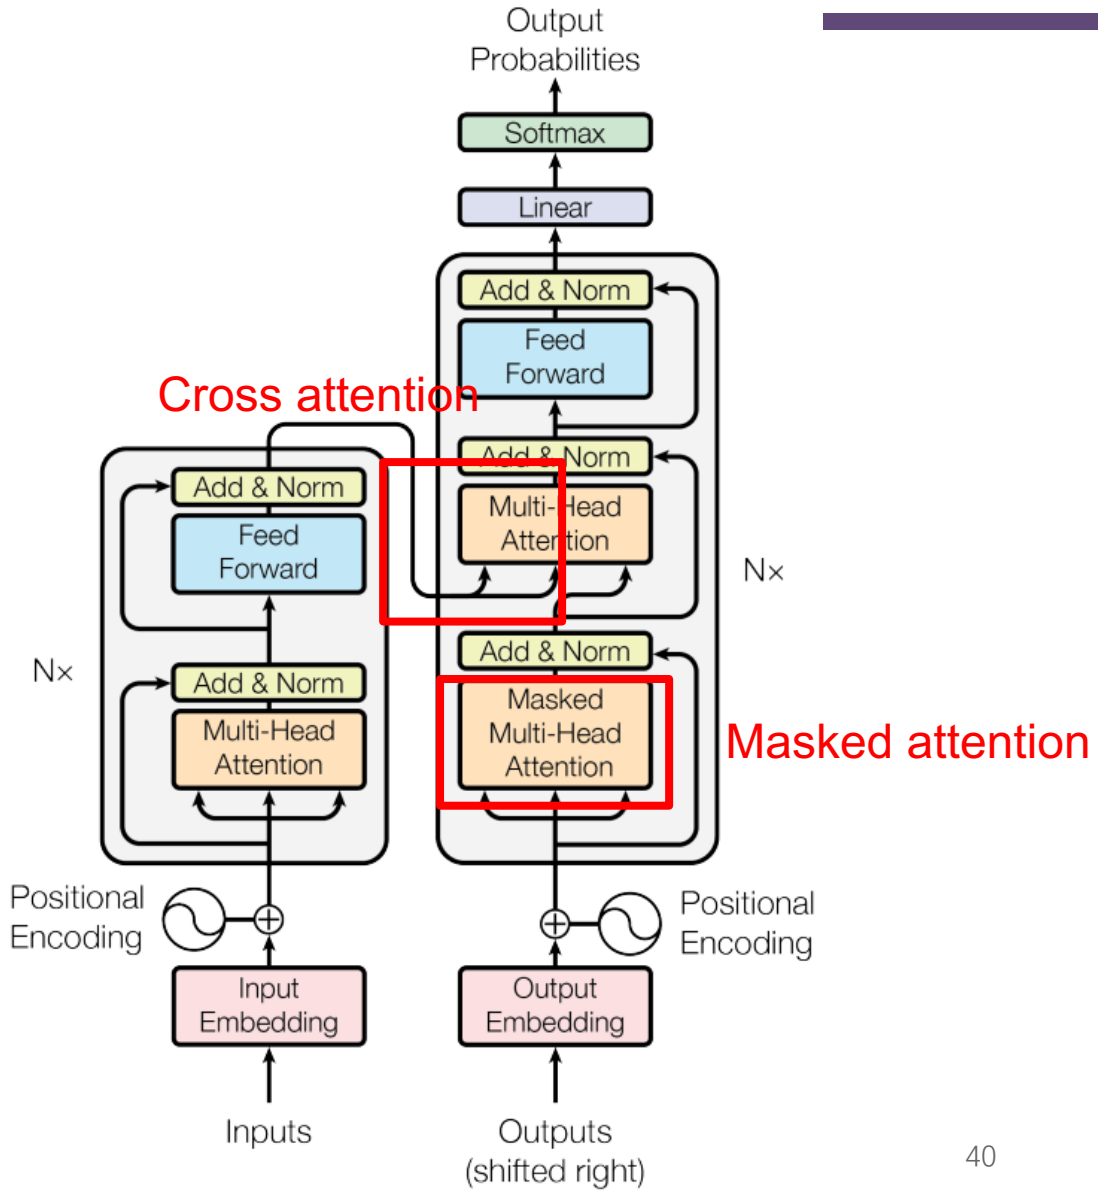

TRANSFORMER翻译示例

- Transformer按时间展开

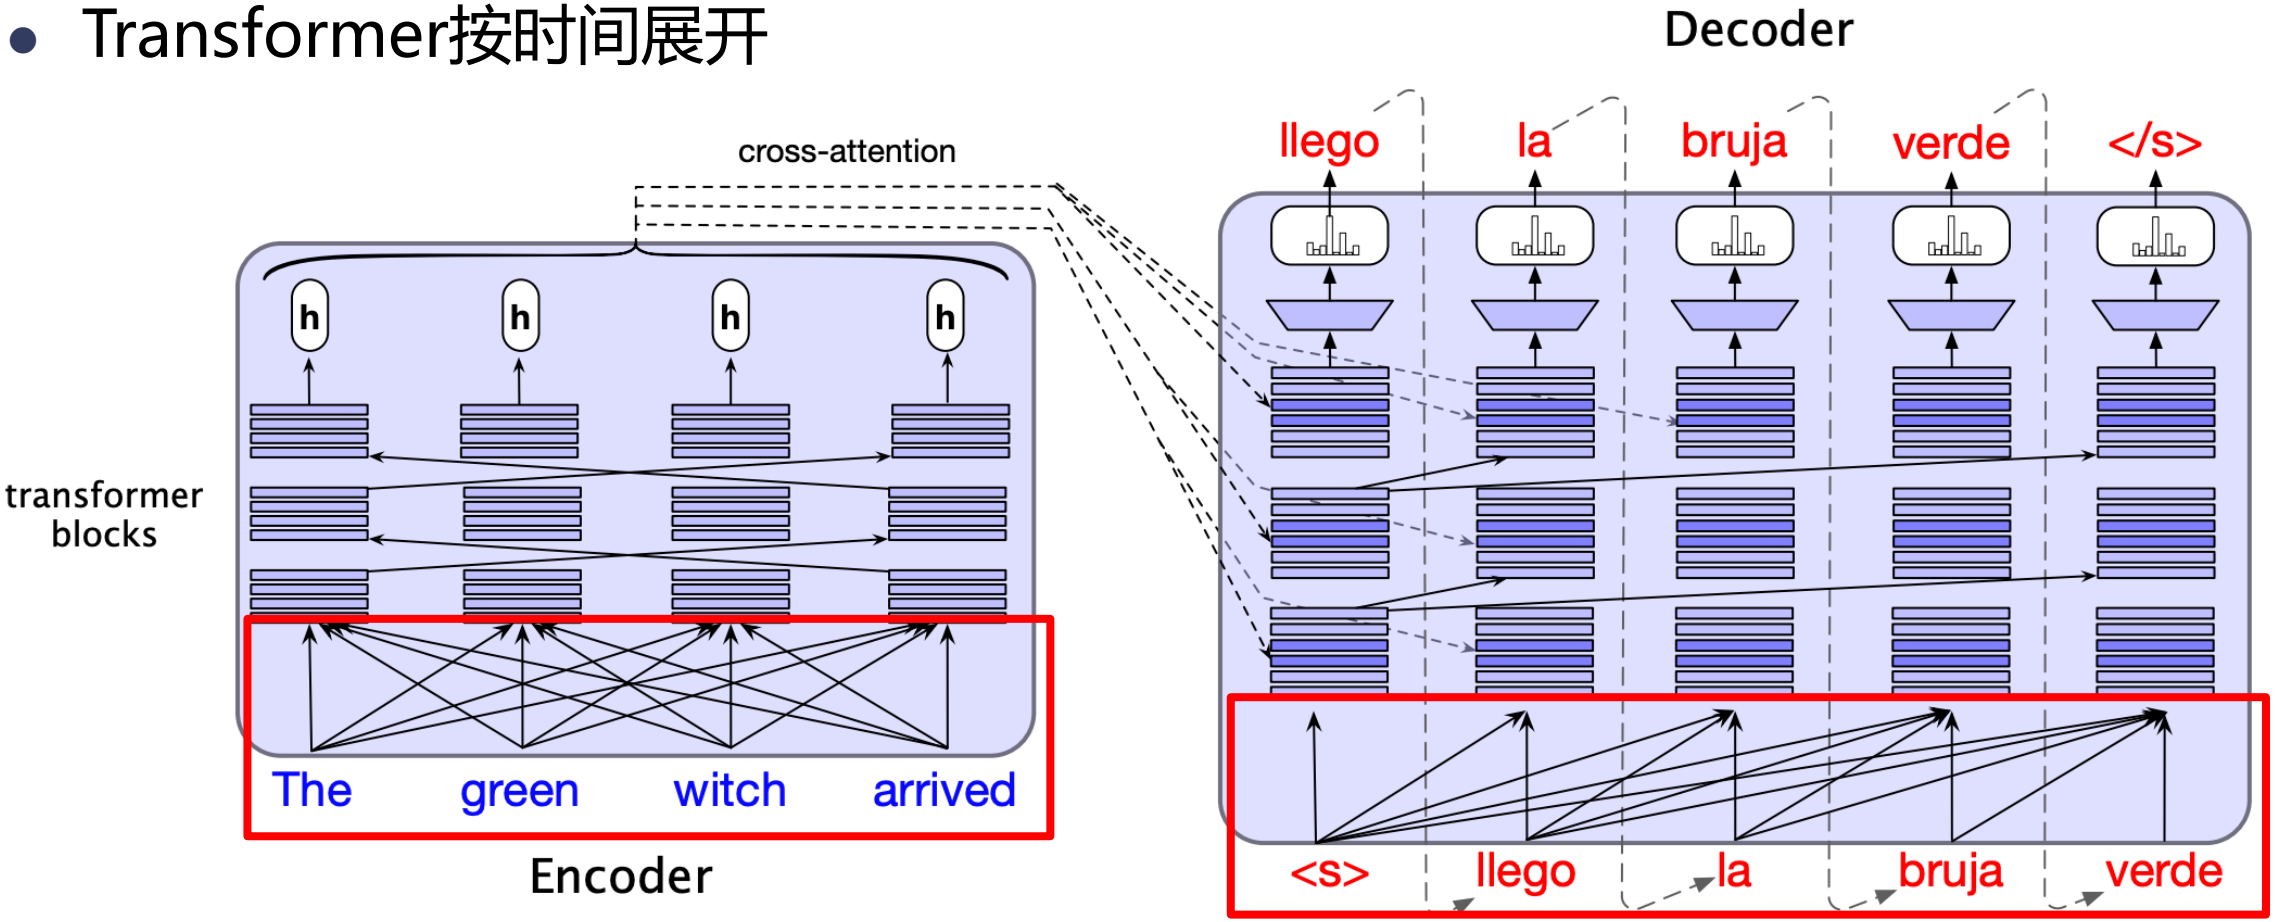

参数训练

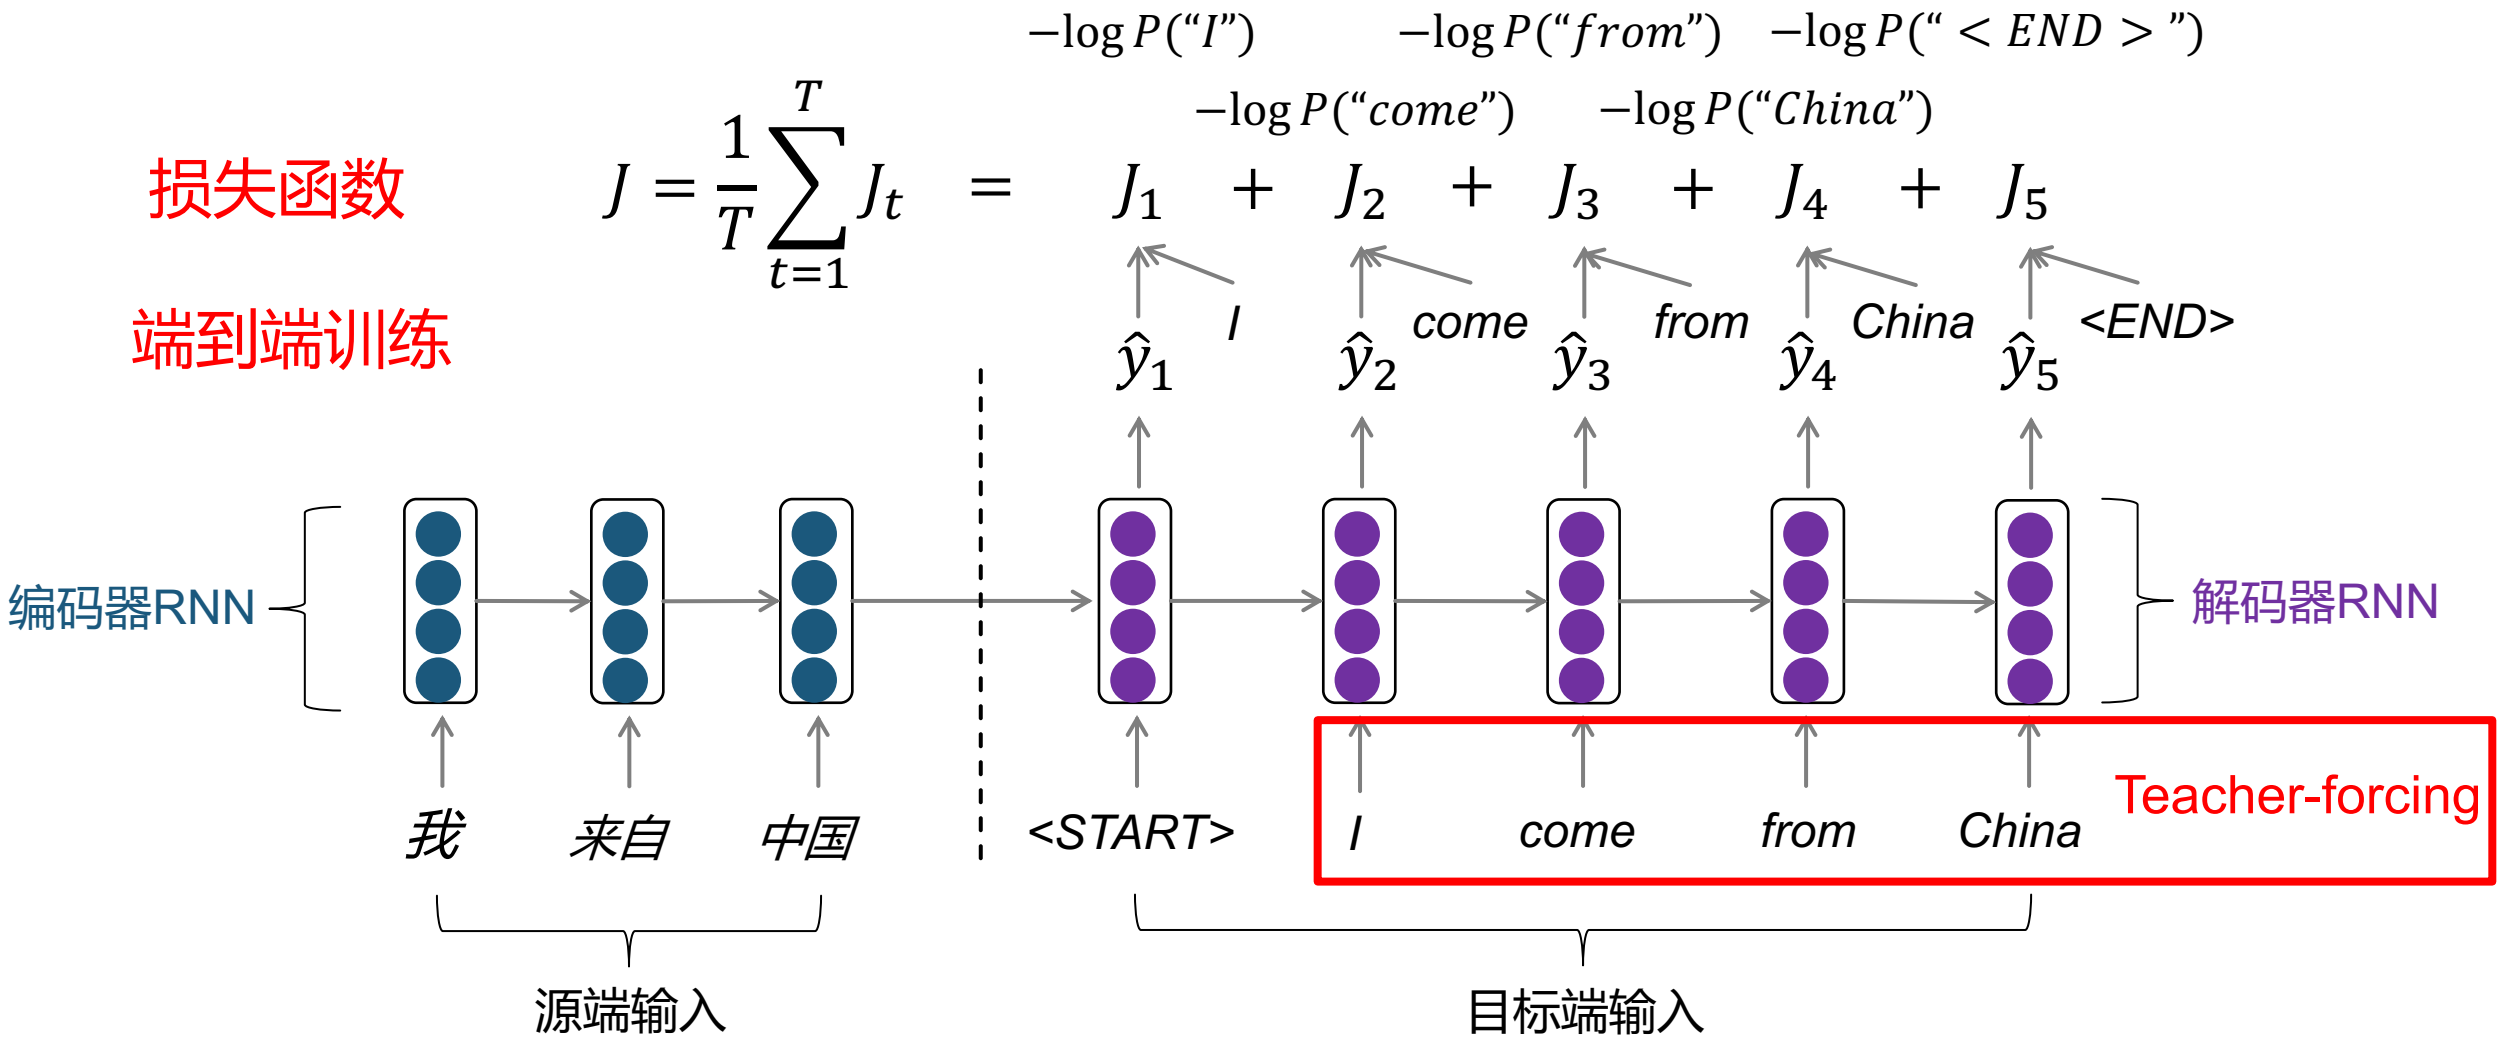
$-\log P(\text{“}I\text{”})$
$-\log P(\text{“}from\text{”})$
$-\log P(\text{“}<END>\text{”})$
$-\log P(\text{“}come\text{”})$
$-\log P(\text{“}China\text{”})$
损失函数
$J = \frac{1}{T}\sum_{t=1}^{T} J_t = J_1 + J_2 + J_3 + J_4 + J_5$
端到端训练
$\hat{y}_1$ I $\hat{y}_2$ come $\hat{y}_3$ from $\hat{y}_4$ China $\hat{y}_5$ <END>
编码器RNN
解码器RNN
我 来自 中国
<START> I come from China
Teacher-forcing
源端输入
目标端输入

贪心解码（GREEDY SEARCH）

- 解码时，每个时刻从解码器取出概率最大的词（argmax）作为预测结果

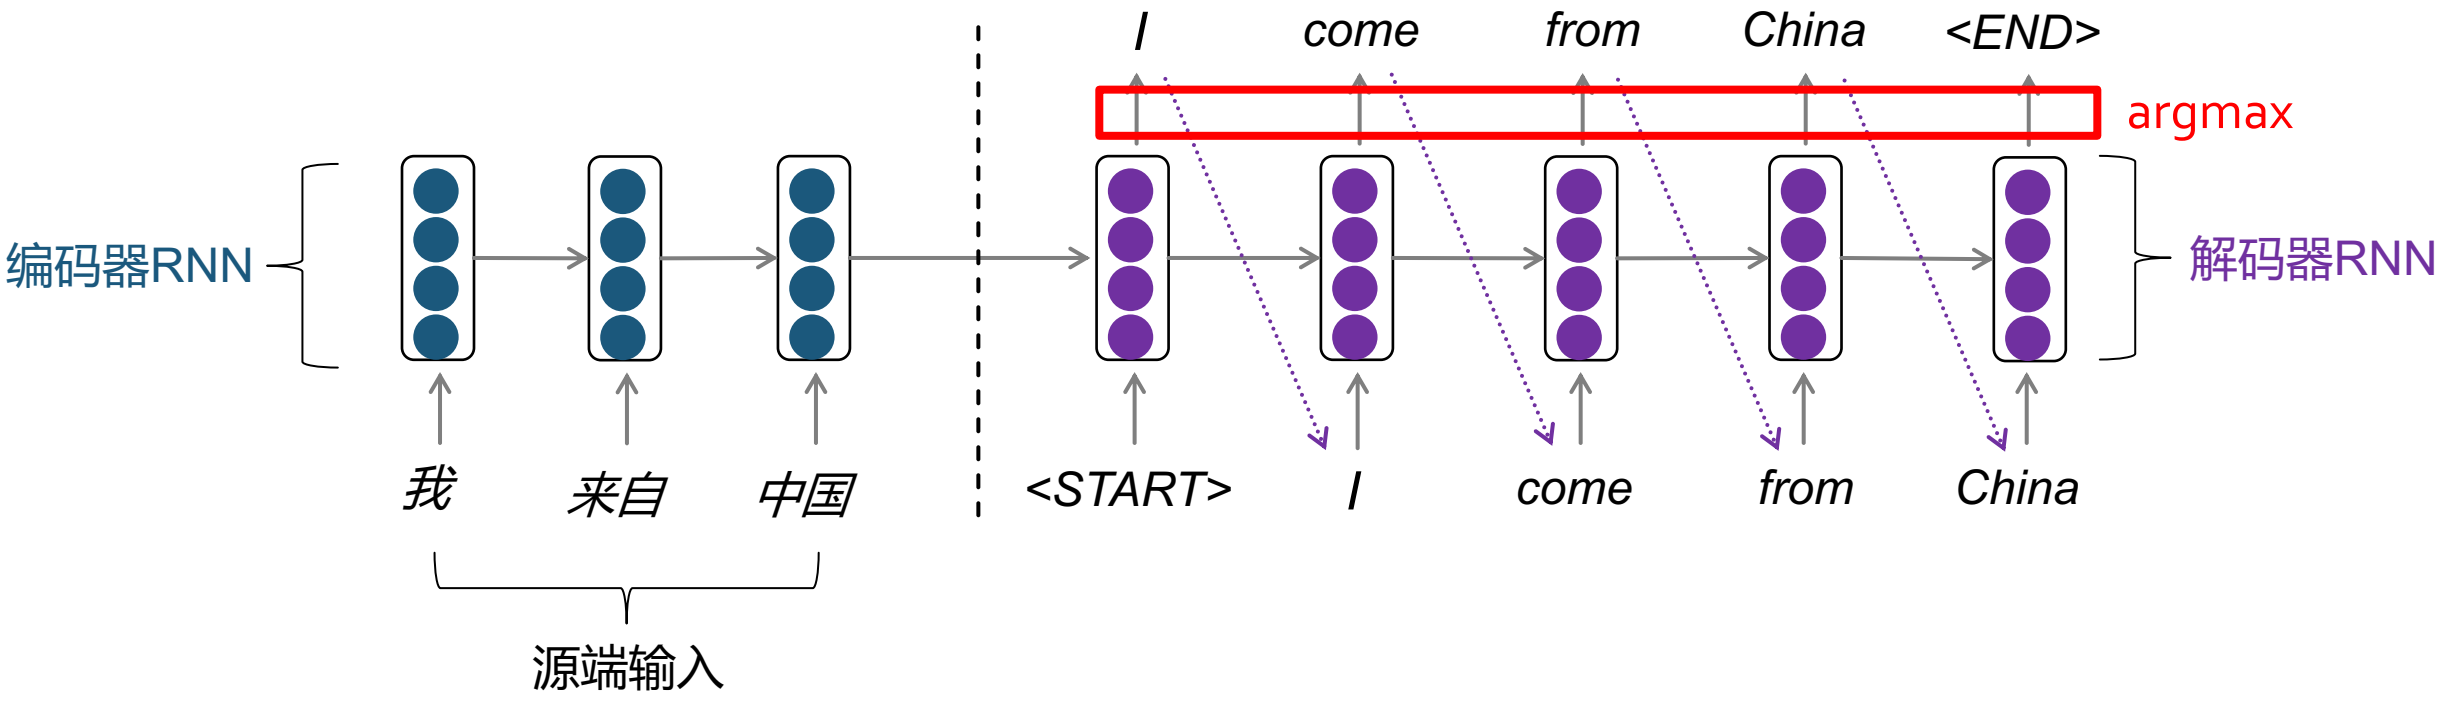

贪心解码的问题

- 某一时刻的错误翻译会影响后续所有翻译，因此不一定能解码出全局最佳（译文概率最大）的译文

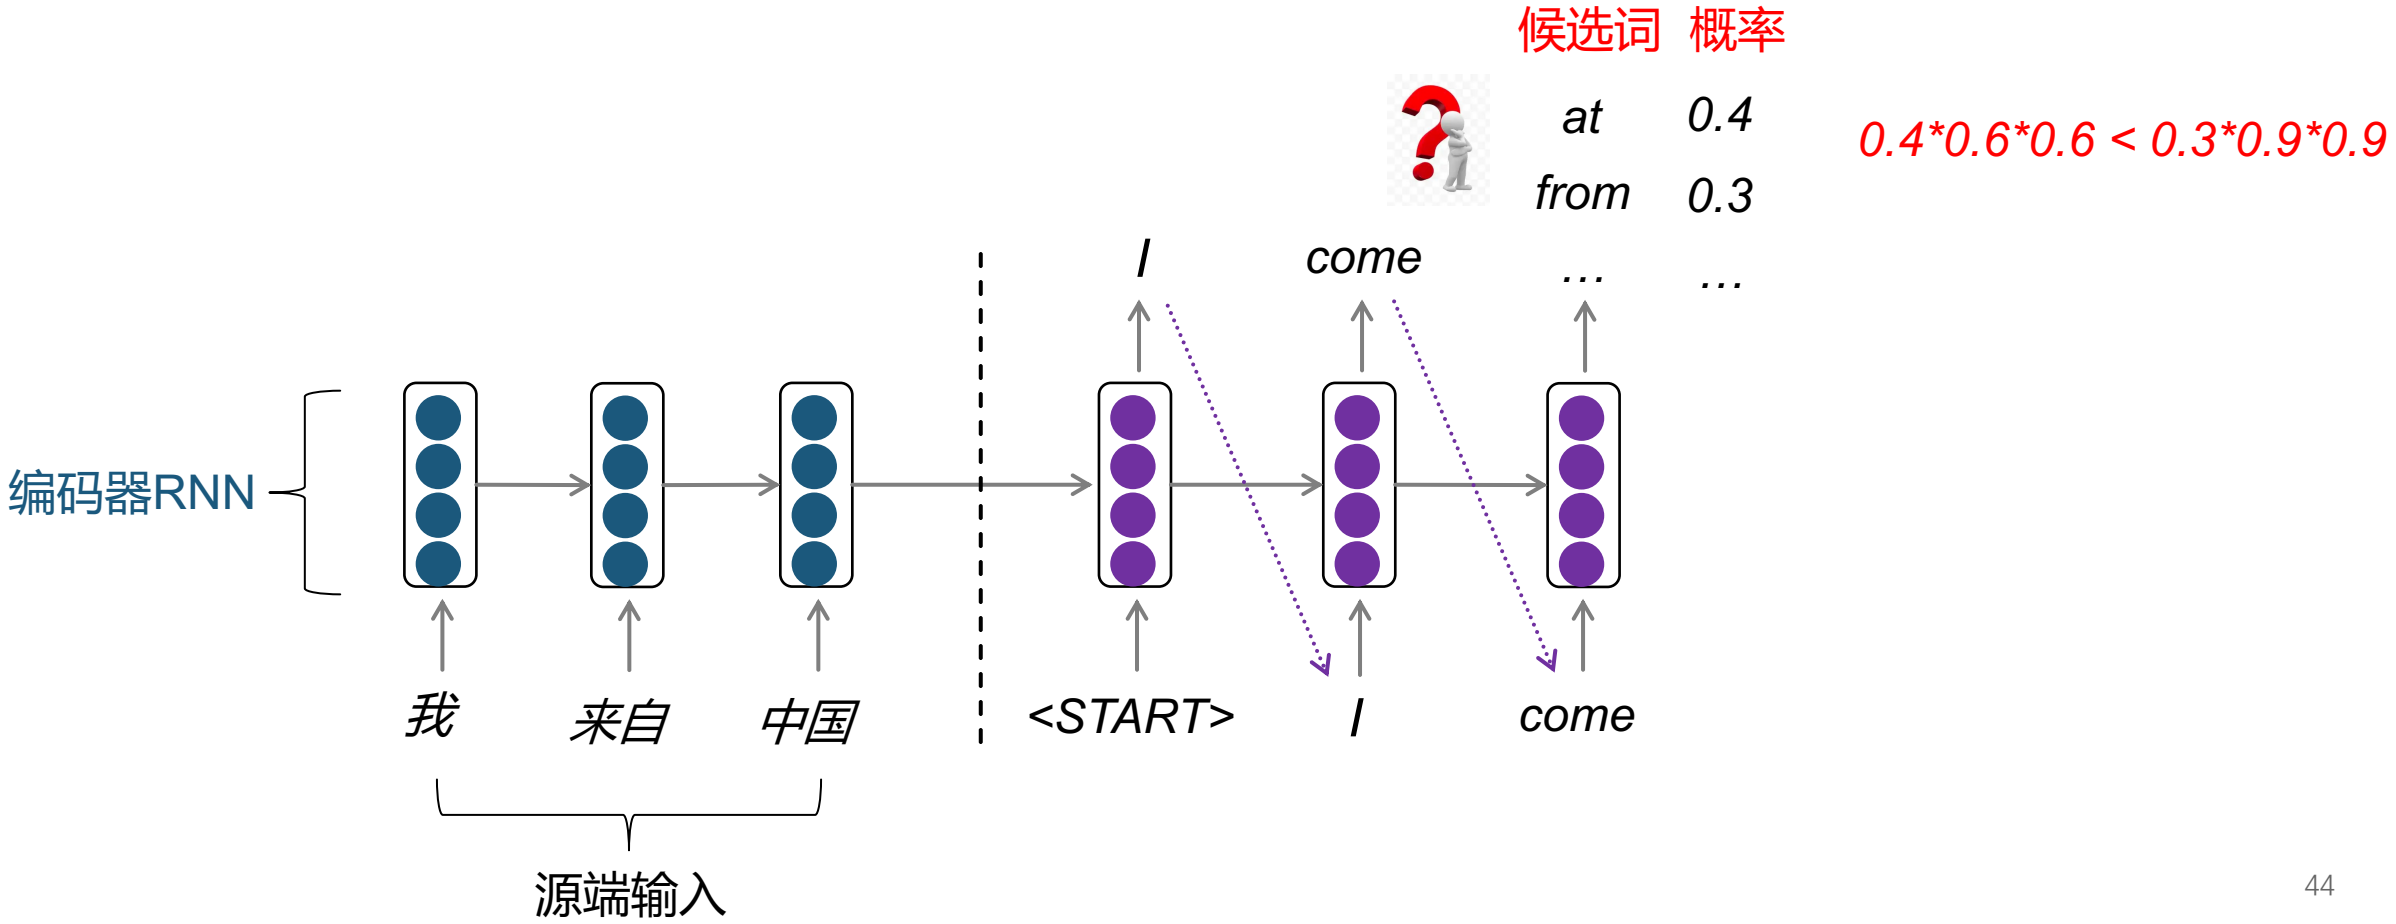

枚举解码

- 翻译目标：对于给定的源语言x，解码出对应的目标语言y= $\text{argmax}_y P(y|x)$

$$P(y|x) = P(y_1|x)P(y_2|y_1,x)P(y_1|x)\dots P(y_T|y_1,\dots,y_{T-1},x)$$

$$= \prod_{t=1}^{T} P(y_t|y_1,\dots,y_{t-1},x)$$

- 解码时枚举所有的翻译结果y
  - 复杂度$O(V^T)$，V为目标语言的词表大小，T为生成译文的长度
  - 极其耗时

柱搜索解码（BEAM SEARCH）

- 在贪心搜索基础上扩大搜索空间，从而更有可能解码出全局最优的译文
- 核心思想：在t时刻，保留k个概率最大的翻译结果（k为beam size）
  - 相比于枚举，极大提高搜索效率
  - 并不能保证一定解码出最优的译文

- 打分函数：

$$score(y_1, \dots, y_t) = \log P(y_1, \dots, y_t | x) = \sum_{i=1}^{t} \log P(y_i | y_1, \dots, y_{i-1}, x)$$

越大越好

柱搜索解码样例

Beam size=2

$$score(y_1, \dots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \dots, y_{i-1}, x)$$

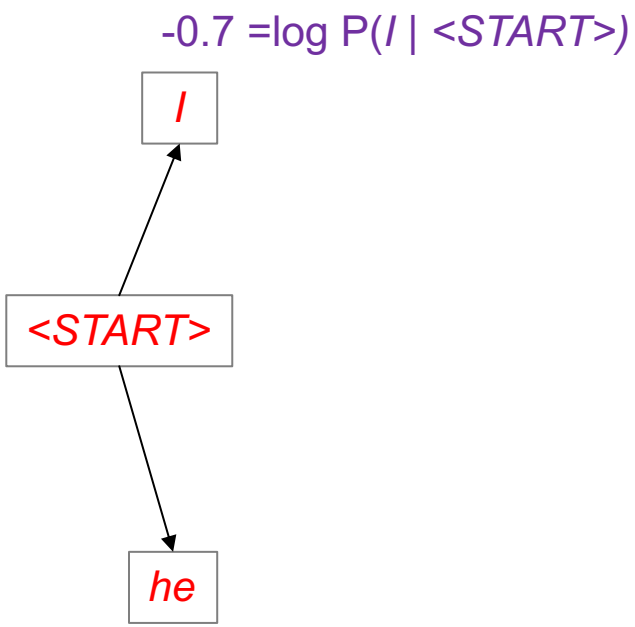

计算打分保留打分最高的2个词

柱搜索解码样例

Beam size=2

$$score(y_1, \dots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \dots, y_{i-1}, x)$$

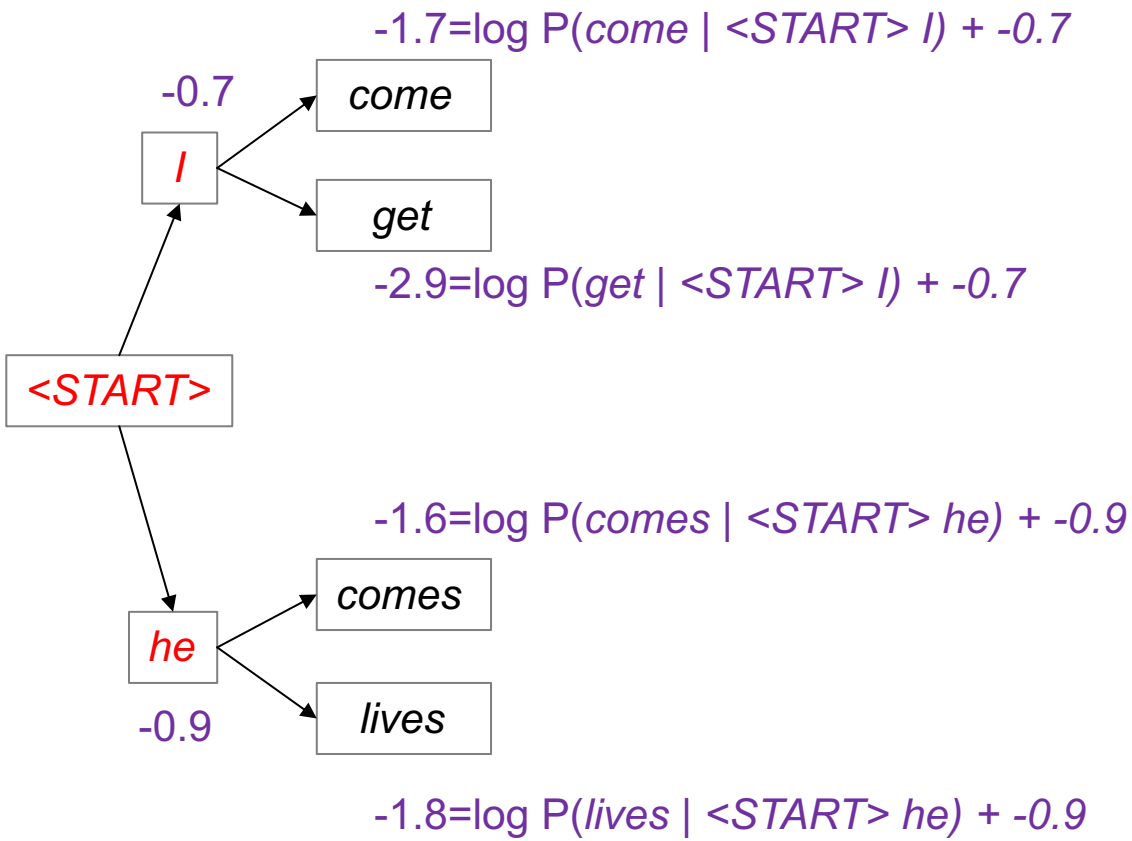

柱搜索解码样例

Beam size=2

$$score(y_1, \ldots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \ldots, y_{i-1}, x)$$

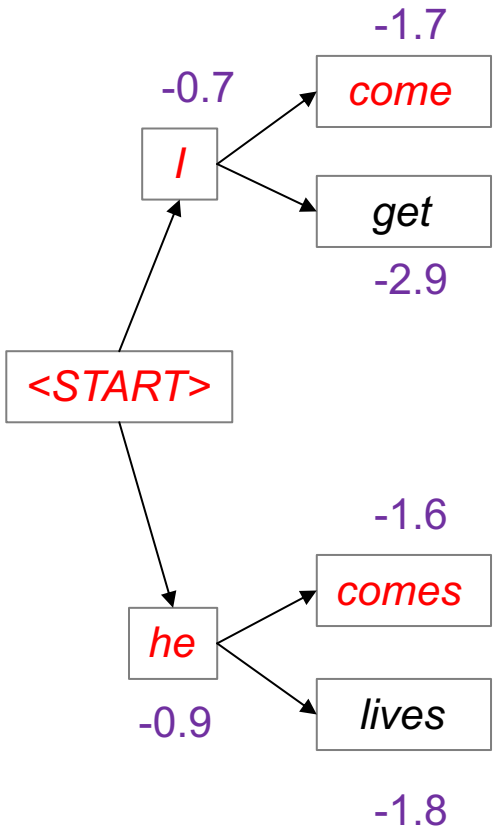

柱搜索解码样例

Beam size=2

$$score(y_1, \ldots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \ldots, y_{i-1}, x)$$

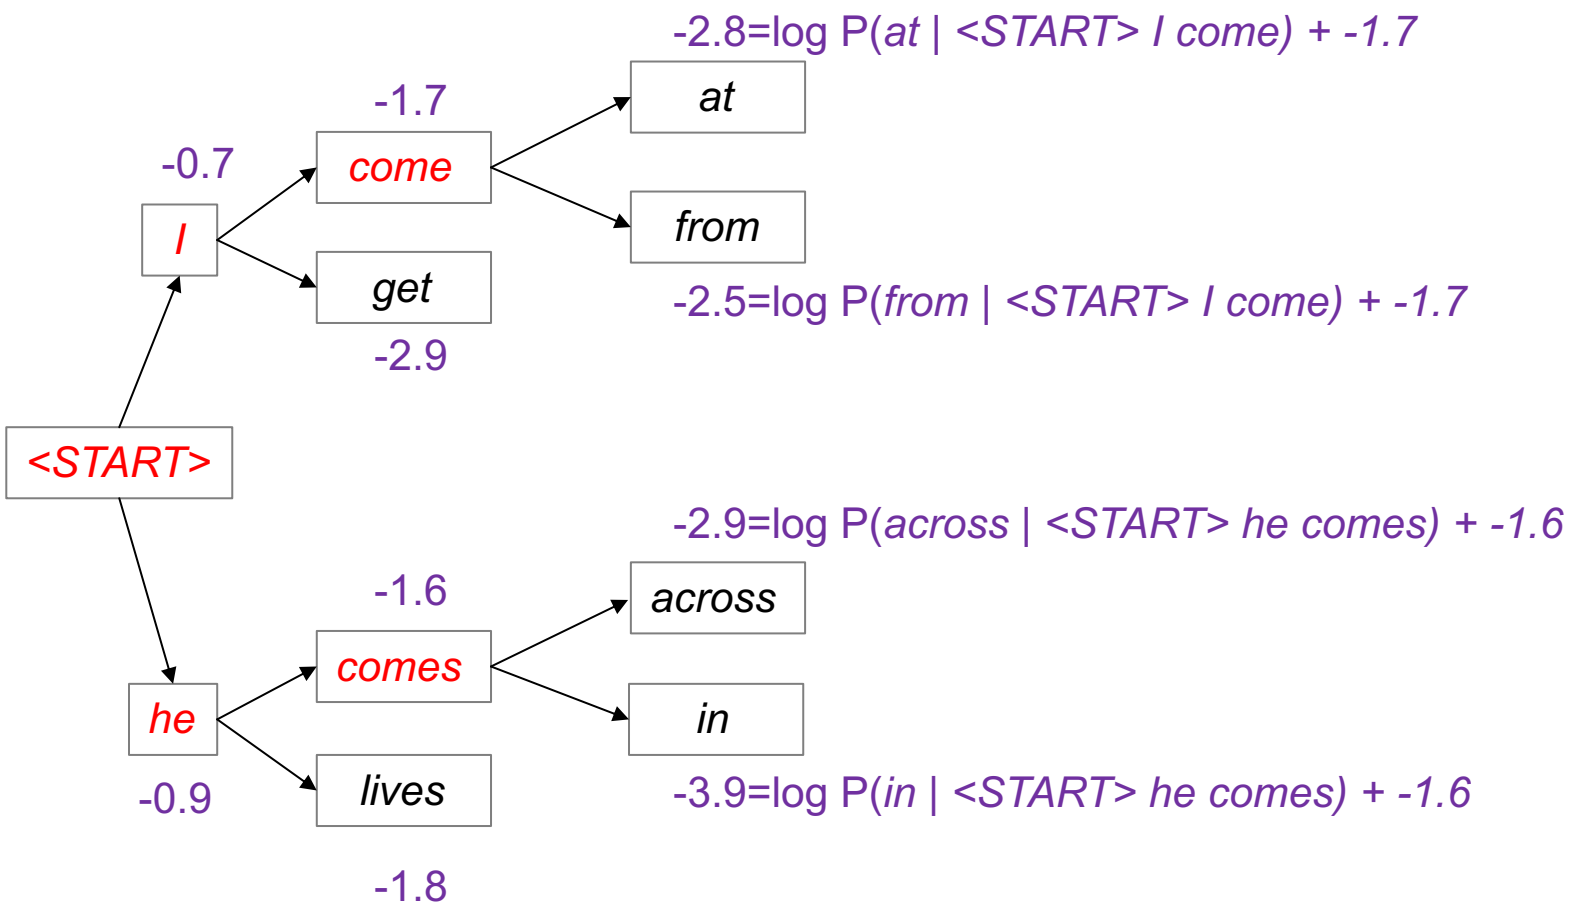

柱搜索解码样例

Beam size=2

$$score(y_1, \dots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \dots, y_{i-1}, x)$$

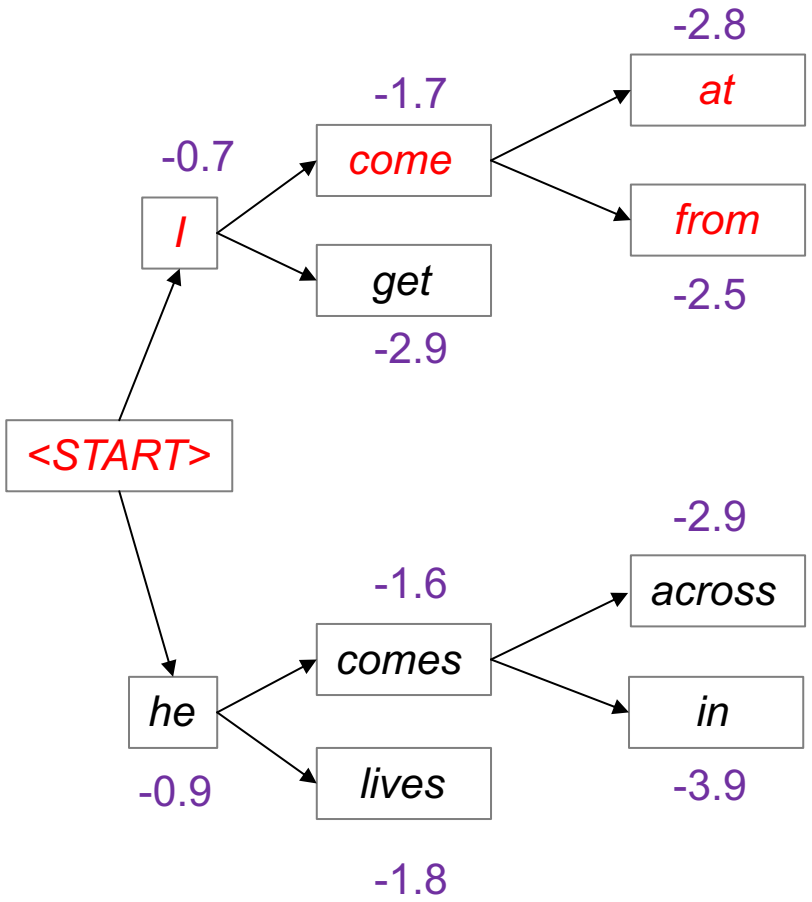

柱搜索解码样例

Beam size=2

$$score(y_1, \dots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \dots, y_{i-1}, x)$$

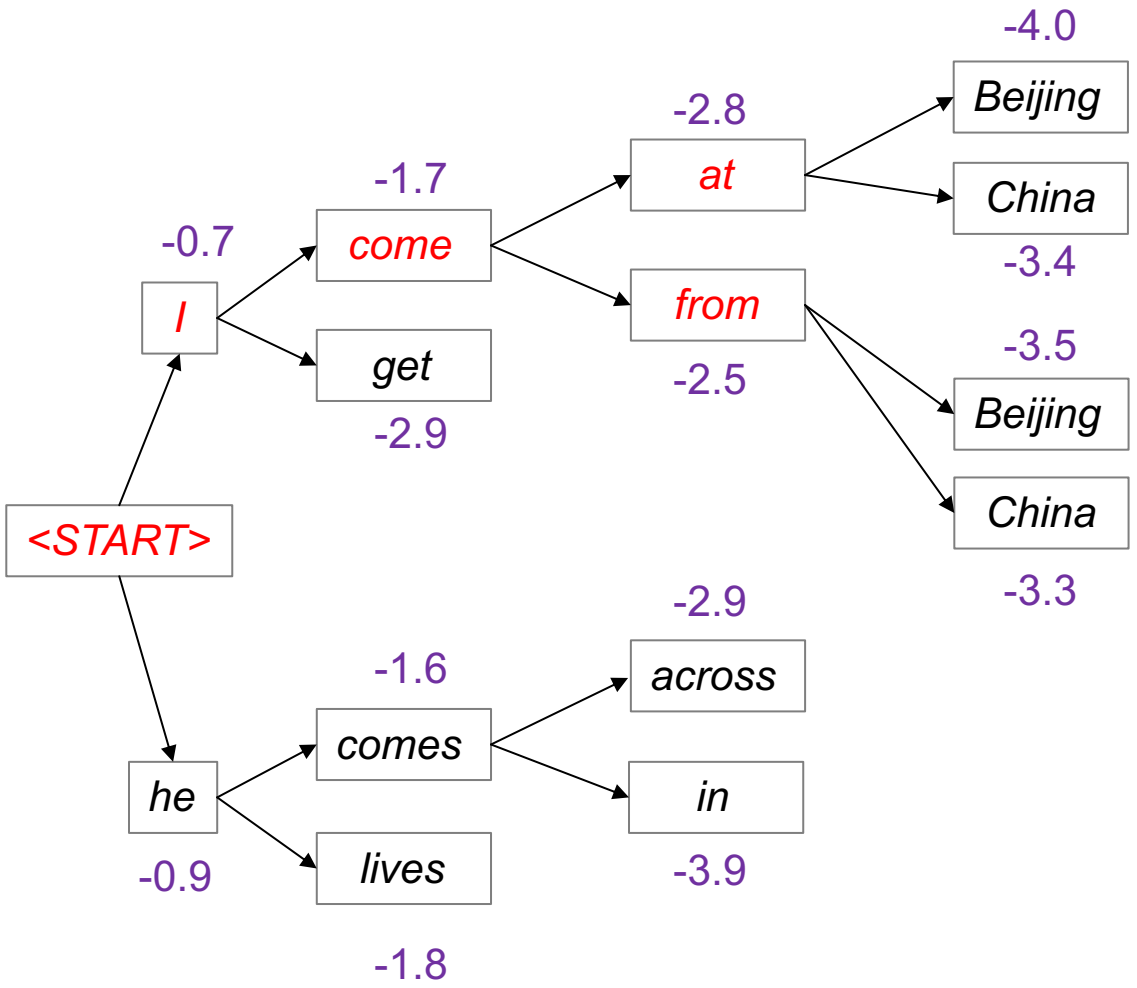

柱搜索解码样例

Beam size=2

$$score(y_1, \ldots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \ldots, y_{i-1}, x)$$

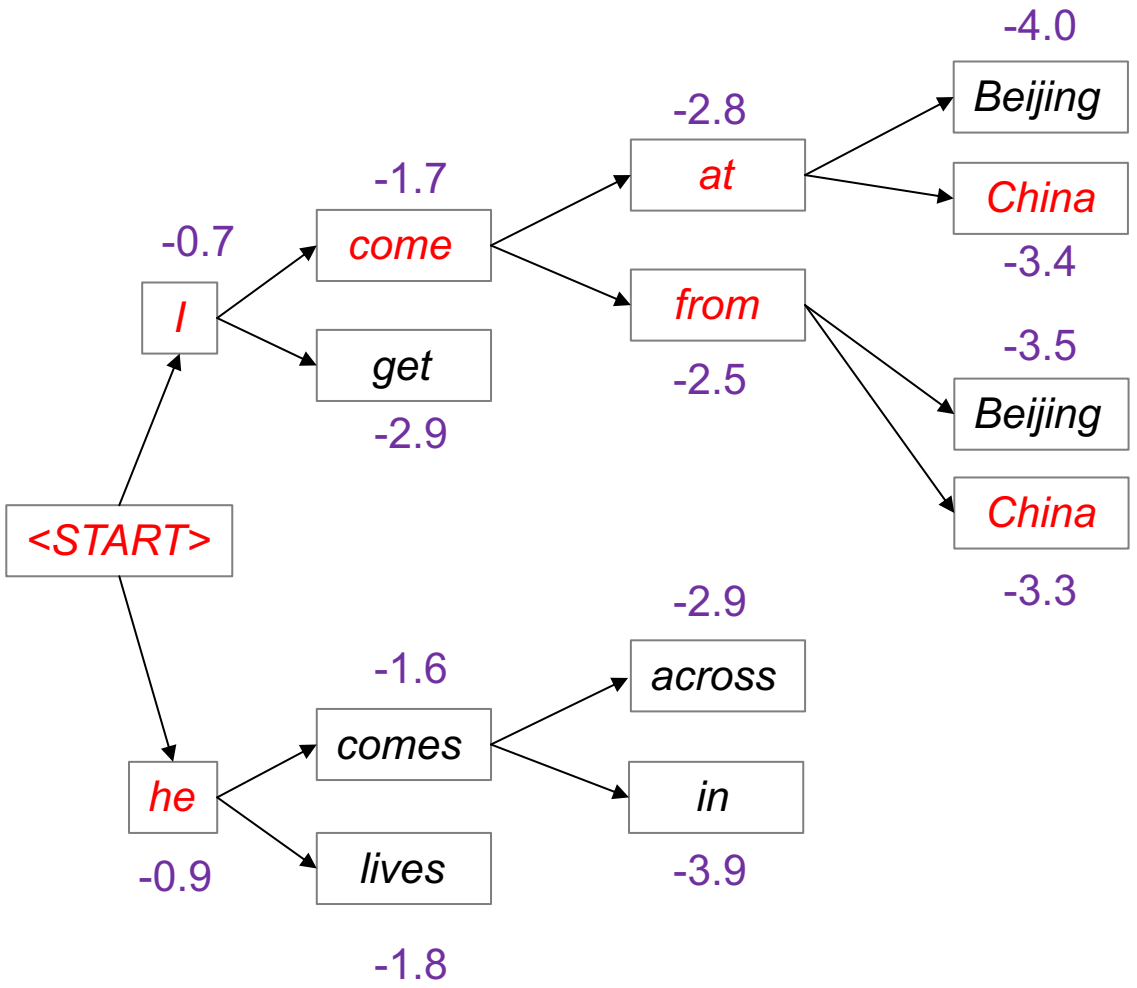

柱搜索解码样例

Beam size=2

$$score(y_1, \dots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \dots, y_{i-1}, x)$$

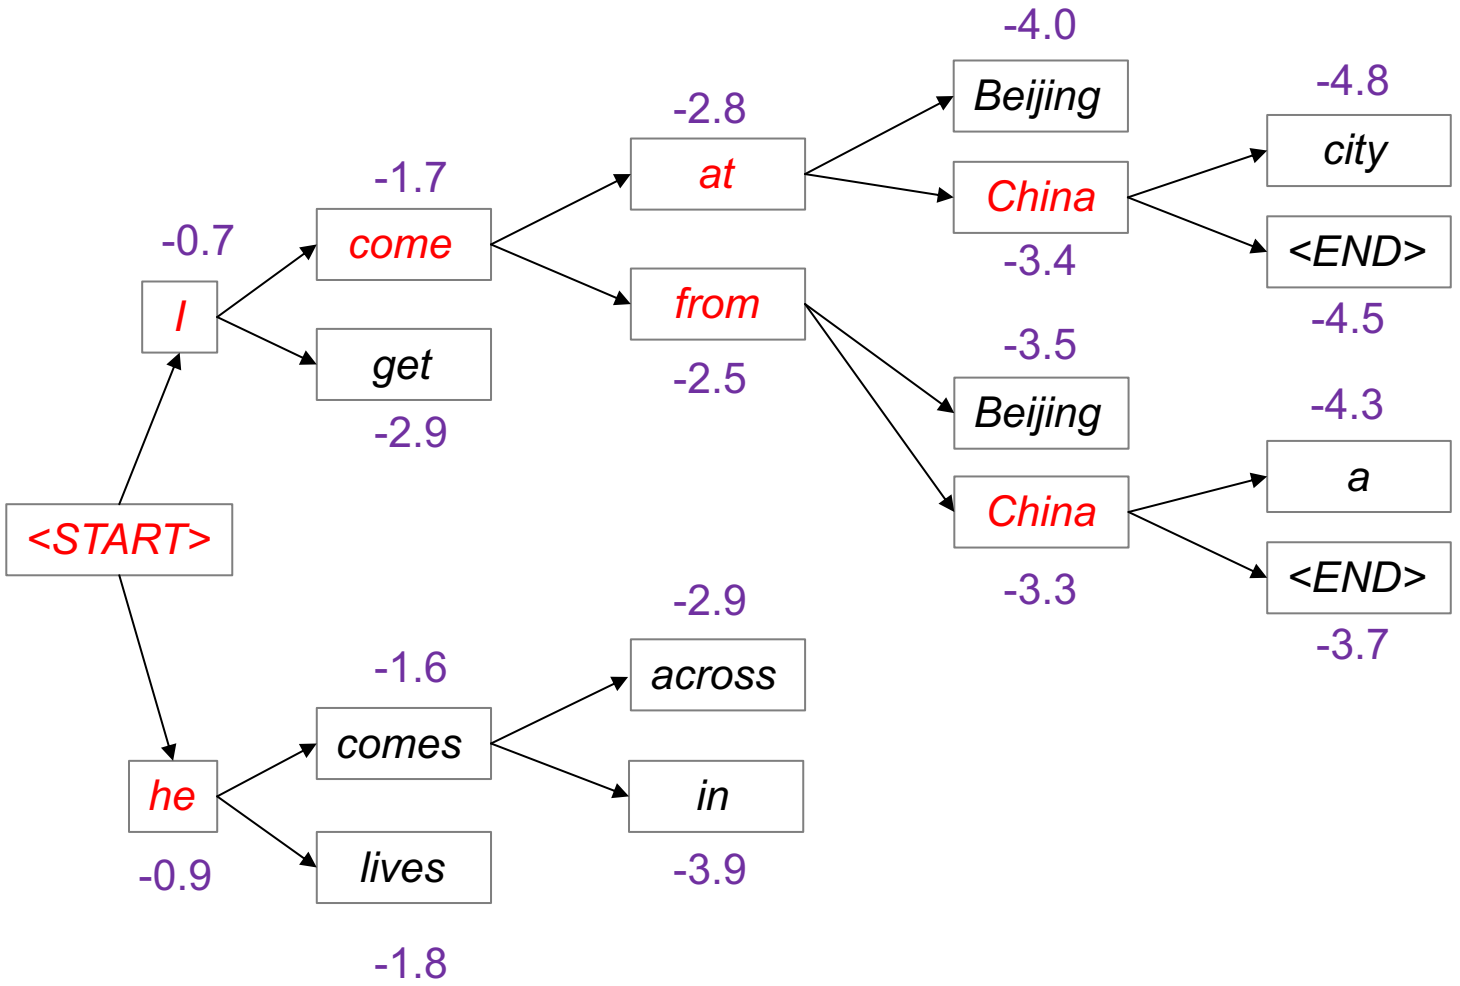

柱搜索解码样例

Beam size=2

$$score(y_1, \ldots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \ldots, y_{i-1}, x)$$

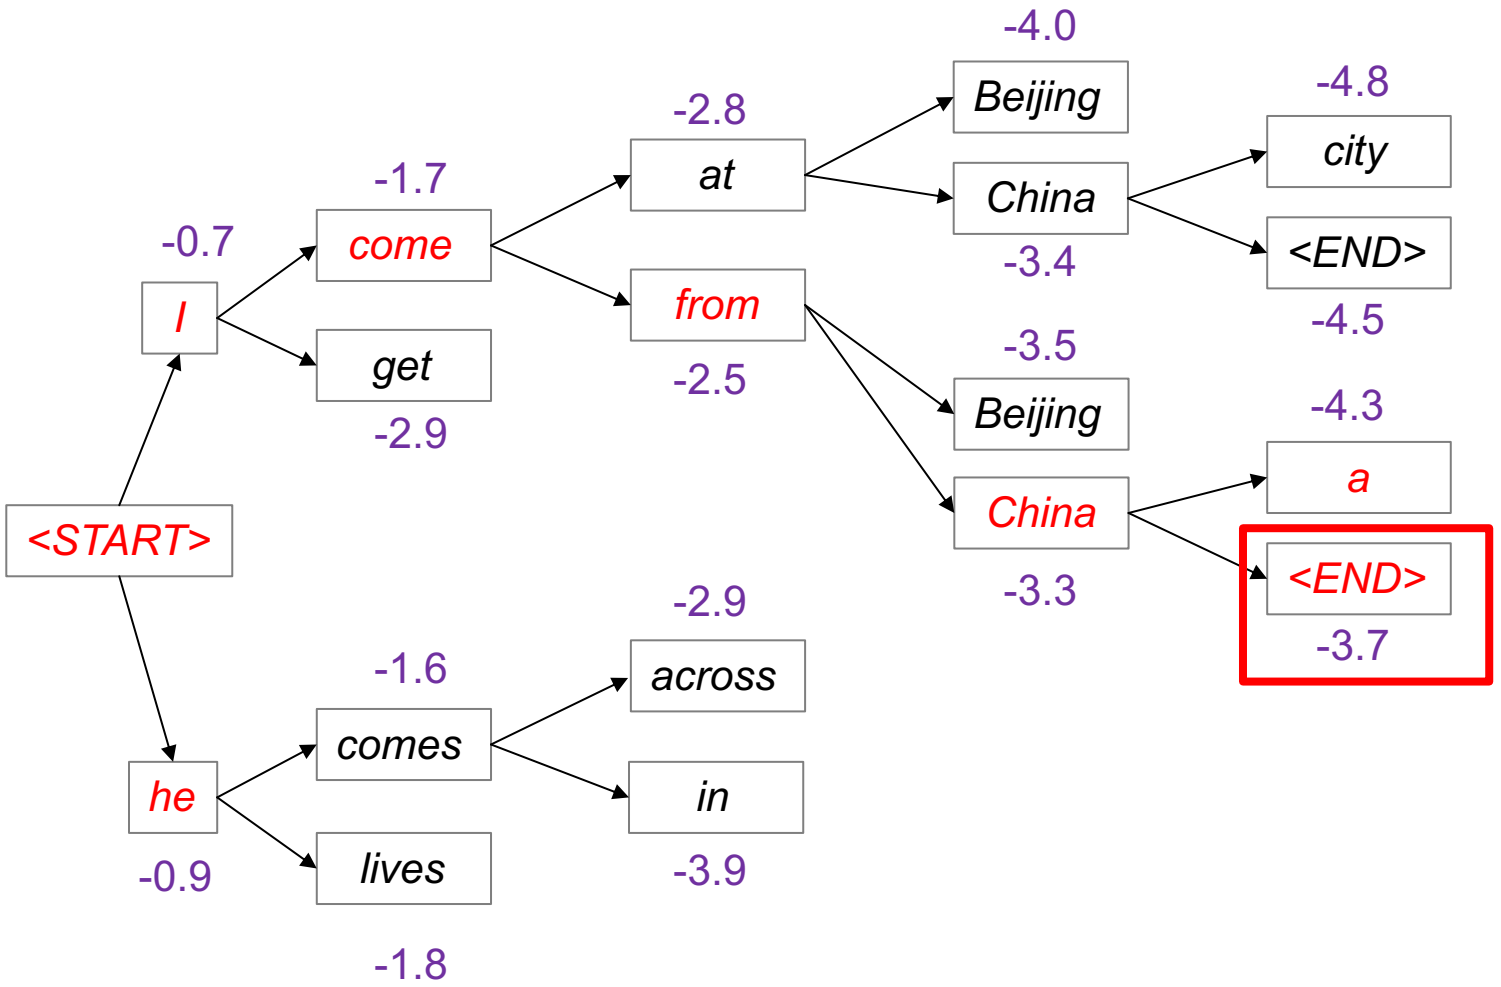

柱搜索解码样例

Beam size=2

$$score(y_1, \ldots, y_t) = \sum_{i=1}^{t} \log P(y_i \,|y_1, \ldots, y_{i-1}, x)$$

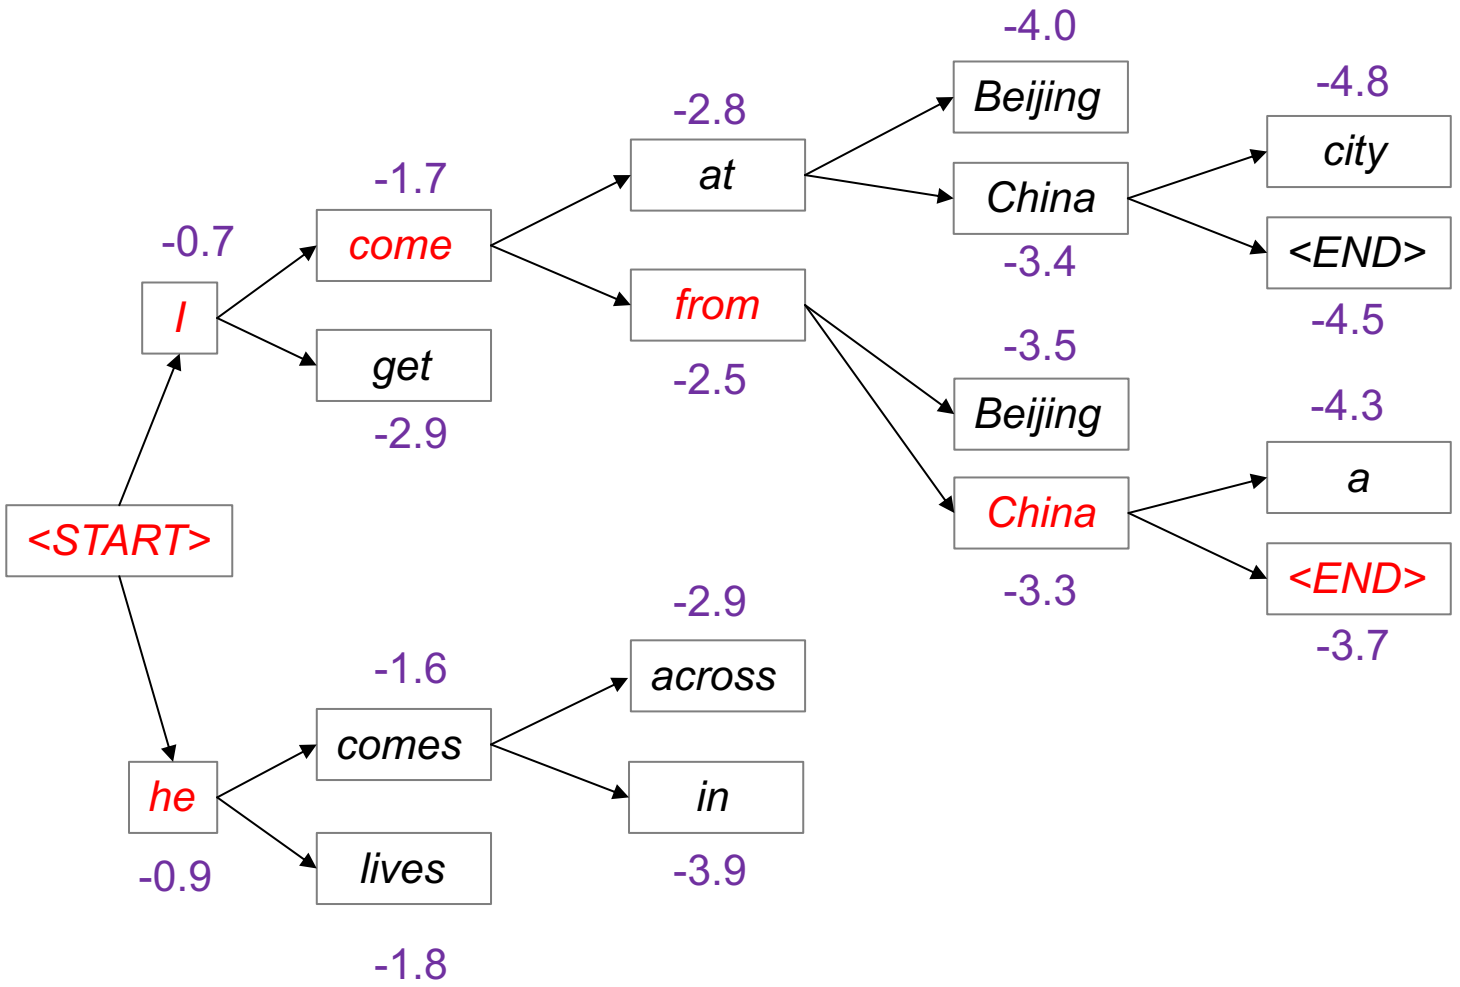

柱搜索解码算法

Algorithm 1 Standard beam search[4]

Input: x: source sentence
k: maximum beam size
n_{max}: maximum hypothesis length ← 译文最大长度
score$(\cdot,\cdot)$: scoring function

1: $B_0 \leftarrow \{\langle 0, \text{BOS}\rangle\}$ ← 译文打分和对应的译文
2: **for** $t \in \{1, \ldots, n_{max}-1\}$:
3: $B \leftarrow \varnothing$
4: **for** $\langle s, \mathbf{y}\rangle \in B_{i-1}$:
5: **if** $\mathbf{y}.\text{last}() = \text{EOS}$:
6: $B.\text{add}(\langle s, \mathbf{y}\rangle)$ ← 某条译文翻译结束，将译文保存
7: **continue**
8: **for** $y \in \mathcal{V}$:
9: $s \leftarrow \text{score}(\mathbf{x}, \mathbf{y} \circ y)$
10: $B.\text{add}(\langle s, \mathbf{y} \circ y\rangle)$ ← 计算翻译中的译文打分并暂存
11: $B_i \leftarrow B.\text{top}(k)$ ← 保留打分最高的k个译文
12: **return** $B.\max()$

南京大学
NANJING UNIVERSITY

06

机器翻译质量评估

MACHINE TRANSLATION EVALUATION

人工评估

- 评估准则（打分制）
  - 忠实度：译文对源文信息和语义的保留程度（“信”）
  - 流利度：衡量译文是否流畅通顺（“达”）

- 缺点
  - 具有主观偏差性
  - 成本昂贵
  - 效率低

自动评估

- 核心思想
  - 通过比较机器翻译的译文和参考译文（人工翻译结果）之间的相似程度来衡量翻译结果的好坏
  - 机器译文越接近人工翻译结果，其译文的质量就越好
- BLEU
  - 一种衡量机器翻译质量的自动评估指标
  - 统计机器翻译译文与参考译文中n元文法匹配的数目占系统译文中所有n元文法总数的比例，即n元文法的精确率

BLEU

- 符号定义
  - y^*：源语言句子x对应的机器翻译译文
  - $(y_1, \dots, y_M)$：M个人工参考译文
  - $count_{match}(ngram)$：某$ngram$片段在y^*和$(y_1, \dots, y_M)$中共同出现的最大次数（将系统译文和参考译文逐个对比并统计共现次数，将共现最大值作为结果）
  - $count(ngram)$： $ngram$片段在y^*中出现的次数

BLEU

- 频数统计

源语言句子：I love the Great Wall and the Imperial Palace

机器翻译译文：我 爱 长城 又 爱 爱 爱 故宫

参考译文1：我 爱 长城 和 故宫

参考译文2：我 爱 长城 也 爱 故宫

$count_{match}(我) = 1$ $count(我) = 1$

$count_{match}(爱) = 2$ $count(爱) = 4$

$count_{match}(长城) = 1$ $count(长城) = 1$

$count_{match}(又) = 0$ $count(又) = 1$

$count_{match}(故宫) = 1$ $count(故宫) = 1$

BLEU

- 计算所有$ngram$的精确率p_n
  - n为$ngram$长度，最大值一般取4（ n 增大时，$ngram$ 共现次数呈指数级下降）

$$p_n = \frac{\sum_{y^*} \sum_{ngram \in y^*} count_{match}(ngram)}{\sum_{y^*} \sum_{ngram \in y^*} count(ngram)}$$

  - 当n最大值取4时，p_1、p_2、 p_3、 p_4的加权精确率为：

$$\prod_{n=1}^{4} p_n^{w_n} \quad \text{通常} w_n = \frac{1}{4}$$

BLEU

- 精确率p_n的问题
  - p_n的计算公式中分母为机器翻译译文，译文越短， p_n的值倾向更大
  - 具有偏向性，对于漏翻的词不敏感

机器翻译译文：我 爱 长城 也 → $p_1 = 1$， $p_2 = 1$，$p_3 = 1$， $p_4 = 1$

BLEU

- 引入长度惩罚因子BP，对过短的译文进行惩罚
  - c：测试语料中每个源语言句子对应的系统译文y^*的长度之和
  - r：测试语料中每个源语言句子对应的多个参考译文$(y_1, \dots, y_n)$中最短译文或者与y^*长度最接近的参考译文的长度之和

$$BP = \begin{cases} 1 & ,c > r \\ e^{1-\frac{r}{c}} & ,c \leq r \end{cases}$$

- 综合$ngram$匹配精确率和长度惩罚因子，BLEU评分公式为：

$$BLEU = BP \times \prod_{n=1}^{4} p_n^{w_n} = BP \times \exp\left(\sum_{n=1}^{4} w_n \log p_n\right)$$

BLEU

- 优点：
  - 自动评估
  - 能够从ngram角度评估翻译质量

- 缺点
  - 无法从语义层面度量翻译质量

机器翻译挑战


7:51 PM
回去迅速消杀 自己最好消杀
Go back and kill yourself quickly. You'd better kill yourself.
Translated by Mr. Translator


@所有人 肉到了
@ All human flesh arrived
Translated by WeChat


小心地滑
Slip Carefully


Hello My test has not been collected. Is this normal?
正常的
Normal
Translated by WeChat
可以自己当垃圾处理
You can treat yourself as garbage
Translated by WeChat


请在一米线外等候
PLEASE WAIT OUTSIDE A NOODLE


Translate server error
餐厅

REFERENCE

- Nagao M. A framework of a mechanical translation between Japanese and English by analogy principle[M]. na, 1984.
- Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- Ilic S, Marrese-Taylor E, Balazs J, et al. Deep contextualized word representations for detecting sarcasm and irony[C]. Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis. 2018: 2-7.
- Kenton J D M W C, Toutanova L K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of NAACL-HLT. 2019: 4171-4186.

南京大学
NANJING UNIVERSITY

Q&A